生成式 AI 應用電台 · EP58 · HUMAN–AI COLLABORATION

不是完全放手，而是讓自主程度配得上責任制度

AI Agent 的關鍵，不是能力越強、越自動越好，而是**在對的風險層級設核准點、監看機制與自主邊界**。

本頁依**54 分 14 秒錄影、55 張關鍵畫面、508 段逐字稿與 10 頁簡報**整理，並以簡報核對專有名詞。

📅 2026/11/07（依檔案建立時間） 👤 講師：課程講師 ⏱ 54 分 14 秒 🧩 In × On × Over the Loop

COURSE INFO

0. 課程資訊與教材

課程名稱	EP58 AI Agent 該放手到哪裡？In / On / Over the Loop 人機協作
日期	2026/11/07（依簡報檔案建立時間；錄影未口述日期）
教材	1 支 54:14 錄影＋10 頁簡報
核心問題	哪些步驟必須等人、哪些可以先跑再監看、哪些能在規則內自主完成？

下載正式手冊

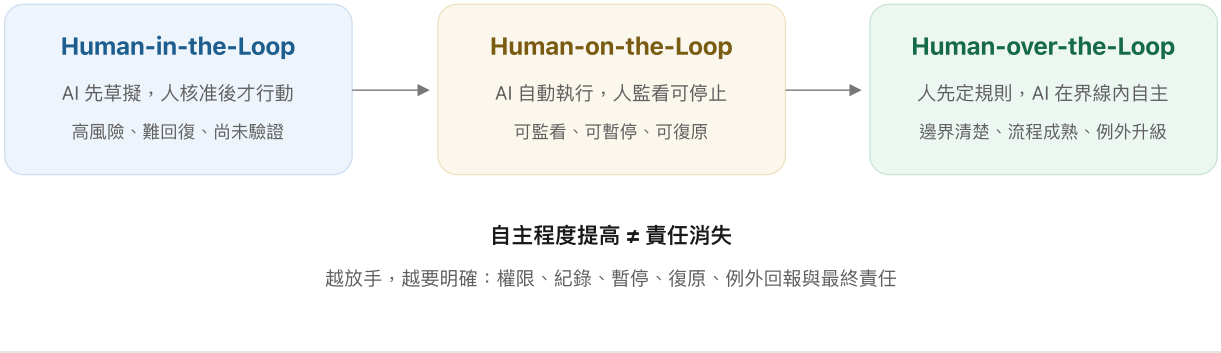
PDF 手冊 · 可編輯 Word

🔒 **公開畫面已逐張檢查。**本頁三張圖都取自簡報，已完整裁去含錯誤集數的頁首，且未含帳號、書籤列、分頁、網址、API key、個資或系統通知；原始錄影畫面不公開。

OVERVIEW

1. 一張圖看懂：放權不是二選一

人不是突然從迴圈中消失，而是把介入位置從「每一步核准」移到「監看與治理」。



三種模式不是互斥選項。同一個專案可在不同步驟使用不同模式，也可在流程成熟後逐步往右移。

00:00–10:00

2. 三種模式不是三個 AI，而是三種工作流設計

課堂先把焦點從「模型夠不夠強」拉回「人怎麼分工」。同一個模型，只要改變核准點、授權邊界與回報規則，就會形成不同的協作模式。

> **「它不是新的 AI 模型，它是一個分工的設計。」**
>
> [06:00] 先設計 AI 要協助到什麼程度，再談自主化。

- **任務：**先寫清楚完成條件與不可做事項。
- **權限：**只開放完成任務所需的最小範圍。
- **節點：**決定何時要等人、何時只通知、何時可直接執行。
- **責任：**最終仍由誰確認、修正與承擔結果。

10:00–18:00

3. Human-in-the-Loop：高風險動作前，必須等人

AI 可以找資料、整理選項、寫草案；發送、刪除、付款、公開發布或採用重要結論前，由人核准。



簡報第 3 頁：AI 起草，人決定；公開版已完整裁去含錯誤集數的頁首。

適合情境	AI 先做	人要決定
對外內容	研究、草稿、版型	事實、語氣、發布
重要文件	摘要、比對、建議	採用、簽核、送出
新工作流	跑第一版流程	逐步確認是否符合需求

「我不要直接一步登天。」

[13:13] 先看方案與草案，不讓 AI 從一句話直接跳到最終檔案。

18:00–24:00

4. Human-on-the-Loop：AI 自動執行，人持續監看

當步驟已被理解、錯誤能及時發現且可以暫停時，人不必每一步按同意，但必須看得到進度與異常。

1. 把每一步的進度與輸出留下紀錄。
2. 先定義異常門檻：超時、重複、品質下降或權限不足。

3. 提供立即暫停與人工接手機制。
4. 確認已產生的副作用能復原或補救。

⚠ 只有「看得到」還不夠；如果不能停、不能接手、不能回復，就不是真正可控的監看。

24:00–36:00

5. Human-over-the-Loop：先走過一次，再讓 AI 在界線內自主

課堂反覆強調：自主不是憑感覺信任，而是把已驗證的做法寫成規則。正常路徑由 AI 完成，例外才升級給人。



簡報第 5 頁：人設目標、邊界與政策，AI 在邊界內自主運作，例外回報；公開版未含集數頁首。

「他做完一次，我發現這個流程是順暢的，接著我會把它寫成規矩。」

[24:00] 先驗證，再規格化，最後才放權。

放權前檢查	要能回答
完成定義	什麼叫做好？品質如何驗收？

允許範圍	能讀寫哪些資料、能用哪些工具？
禁止事項	哪些動作永遠要問人？
例外處理	遇到不確定、超時或衝突時怎麼升級？
可追溯性	人能否知道它做過什麼、為何這樣做？

34:00–42:00

6. 對話規則與系統權限，要分開設計

在 Chatbot 專案裡，自訂指示可以寫角色、工作規則、介入點與回報方式；在能使用工具的 Agent 環境裡，則可用 `AGENTS.md` 表達長期規則。文字規則是行為約定，真正的檔案、網路與系統權限仍由工具環境強制執行。

`Role`：你負責什麼，不負責什麼
`Allowed`：可以讀寫哪些範圍、使用哪些工具
`Approval`：哪些動作執行前必須取得同意
`Escalation`：遇到不確定、衝突或失敗時如何停下並回報

🔧 **文字不是安全邊界。**若工具環境仍允許高風險操作，不能只靠提示詞期待它永遠遵守；要用權限、隔離、版本紀錄與審核共同約束。

40:00–50:00

7. 多 Agent 可以分工，但不能變成看不見的黑箱

課堂以研究、影片製作與檢查等角色示範任務交接。角色越多，越需要一位負責拆解與整合的管理角色，以及一致的紀錄格式。

必要元件	作用
管理者	拆任務、指定角色、整合結果，不直接包辦所有工作。
專業角色	研究、製作、檢查各自有明確輸入與輸出。

交接格式	記錄來源、完成項目、未決問題與下一棒。
品質閘門	檢查事實、版權、格式與風險後才進下一步。
人類介入點	初期看分鏡與重要決策；成熟後可改成只看例外與最終驗收。

課堂現場遇到權限與預覽問題，正好說明多 Agent 的難點不只在「叫誰做」，還在分享、權限、狀態同步、失敗復原與成果驗證。

50:00–54:14

8. 用風險、可逆性與可監看性選模式



簡報第 10 頁：高風險用 In；可監看、可暫停的流程用 On；規則清楚、低風險的成熟流程才適合 Over。公開版已完整裁去含錯誤集數的頁首。

問題	若答案偏高 / 偏難	建議
錯一次的損失大嗎？	金錢、名譽、法規或不可逆影響	Human-in-the-Loop
出錯能即時發現嗎？	可以觀察、暫停、回復	Human-on-the-Loop
規則與例外穩定嗎？	界線清楚、流程已多次驗證	Human-over-the-Loop

✅ 成熟的做法不是整個專案只選一種模式，而是逐步分級：研究可 Over、製作可 On、對外發布仍 In。

TAKEAWAY

9. 這堂課真正在教的事

1. **先設計流程，再挑工具。**模型不會替你決定責任邊界。
2. **先帶 AI 走過一次，再把做法寫成 Skill。**沒有驗證的自動化，只是把錯誤跑得更快。
3. **自主程度提高，治理也要升級。**可追蹤、可暫停、可復原與例外升級不能省略。
4. **同一流程可混用三種模式。**依步驟風險，而不是依工具名稱判斷。

💡 最實用的落地句：**先走過、驗證、寫成規則，再逐步放權。**

QUOTES

10. 老師金句

「它不是新的 AI 模型，它是一個分工的設計。」

[06:00]

「我不要直接一步登天。」

[13:13]

「已經走過一遍，已經實踐一遍了。」

[24:59]

「我把規則寫清楚，授權範圍也寫清楚。」

[27:51]

SOURCES

11. 資料來源與整理限制

- 來源：54:14 課堂錄影、55 張自動擷取關鍵畫面、508 段語音轉錄、10 頁原始簡報。
- 專有名詞以簡報為準；逐字稿中的辨識錯字未當成事實依據。
- 時間戳是段落索引，可能與播放器顯示相差數秒。
- 公開頁只使用三張經人工檢視並裁去錯誤集數頁首的簡報畫面，不含原始影片、整份簡報與課堂介面截圖。
- 這是課堂整理，不是法律、資安或組織治理的正式意見。