生成式 AI 應用電台 · EP59 · STRATA

讓模型住進電腦，再接上 AI Agent

Strata 不只是另一個模型，而是把模型載入、本機服務與操作介面接在一起的執行環境。這堂從硬體盤點、模型選擇、安裝與錯誤處理，一路示範到本機服務如何接進工作工具。

本頁依**20 分 5 秒錄影、28 張關鍵畫面、210 段逐字稿與 11 頁簡報**整理，重點段落附影片時間戳。

📅 2026/11/07 | 👤 講師：課程講師 | ⏱ 全長 20 分 5 秒 | 🧩 主題：硬體盤點 × 本機模型 × AI Agent | 🔰 小白友善

COURSE INFO

0. 課程資訊與教材

課程名稱	EP59 Strata 地端 AI 實戰：在自己電腦跑大模型，串接 AI Agent
日期	2026/11/07（依簡報檔案建立時間；錄影未口述日期）
錄影長度	20 分 5 秒
教材	1 支錄影＋11 頁簡報
本堂主題	硬體盤點、Strata 安裝、模型選擇、本機服務、工作工具串接與故障處理
要先準備	Windows 或 Linux 電腦、足夠的 SSD 空間；建議先確認 GPU、VRAM、RAM 與顯卡驅動

📁 課程資料夾（Google Drive）

原始錄影與完整簡報保留在課程資料夾，本頁只公開整理後筆記與四張必要、無身分資訊的簡報畫面。

🔗 開啟「EP59 Strata 地端 AI 實戰」課程資料夾 ›

教材檔案	在本頁的用途

EP59_Strata…mp4	核對課堂實際操作順序、現場遇到的相容性問題與老師原話。
簡報_EP59_Strata…pptx	補上硬體盤點、安裝路線、終端機指令、Agent 串接與故障處理的完整脈絡。

帶走一份正式手冊

下載課堂筆記 PDF · 下載可編輯 Word

📖 本頁不鏡像原始錄影或整份簡報。工具版本、安裝指令與相容模型可能更新，真正安裝前請再回官方專案核對。

🔒 **公開畫面已逐張檢查。**四張圖片都取自簡報頁面，未包含課堂帳號、瀏覽器分頁、書籤列、個人名稱、真實 API 金鑰或系統工作列。

OVERVIEW

1. 一張圖看懂這堂

這堂課的主線不是「下載一個模型」，而是把硬體、模型、本機服務與工作工具串成一條可以重複使用的路。



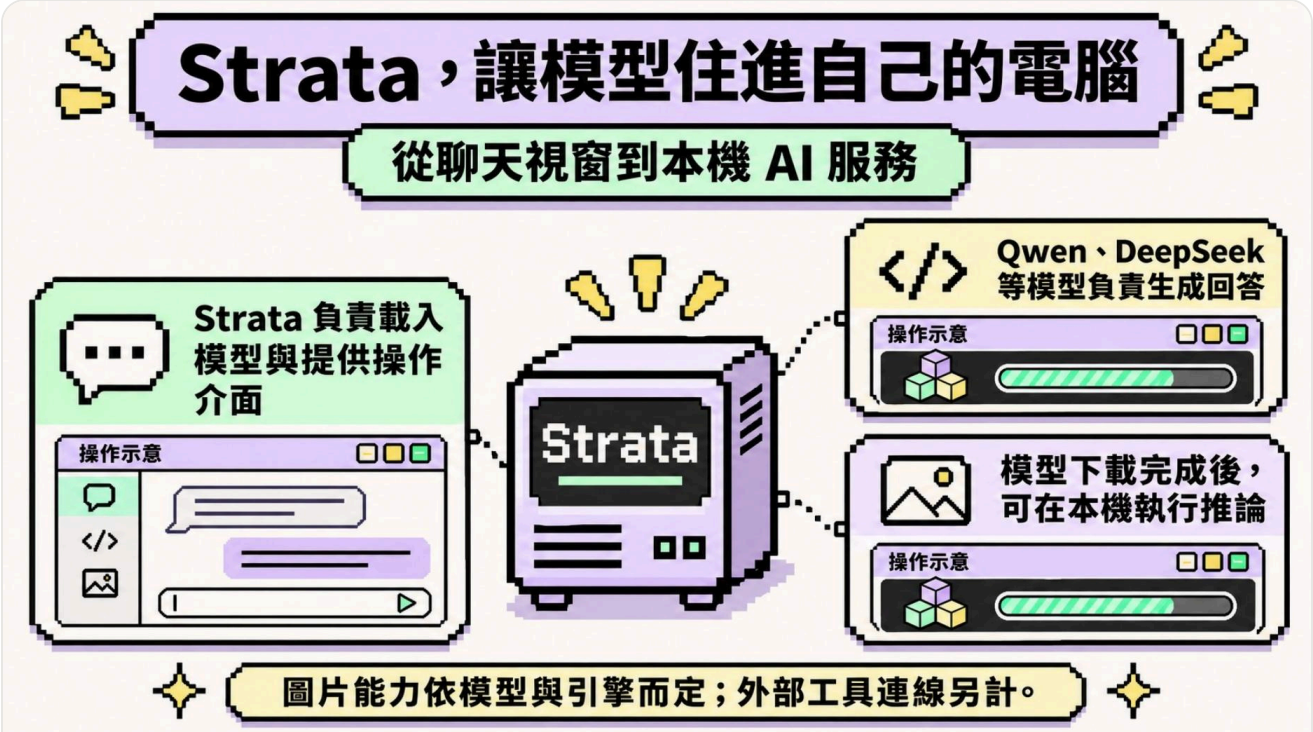
先讓一個小模型穩定跑起來，再談圖片、長上下文與 Agent；這比一開始追最大模型更容易完成。

💡 如果只記得一句話，記這句：**本機 AI 不是「免費的雲端 AI」，而是把費用、速度、維護與治理責任移回自己的電腦。**[02:30–02:38]

00:36–02:46

2. Strata 是執行環境，不是另一個模型

老師一開始先拆開「模型」和「讓模型運作的環境」。Strata 的角色，是載入相容模型、提供聊天介面與本機服務，再讓其他工具連進來。



簡報把角色拆成兩層：Qwen、DeepSeek 等模型負責生成回答；Strata 負責載入模型與提供操作介面。模型下載完成後，推論才在本機進行。[01:10–02:30；簡報第 3 頁]

層次	它負責什麼	這堂提醒的限制
模型	理解提示、產生文字，部分模型可看圖或處理更多媒體。	能力、授權、來源與硬體需求各不相同。
Strata	協助載入模型、建立操作介面與本機連線服務。	支援範圍依版本、引擎與模型格式而變。

AI Agent / 工作工具	透過服務位址和模型名稱，把本機模型用在程式、檔案或自動化任務。	仍要控制檔案、工具與系統權限。

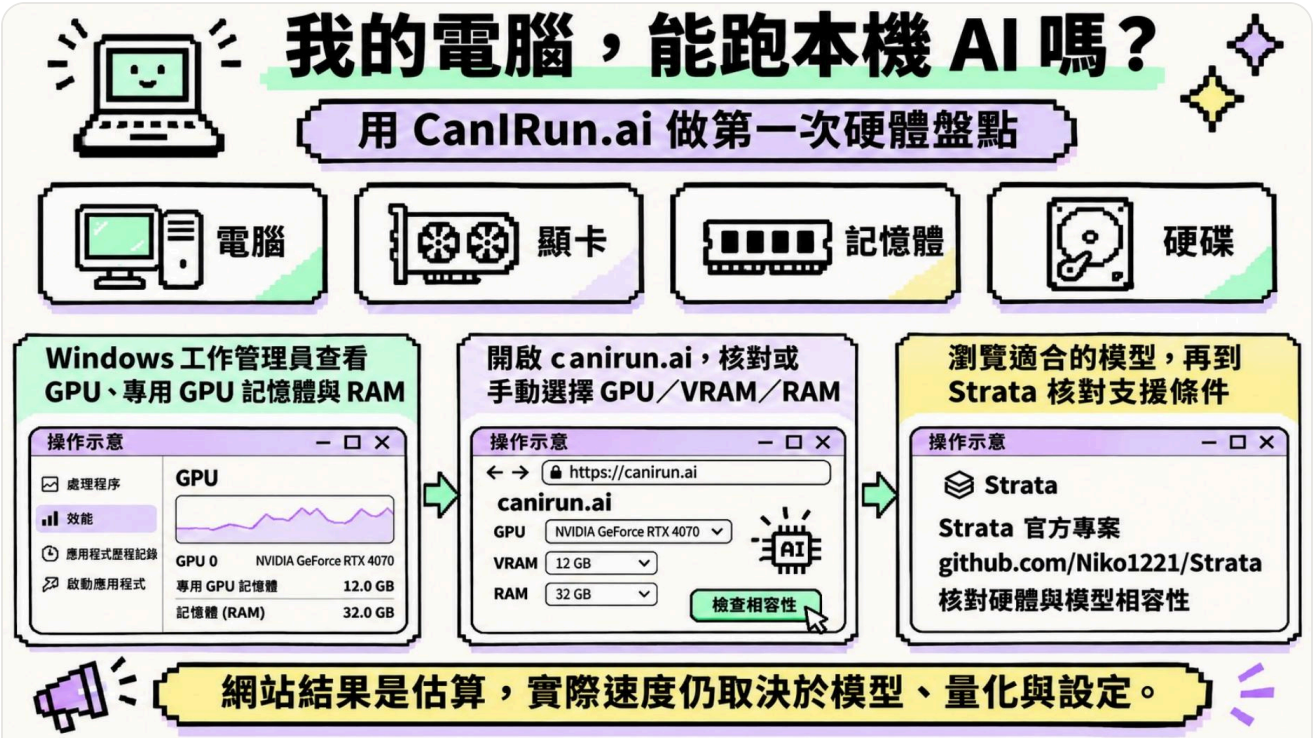
> **「而且可以接自己的電腦工具，全部都在你自己的電腦端執行。」**
>
> [02:12] 老師用這句交代本機模型與 Agent 串接的核心價值。

🔧 「本機執行」不代表所有功能都不連網。模型下載、更新、外部搜尋與第三方工具仍可能需要網路；要依實際設定逐項確認。

02:47–04:24

3. 先問硬體跑不跑得動，再談模型大小

老師示範 CanIRun.ai，讓學員先用 GPU、VRAM、RAM 與硬碟條件估算可用模型，再回 Strata 核對支援狀態。



先從 Windows 工作管理員查看 GPU、專用 GPU 記憶體與 RAM，再用 CanIRun.ai 做第一輪估算，最後回 Strata 與官方文件核對。網站結果只是起點，實際速度還會受模型、量化與設定影響。[02:47–04:24；簡報第 2 頁]

硬體判讀，不是只看一個數字

項目	影響	不夠時先怎麼做
GPU / VRAM	決定模型能否主要在顯卡上推論，以及速度上限。	改用較小模型或較低量化，必要時降低圖片能力。
RAM	影響模型載入、上下文與系統同時運作的餘裕。	縮短上下文，關閉其他程式，先維持單一請求。
SSD	模型檔、引擎與快取會佔用大量空間。	先規劃儲存位置；不要用「下載大小」直接推論記憶體用量。
任務類型	文字、圖片、影音與長上下文需要的資源不同。	先定義最小任務，再選模型，不用一開始就追求全能。

> **「不是不好，就是你現在配備可能沒辦法跑到它這樣的結果。」**
>
> [03:52] 網站顯示某個 20B 模型太重時，老師把判讀焦點拉回「配備與模型是否相配」。

04:25–07:58

4. 安裝只是起點，模型相容性才決定能不能用

課堂先提到從 GitHub 取得 Strata，也示範讓 AI 助理按官方說明協助安裝。簡報則把桌面版、終端機與 Docker 分成三條路。

依使用習慣選安裝路線

路線	適合誰	先注意
桌面版	想用視窗完成模型選擇與聊天的初學者。	下載對應作業系統的安裝檔，確認偵測到顯卡。
終端機	需要狀態檢查、停止服務或串接工具的人。	完成官方 Terminal 安裝後，才使用 `strata launch`。

Docker	已熟悉容器與網路設定的進階使用者。	依官方文件操作，不把課堂示意當成每個版本都適用的固定指令。

```
strata launch
strata launch --status
strata launch --stop
```

這三個指令來自簡報第 9 頁，分別用來逐步啟動、查看狀態與停止模型。簡報也示範用 `--plan` 先看下載規劃；實際參數要以目前版本的官方說明為準。

第一次啟動，先求穩定

1. 先更新顯卡驅動，確認 SSD 有足夠空間。
2. 用硬體條件篩出相容模型與量化版本，不直接選最大的。
3. 上下文先設小一點，單人使用先維持一個請求。
4. 下載完成後，用一小段自己有權使用的文字測試繁中摘要。
5. 確認內容有依據、等待時間可接受，再增加圖片或其他能力。

> ⚠️ 課堂 06:00–07:58 的實際下載花了時間，老師也當場發現某些模型太大或不適合當下電腦。這不是失敗，而是本機 AI 必須納入的正常成本。

07:58–09:59

5. 地端不等於可以放進任何資料

老師談到機敏資料時，特別提醒公家與教育單位仍要遵循各自的規範。資料留在電腦裡，只解決了傳輸位置的一部分問題。

常見誤解	課堂筆記應補上的判斷
「沒有上雲，所以什麼資料都能放。」	仍要確認機關規範、資料分級、用途限制、保存位置與人員權限。
「模型在本機，所以完全不會連網。」	下載、更新、外部搜尋、Agent 工具與遙測可能連網；要逐項查設定。

「模型免費，所以沒有成本。」	硬體、電力、等待時間、維護與故障處理都是真實成本。
「開了資料夾權限，Agent 就能自動做好。」	先只開最小必要權限，測試小任務，再逐步擴大。

🔒 **這裡是課堂風險提醒，不是法規解釋。**各單位規範會變動；使用真實機敏資料前，應依目前有效的內部規定與主管機關要求確認。

錄影在 09:20–09:59 回到 Strata 介面，老師說明本機模型可以像一般聊天工具一樣使用，也可以安排 Agent 任務。這個便利性反而更需要把「模型權限」和「工具權限」分開管理。

10:00–16:59

6. 現場卡住的地方，正是實作課最有用的部分

下載等待、引擎不支援、模型供應商設定與 Model ID 都在現場遇到。錄影沒有剪成一條假裝一次成功的流程，而是留下除錯的真實順序。

把卡住處翻成可重複的除錯步驟

1. **確認下載是否完成：**模型檔沒有就緒，介面能打開也不能推論。
2. **核對引擎支援：**錯誤畫面顯示 model type 不被支援時，先查目前引擎與模型格式。
3. **選對供應商：**要接自訂本機模型時，選自訂或本機設定，不把外部服務欄位硬套進去。
4. **依服務回報填 Model ID：**不要從檔名猜模型名稱。
5. **保留 Logs：**啟動失敗時，把錯誤訊息交給協助安裝的人或 AI 助理，比只說「不能用」有效。

現場現象	不要急著下的結論	下一步
下載很久	不是模型一定壞掉。	查看檔案大小、網路與磁碟空間。
模型類型不支援	不是整臺電腦都不能跑地端模型。	換相容格式 / 量化或更新引擎。
服務逾時	不是 Agent 完全不能用。	改用小模型、小任務與較短上下文。

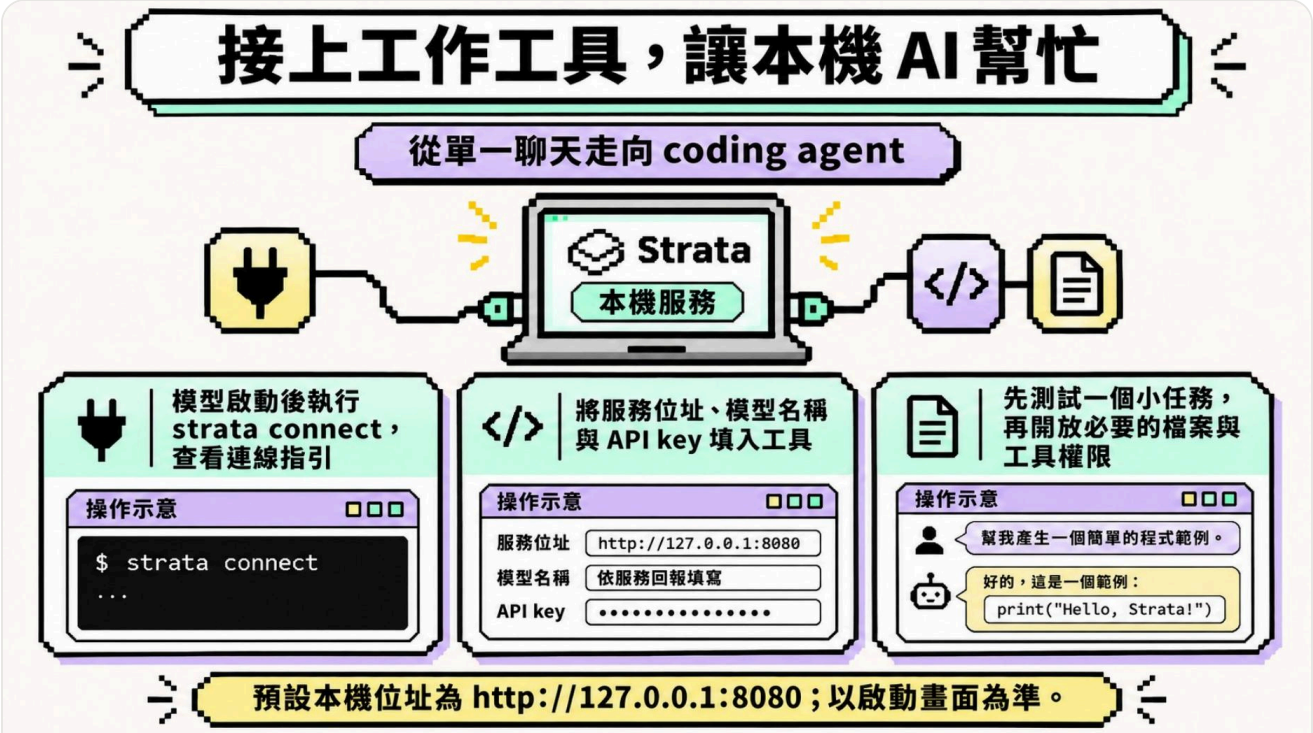
介面要求服務位址或模型名	不要填入真實 API 金鑰做試錯。	依本機服務的連線指引填寫。

🛠️ 簡報第 11 頁把兩個最常見問題寫得很清楚：記憶體不足就縮短上下文、關閉圖片或改小模型；啟動失敗就看 Logs、核對驅動，更新前先停止模型。

17:00–20:05

7. 接上 Agent 後，算力、速度與權限要一起管理

後段把地端模型接回工作工具，並實際看到速度慢與逾時。地端不是雲端模型的無限免費版，而是一種不同的取捨。

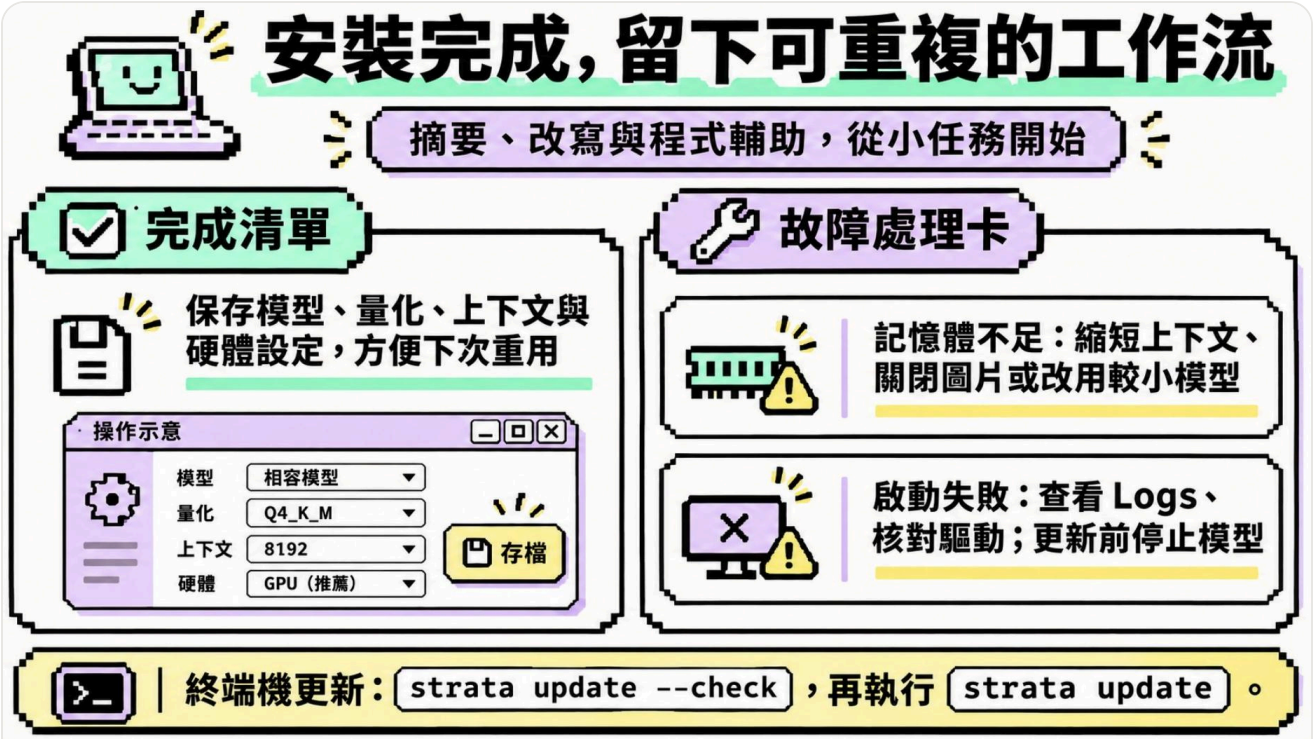


模型啟動後，以 `strata connect` 查看連線指引，再把服務位址與模型名稱填入工作工具。示意圖中的 API key 是遮罩占位，不是真實金鑰；正式使用時只依服務需求提供必要憑證。[17:00–17:55；簡報第 10 頁]

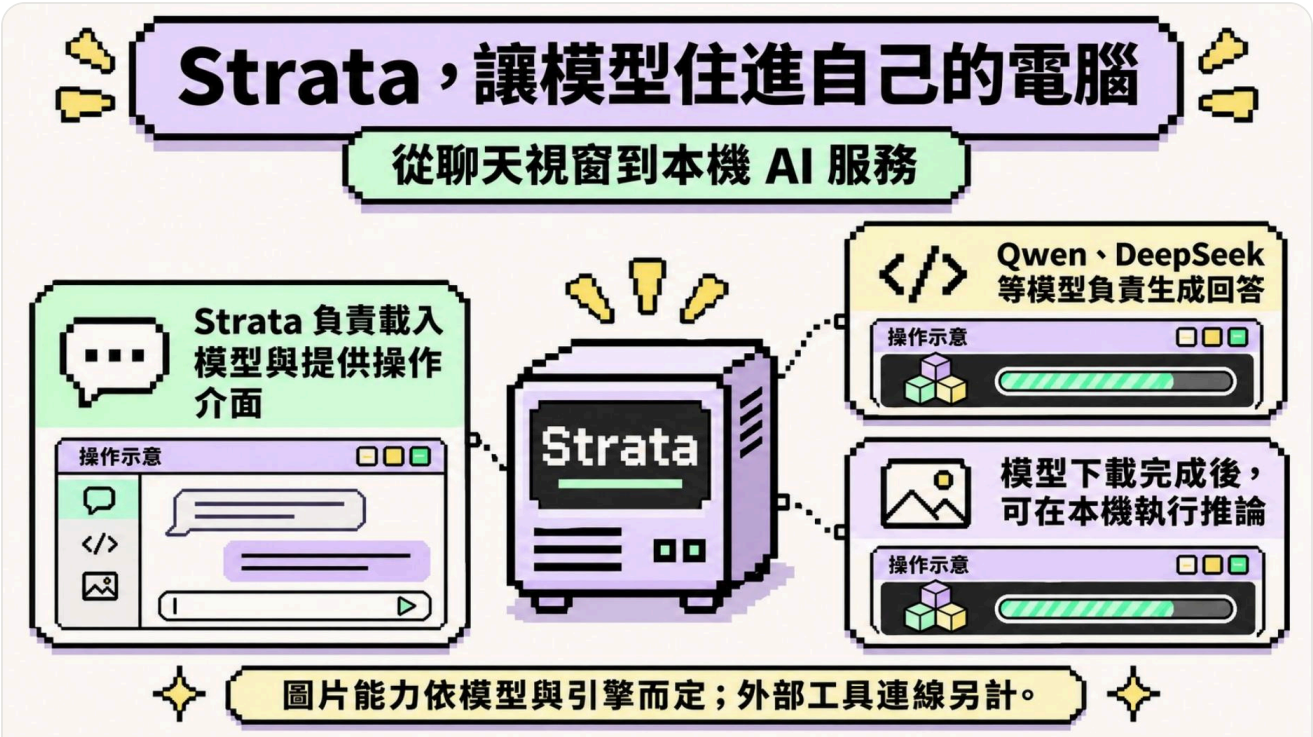
從單一聊天走向 Agent，照這個順序

1. 確認模型能在 Strata 裡完成一個小型文字任務。
2. 啟動本機服務，取得實際服務位址與模型名稱。

3. 在工作工具裡新增自訂模型供應商。
4. 先測一個不含敏感資料的小任務，例如產生簡單程式範例。
5. 確認速度、穩定性與回應品質，再開放必要的資料夾或工具權限。



可重複的工作流要保存模型、量化、上下文與硬體設定；出錯時先縮小任務與資源需求，再查 Logs 和驅動。[18:00–20:05；簡報第 11 頁]



本機推論的優勢是資料處理位置與工具連線可由自己掌握；代價是速度、電力、硬體與維護也由自己承擔。［18:00–18:45；簡報第 3 頁］

「畢竟是地端模型，如果你要達到跟雲端模型一樣的速度的情況下，它需要一點時間。」

［18:00］現場測試出現等待與逾時後，老師把速度差異講得很直接。

💡 老師的實際用法是把剪影片、查資料這類可等待的任務交給地端跑，完成後再回來查看。這是一種用時間換隱私與成本控制的排程思路，不是所有任務都適合。

00:36–20:05

8. 這堂課真正在教的事

一、先定義任務，再挑模型

文字摘要、圖片理解、影音處理和 coding agent 的資源需求不同。先從一個可驗收的小任務開始，模型才有合理的選擇標準。

二、相容性比「最大、最新」更重要

能下載不等於能載入，能載入不等於穩定。模型格式、量化、引擎、驅動與硬體要一起看。

三、地端只是資料治理的一個技術條件

資料未上雲，不代表自動符合組織規範；來源、用途、存取權、Logs 與工具連線仍要管理。

四、現場卡住要留下可查的證據

把下載狀態、錯誤訊息、Logs、設定和 Model ID 保存下來，下一次才能重複，也能請人有效協助。

五、Agent 先給最小權限

先測不含敏感資料的小任務，再逐步開放資料夾和工具；不要因為模型在本機，就一次交出整臺電腦的權限。

✅ 最小驗收：**能啟動、能完成一個小任務、知道用了哪個模型與設定、清楚它能讀哪些資料、出錯時能找到 Logs。**

QUOTES

9. 老師金句

「而且可以接自己的電腦工具，全部都在你自己的電腦端執行。」

[02:12] 用一句話點出本機模型與 Agent 串接的核心。

「它不會計算費用，原則上它就是靠你自己電腦的硬體，還有你電腦的電力。」

[02:33] 提醒「不按 Token 計費」只是把成本換成硬體、電力與等待時間。

「不是不好，就是你現在配備可能沒辦法跑到它這樣的結果。」

[03:52] 面對太重的模型，問題是配對，不是替電腦貼上好壞標籤。

「通常都需要載地端的時候要稍微等它一下。」

[11:31] 模型下載與準備不是雲端服務的即開即用體驗。

「畢竟是地端模型，如果你要達到跟雲端模型一樣的速度的情況下，它需要一點時間。」

[18:00] 回應現場逾時，說明速度是地端方案的真實取捨。

「所以我通常都會把地端放著，讓它去剪影片，讓它去查資料。」

[18:28] 用可等待的背景任務，說明地端模型適合被放進什麼工作節奏。

SOURCE

10. 資料來源與整理說明

來源	EP59 課堂錄影 1 支（20:05）與同課程簡報 11 頁。
整理方式	全程本機處理；場景偵測保留 28 張關鍵畫面，產生 210 段逐字稿，再把錄影操作與簡報內容合讀成正式筆記。公開頁精選 4 張簡報畫面。
時間戳	［mm:ss］對應錄影播放器時間；簡報補充另標頁碼，不冒充錄影當下已完成的操作。
整理	竹貞（Tarshar 的逐幀筆記專員）

已知限制，請先看過再引用

- 逐字稿是機器產生的，人名與工具名可能聽錯；正式頁只保留能由畫面、簡報或上下文佐證的用語。
- 片頭與片尾靜音曾產生無關的辨識幻覺，已從 raw 逐字稿與正式頁移除。
- 錄影中 Strata 安裝、模型下載與自訂模型串接沒有全部一次成功；本頁照實保留，沒有把示範改寫成全數完成。
- 簡報的指令、位址與設定是課程當時版本；實作前要再核對官方專案與目前版本。
- 課堂對公家或教育單位的資料規範屬風險提醒，不是最新法規或各單位內規的完整說明。
- 公開畫面未使用原始桌面錄影截圖；簡報頁已逐張檢查，無帳號、分頁、書籤、真實 API 金鑰與個資。
- 教材與課堂畫面版權屬原作者。若原作者或課程方希望撤下，請透過聯絡頁告知，將即刻移除。
