L22 口訣圖卡總冊

點下面任一行，直接跳到那一組圖卡

我的手繪卡 2 張 ›

11/2 K3 假設檢定 3 張 ›

11/2 K4 選哪一種檢定 1 張 ›

11/2 K5 分類指標 2 張 ›

11/3 K1 敘述統計與相關 2 張 ›

11/3 K2 機率分佈與定理 2 張 ›

11/4 K8 大數據元件 2 張 ›

11/4 K9 資料儲存與 NoSQL 2 張 ›

11/4 K10 資料處理與特徵轉換 2 張 ›

11/4 K13 隱私與治理 2 張 ›

11/5 K6 分析方法辨識 3 張 ›

11/5 K7 模型訓練與調校 2 張 ›

11/5 K11 視覺化工具 1 張 ›

11/5 K12 視覺化設計原則 1 張 ›

K3 教學圖 1～11 11 張 ›

預設：沒資格

	H0 真	H0 假
保留 O	判斷正確沒資格 1−α	型二 判錯，有資格，當沒資格 β
拒絕 X	型一 α 判錯，沒資格當成有資格	判對，有資格，也過了 1−β 檢定力

‹ 回目錄

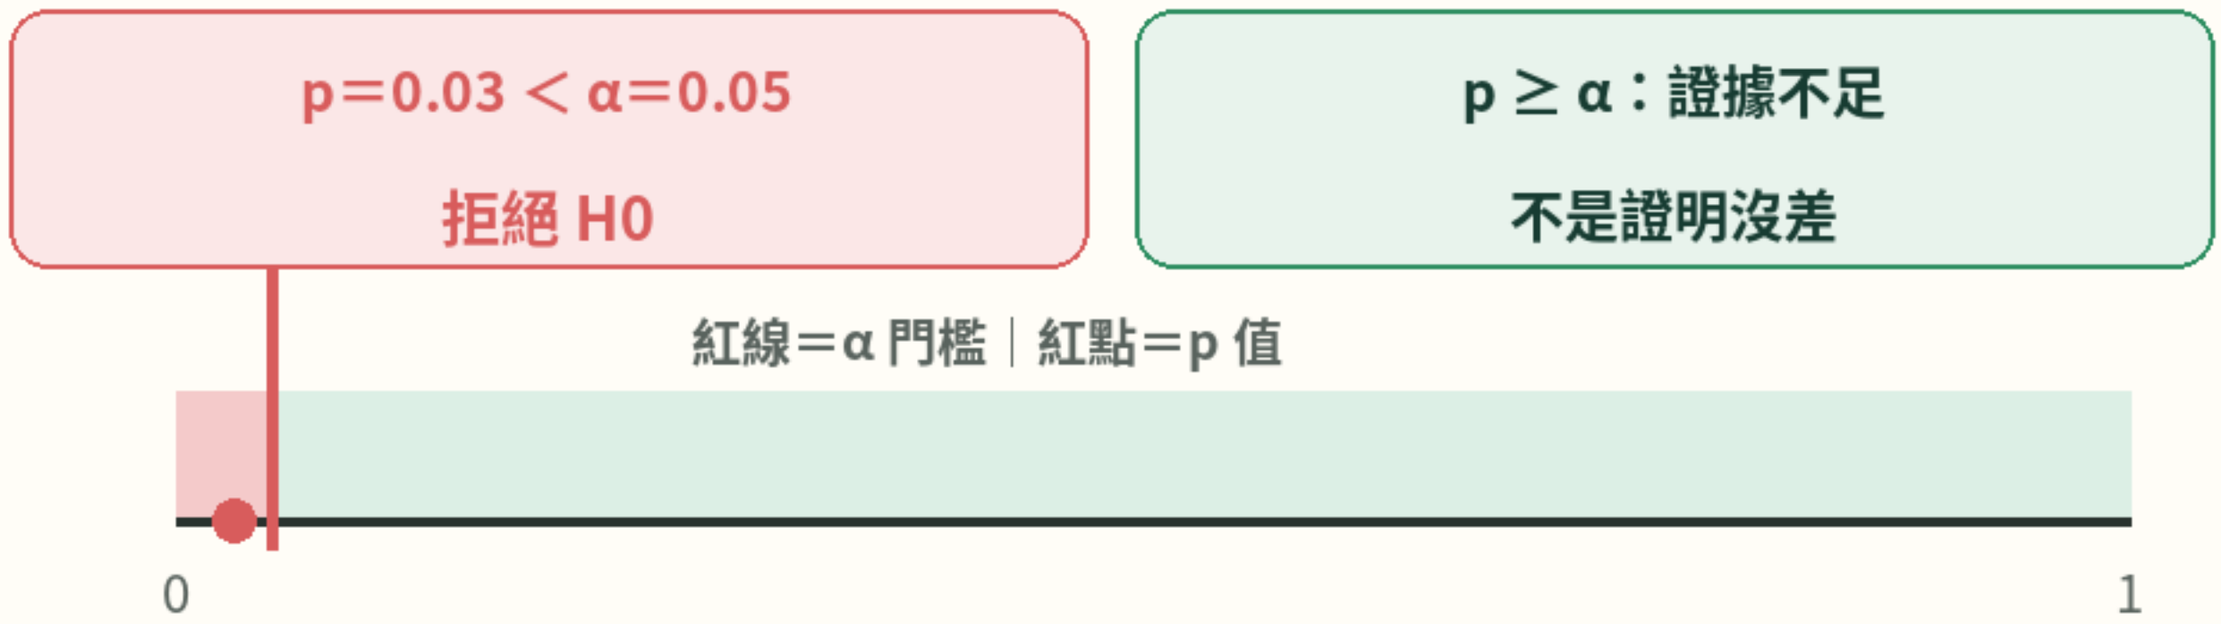
信賴區間

‹ 回目錄

K3 假設檢定

視覺記憶卡｜第 1／3 張

K3-1



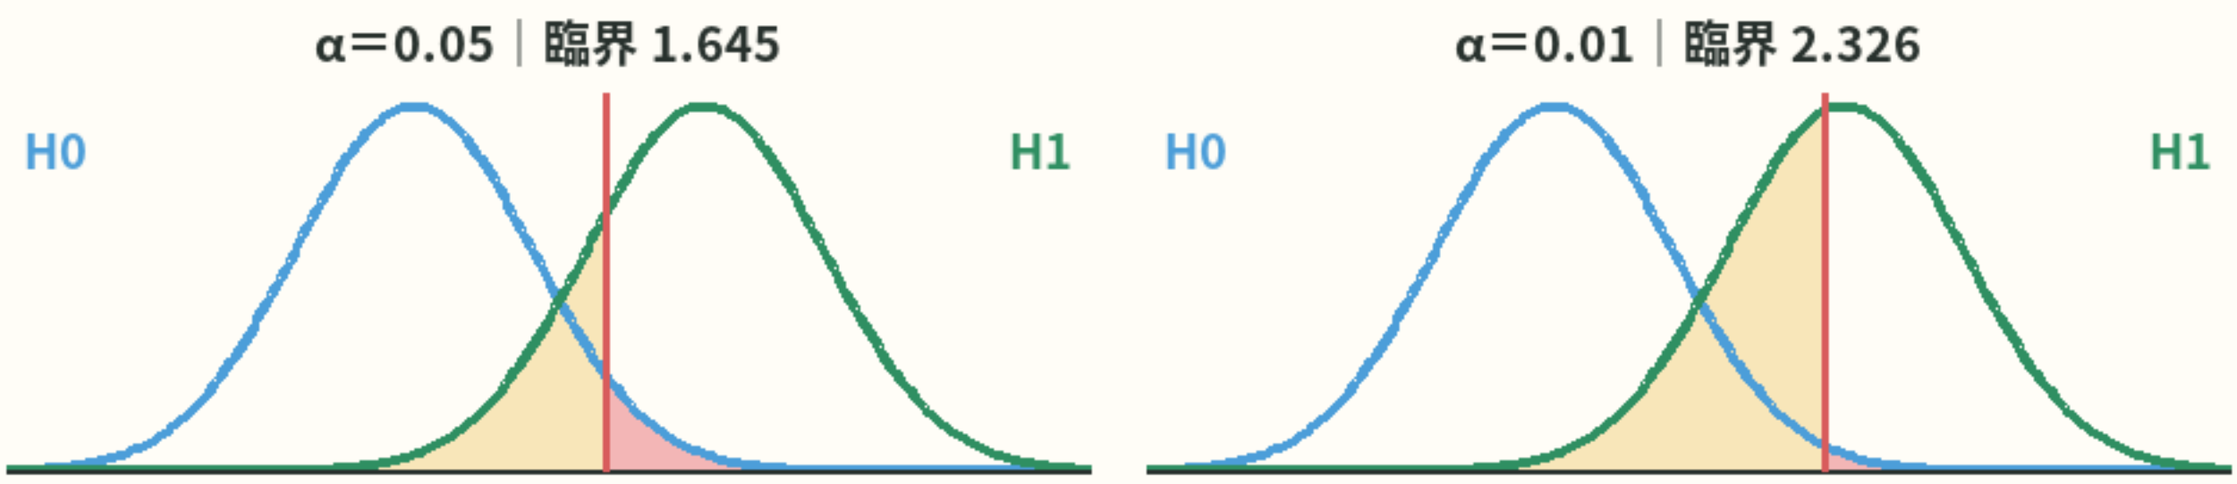
p 小就拒絕

K3-2

	事實：H0 為真	事實：H0 為假
保留 H0	正確 1−α	型二錯誤 β 該做沒做（放走壞人）
拒絕 H0	型一錯誤 α 不該做卻做（冤枉好人）	正確 檢定力 1−β

型一冤枉好人，型二放走壞人

K3-3



β≈19.6%

β≈43.1%

α 調小，冤枉變少、放走變多

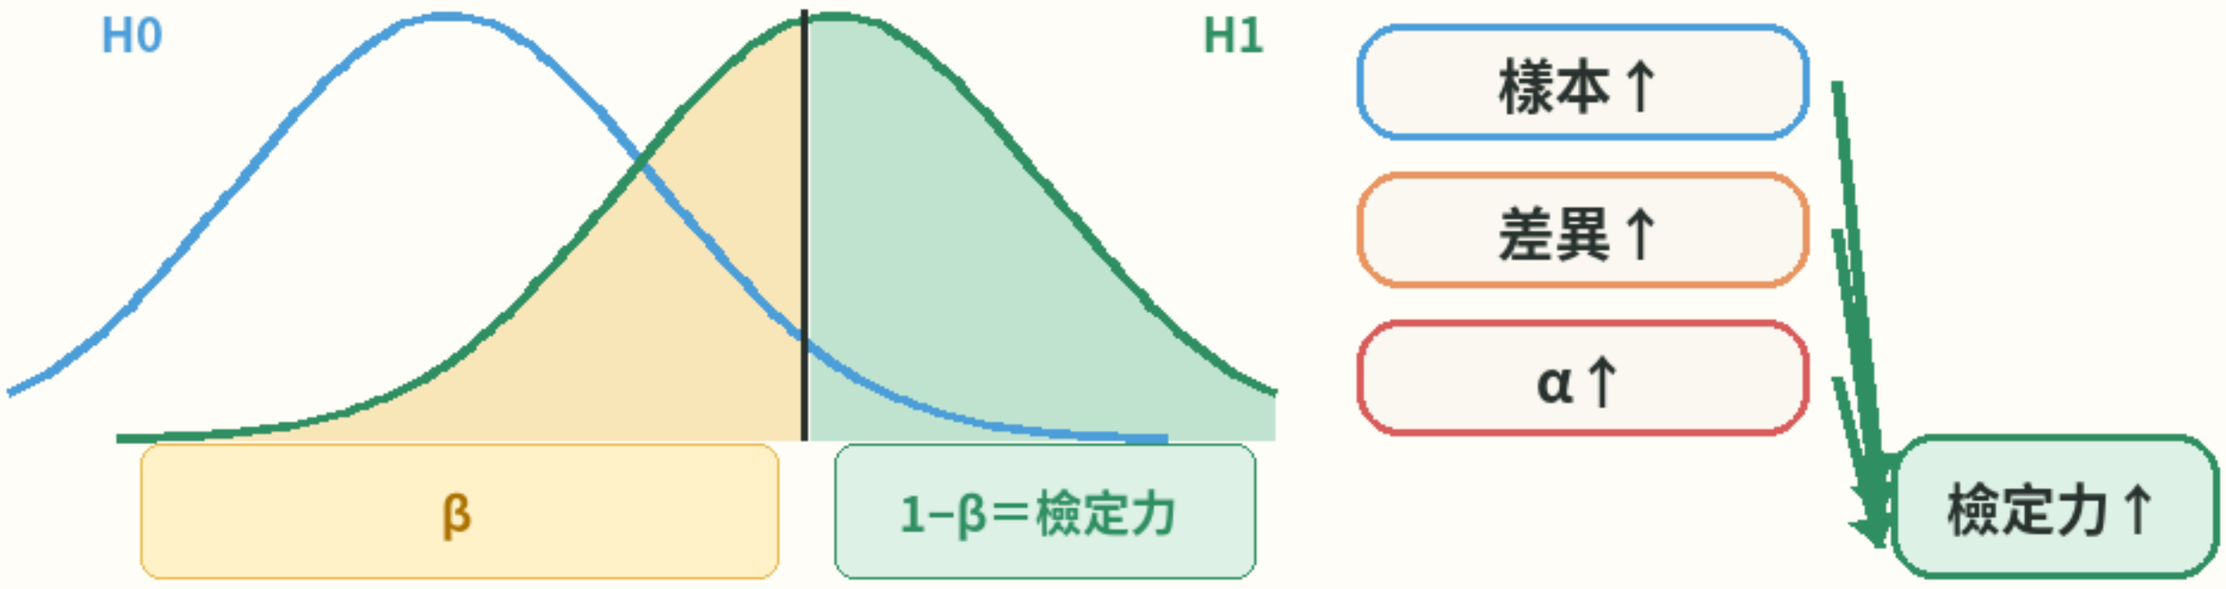
看圖默講觀念｜騎車時不看手機

‹ 回目錄

K3 假設檢定

視覺記憶卡｜第 2／3 張

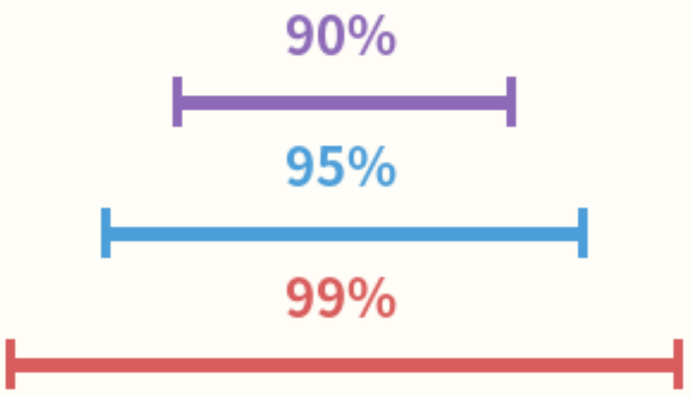
K3-4



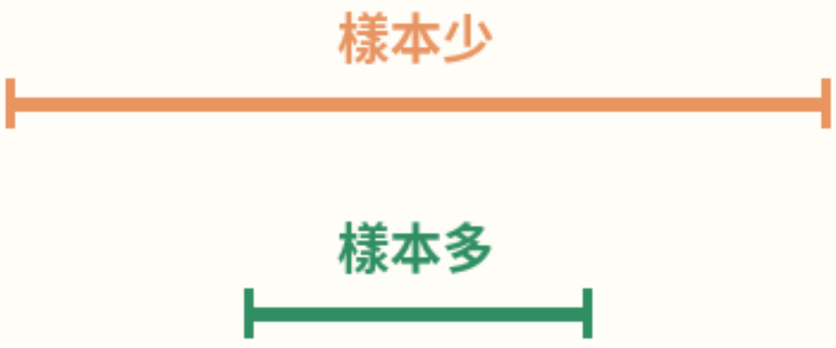
檢定力＝抓到壞人的本事

K3-5

信賴水準越高，區間越寬



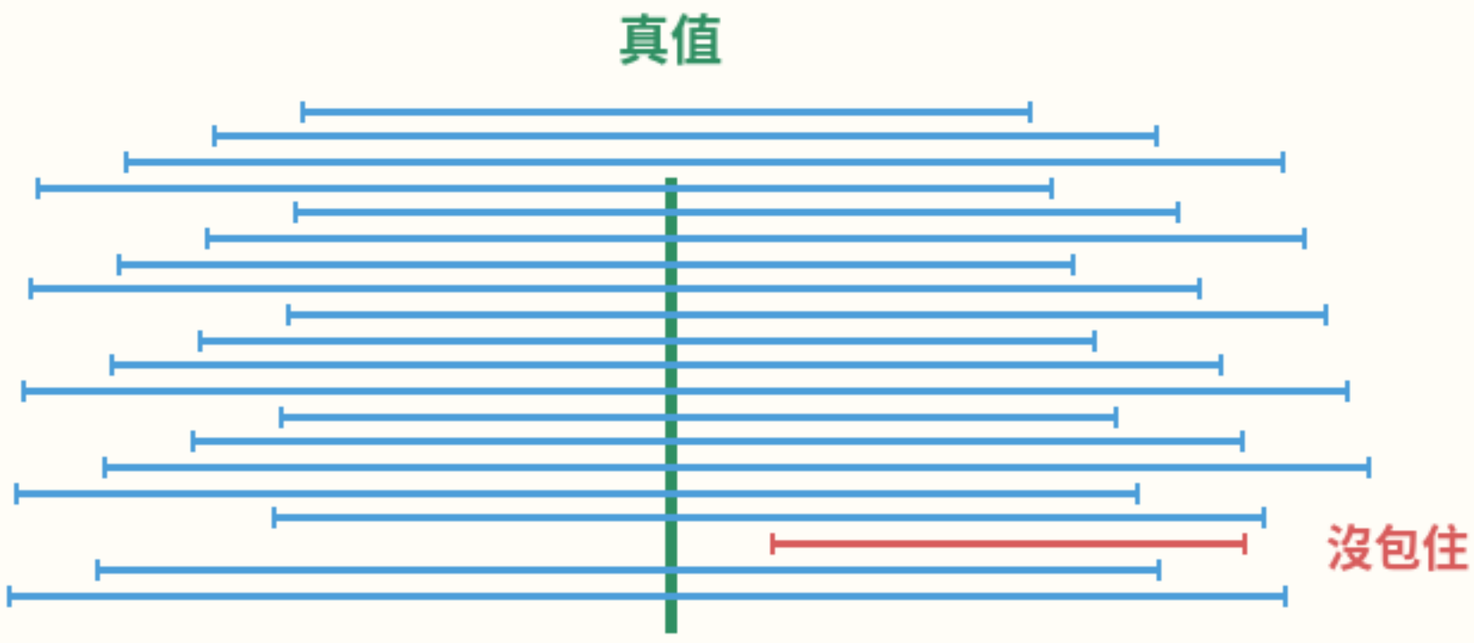
樣本越多，區間越窄



標準誤＝標準差 ÷ √樣本數

想更有把握，網要撒更寬

K3-6



20 條中約 95% 包住真值

信賴區間說的是方法，不是這一次

看圖默講觀念｜騎車時不看手機

‹ 回目錄

K3 假設檢定

視覺記憶卡｜第 3／3 張

K3-7

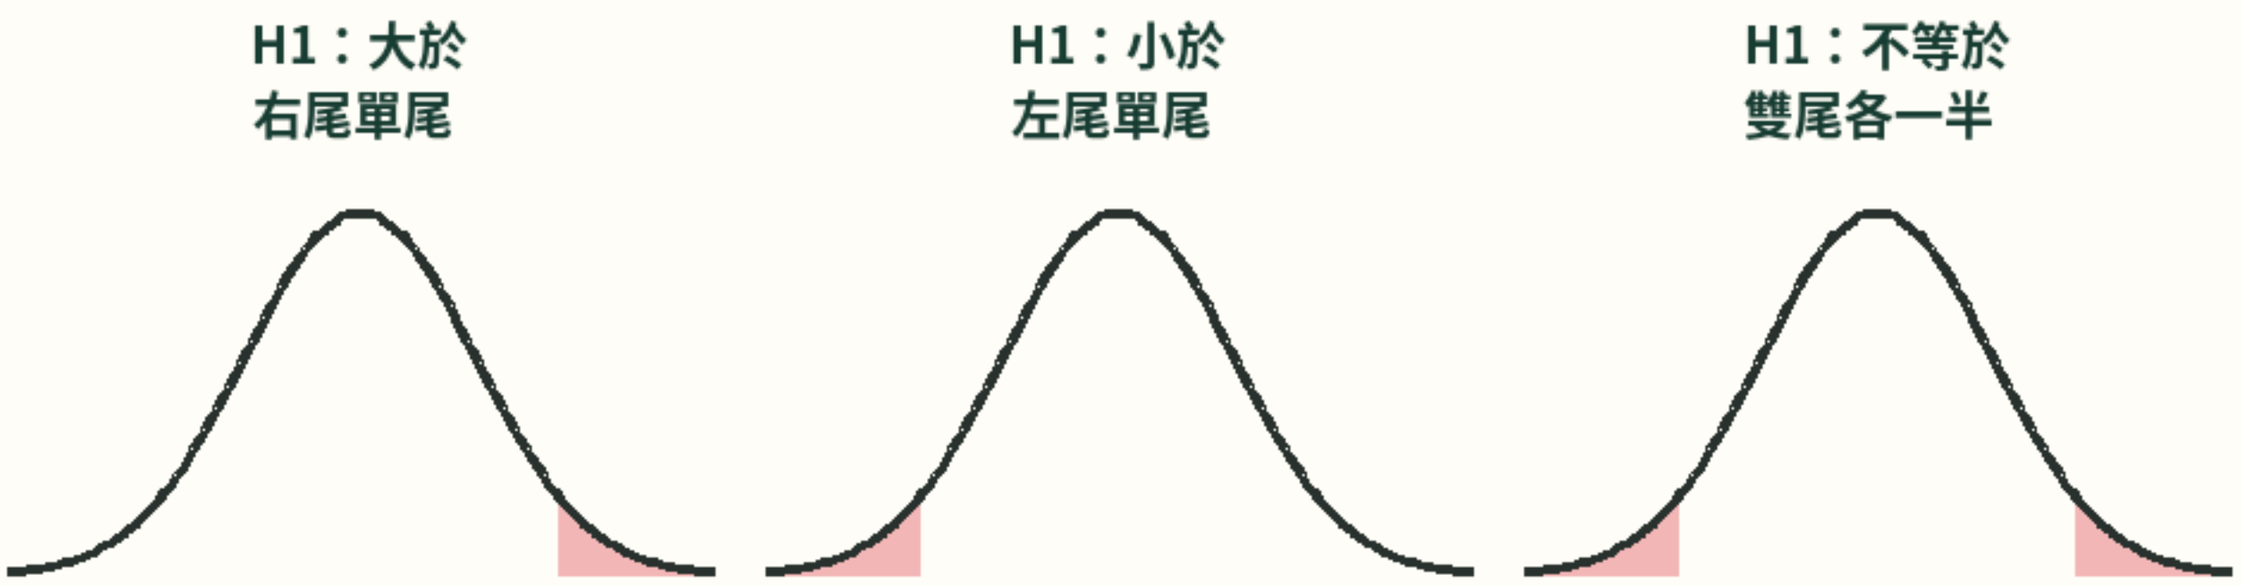


沒包住 → 拒絕 H0

包住 → 不拒絕

區間沒包住，就拒絕

K3-8



單尾有方向，雙尾只問不同

K3-9



20 次檢定｜每次 5% 誤報

至少一次誤報 ≈ 64.2%
1−0.95 的 20 次方＝0.642

邦弗朗尼
0.05 ÷ 20＝0.0025

檢定越多次，誤報越多

看圖默講觀念｜騎車時不看手機

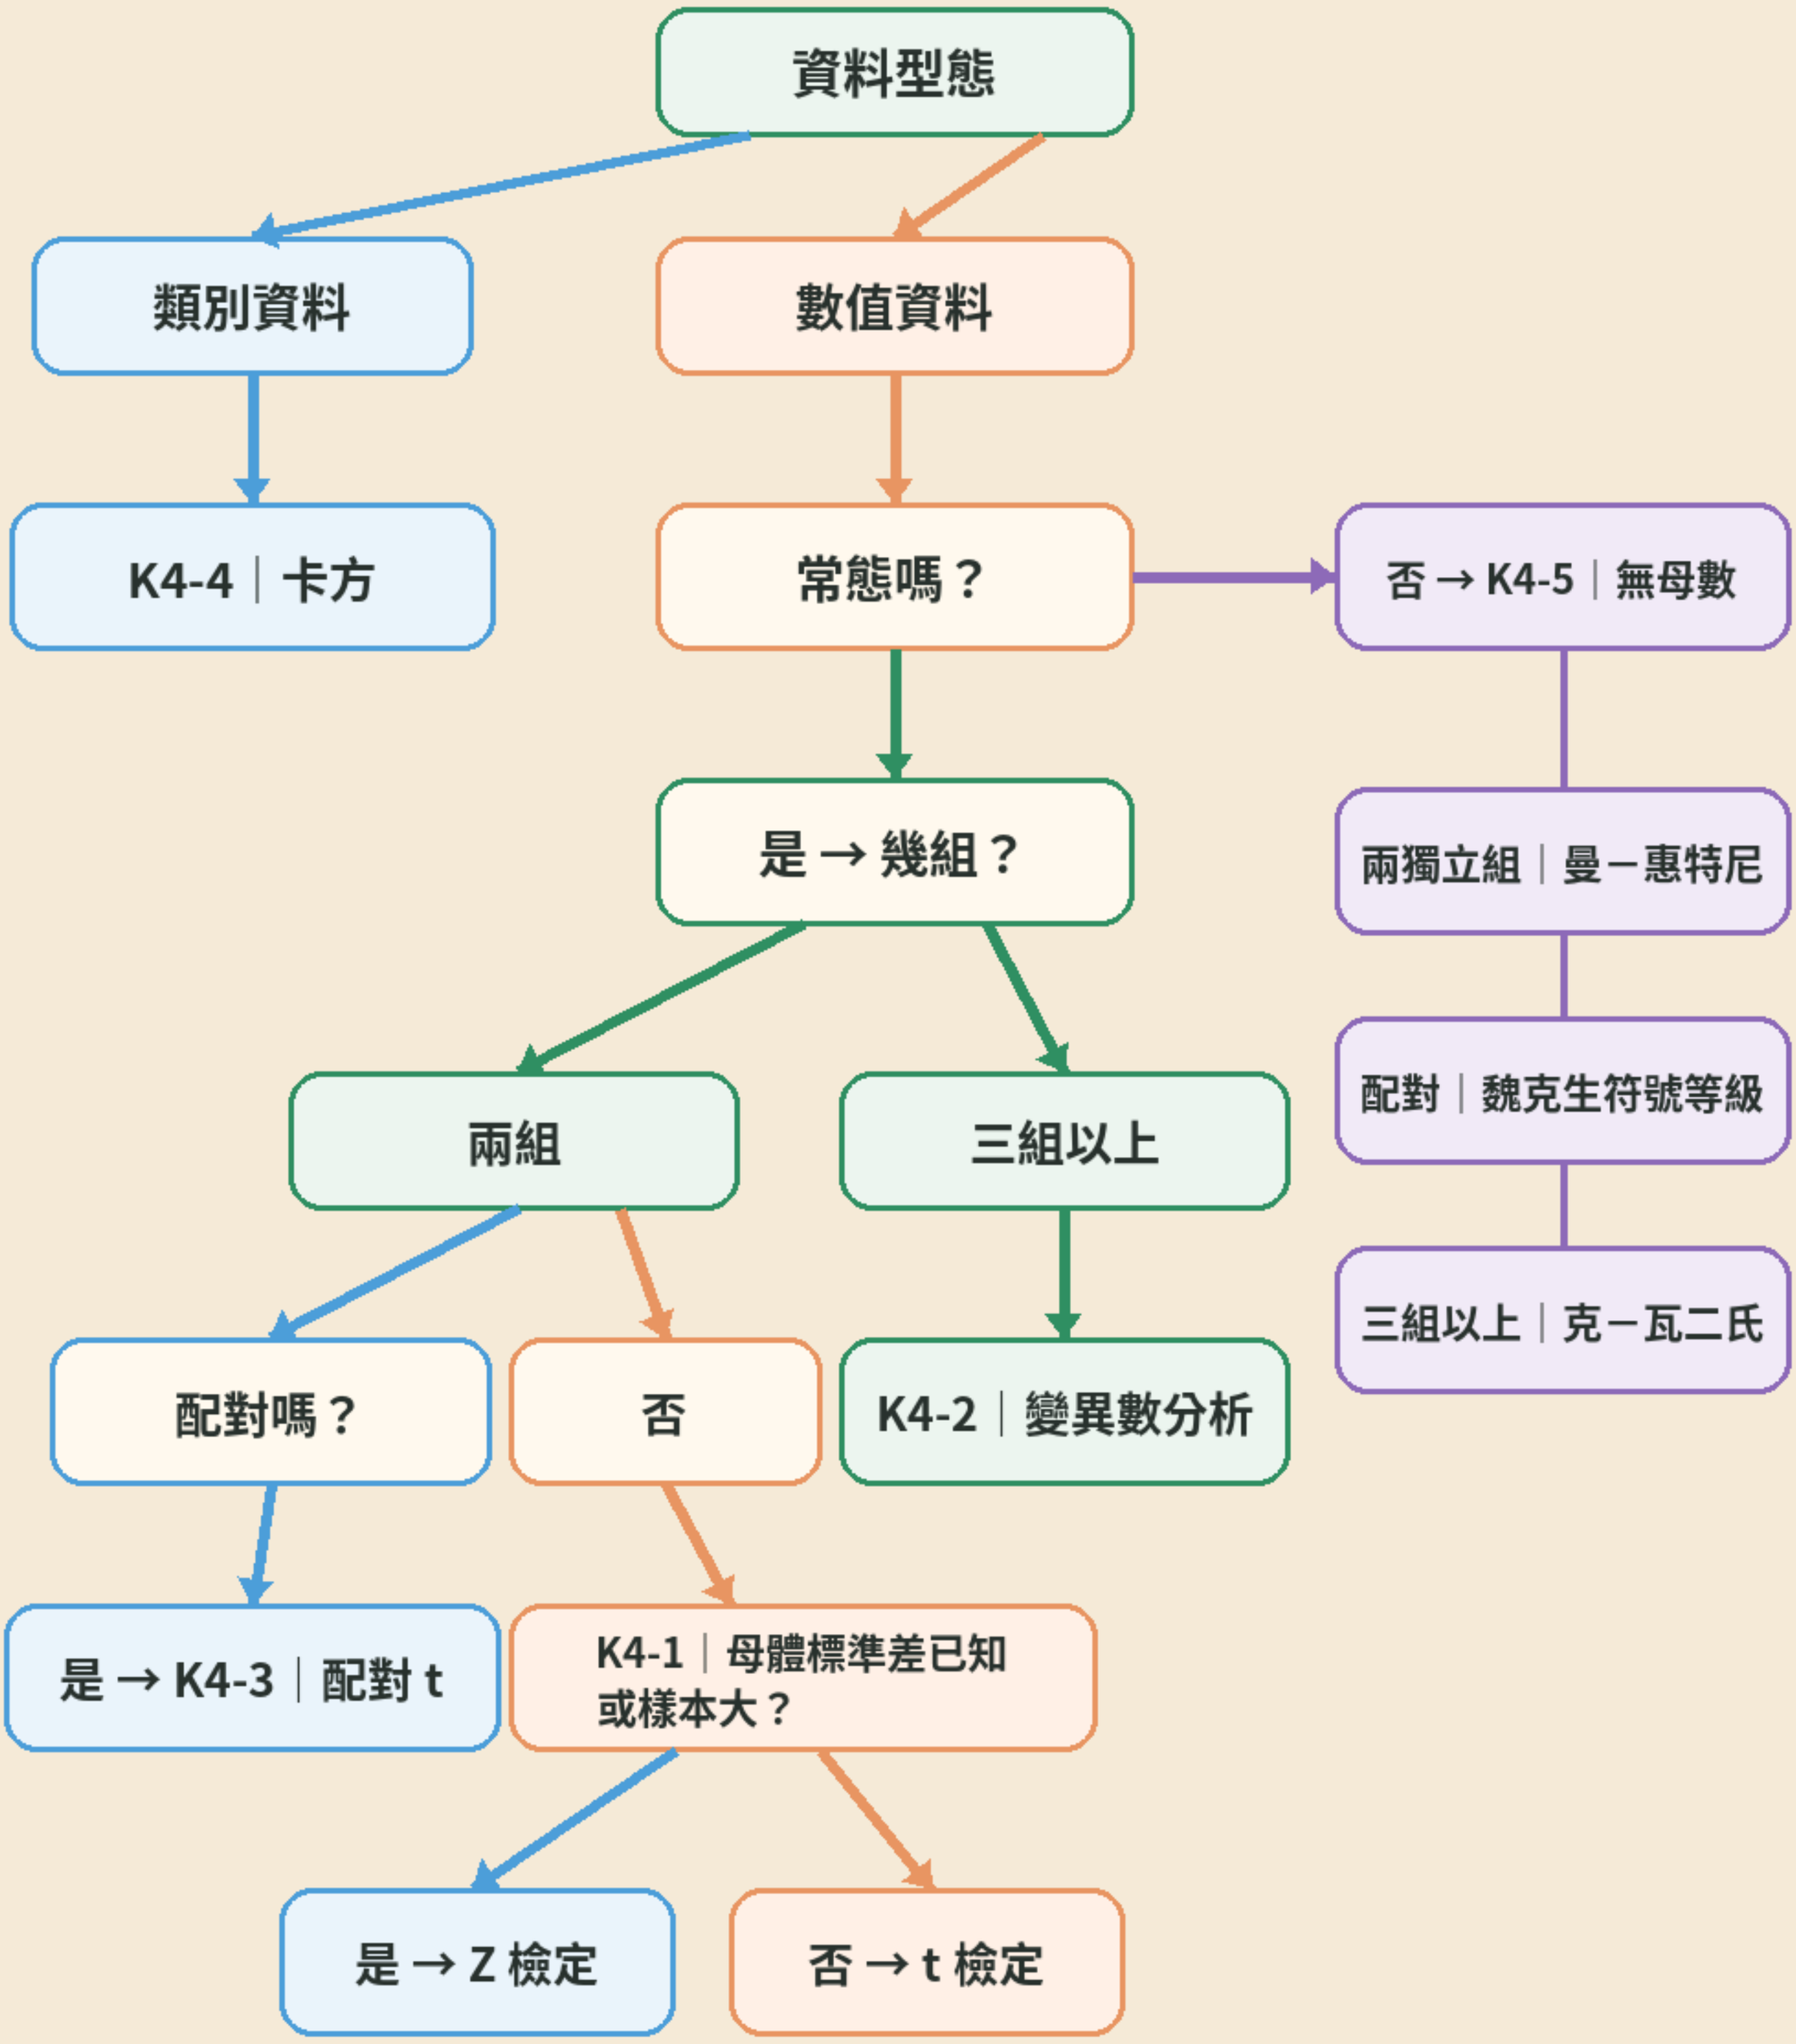
‹ 回目錄

K4

選哪一種檢定

視覺記憶卡｜第 1／1 張

資料是什麼型態？



節點口訣

K4-1｜知道母體標準差或樣本很大用 Z；否則用 t

K4-2｜兩組比平均用 t；三組以上用變異數分析

K4-3｜同一群人前後測，用配對 t

K4-4｜類別對類別，用卡方

K4-5｜不常態、樣本小、排名資料，用無母數

從資料型態一路往下走

‹ 回目錄

K5 分類指標

視覺記憶卡｜第 1／2 張

K5-1

	實際：是	實際：否
預測：是	真陽性	假陽性
預測：否	假陰性	真陰性

精確率框列

召回率框欄

精確率看「我說是的」，召回率看「真的是的」

K5-2

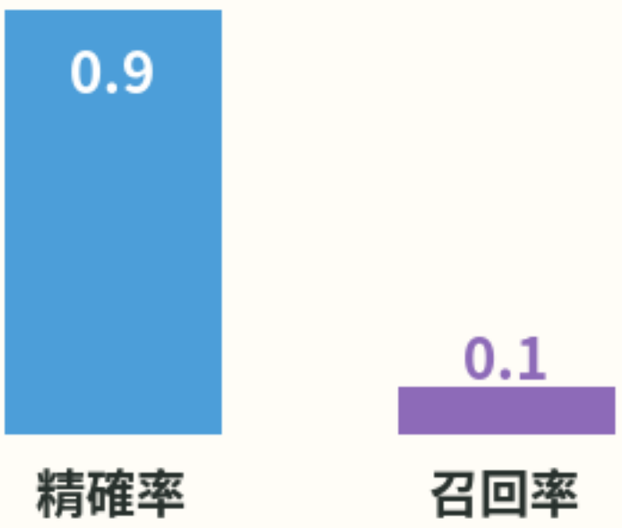


誤抓重要信 → 看精確率

漏抓病人 → 看召回率

怕誤抓看精確率，怕漏抓看召回率

K5-3



算術平均
0.5

F1＝0.18

一邊低，F1 就低

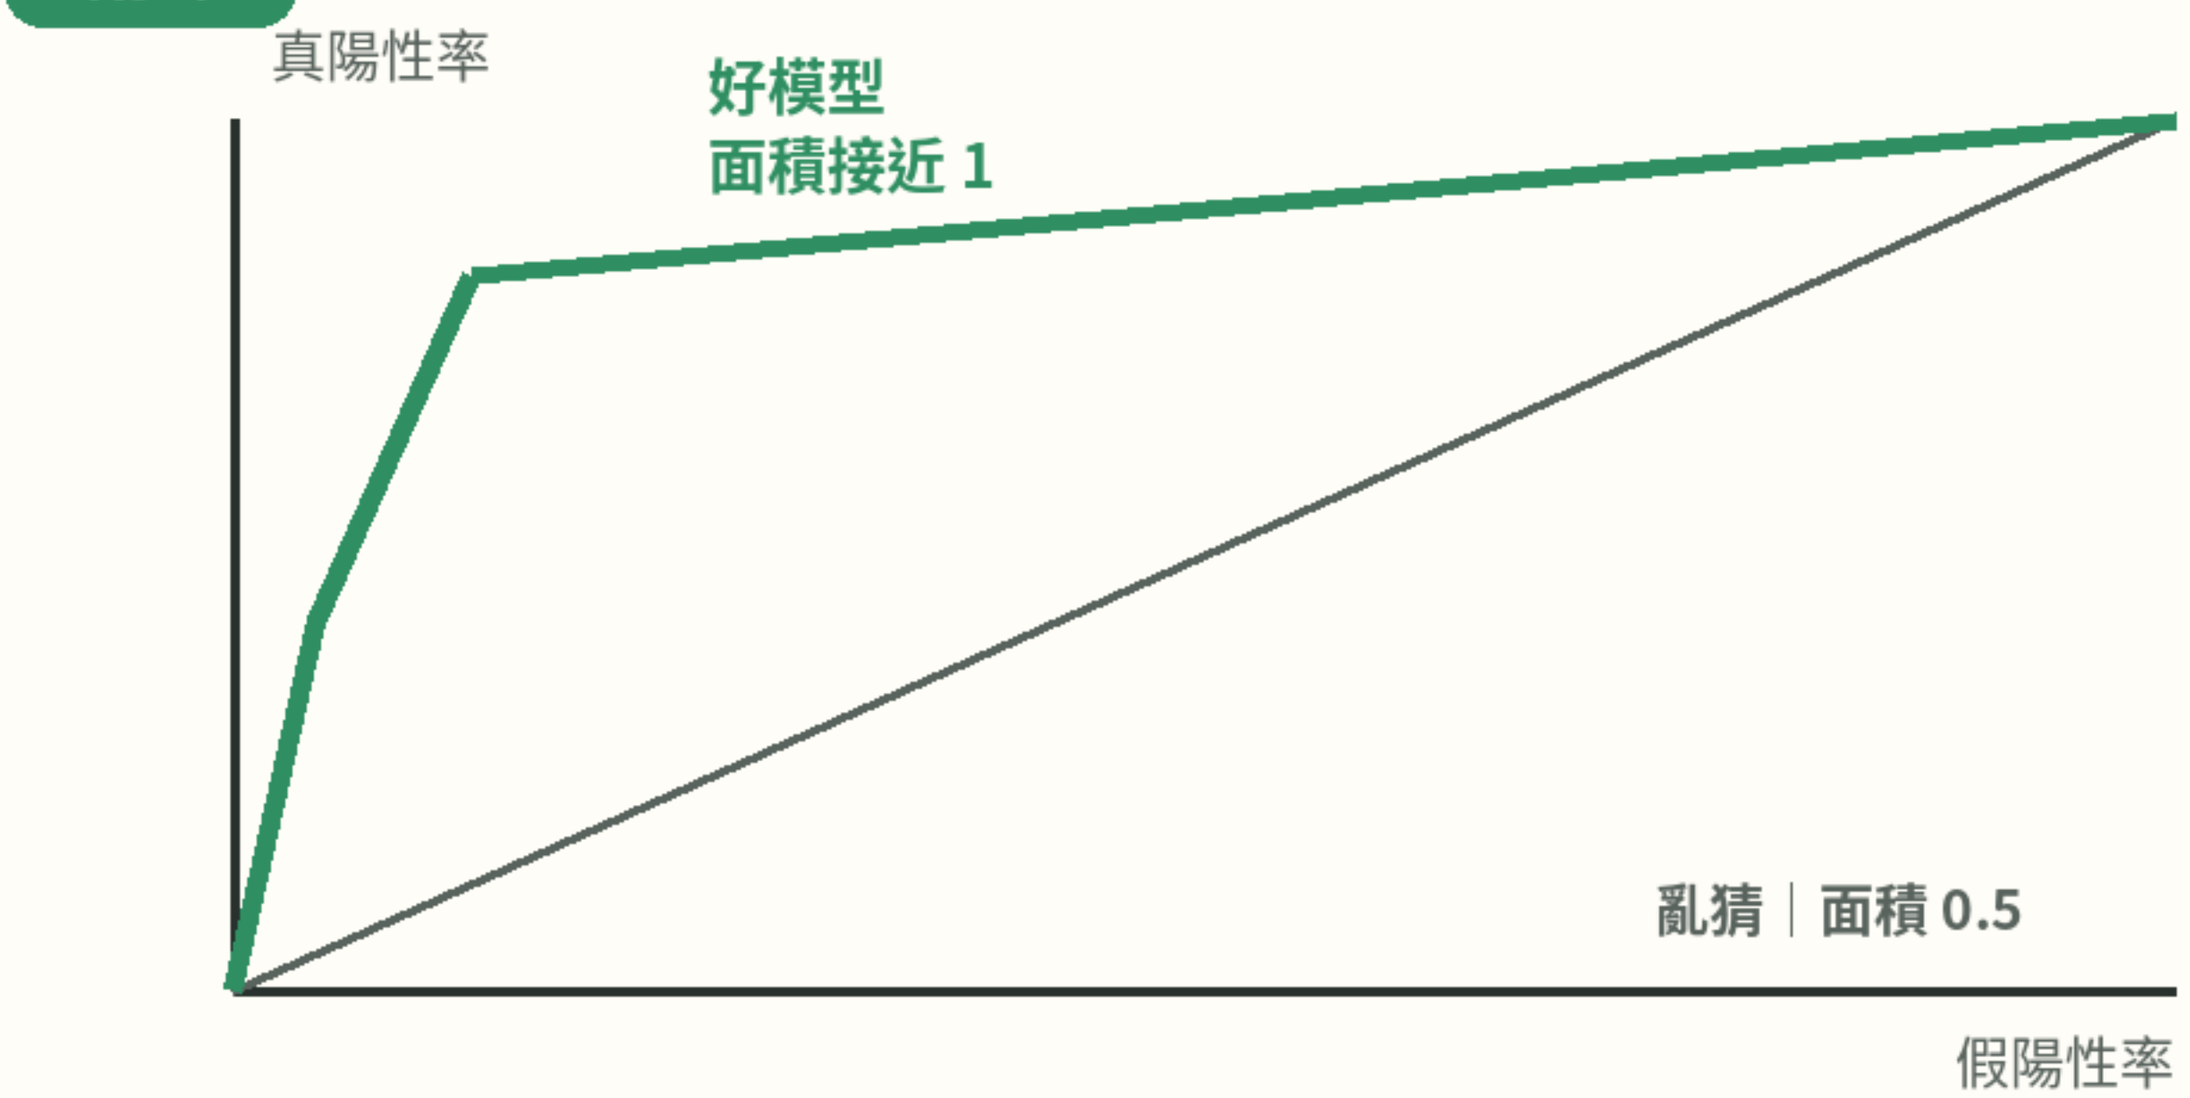
F1 是兩者的調和平均

K5

分類指標

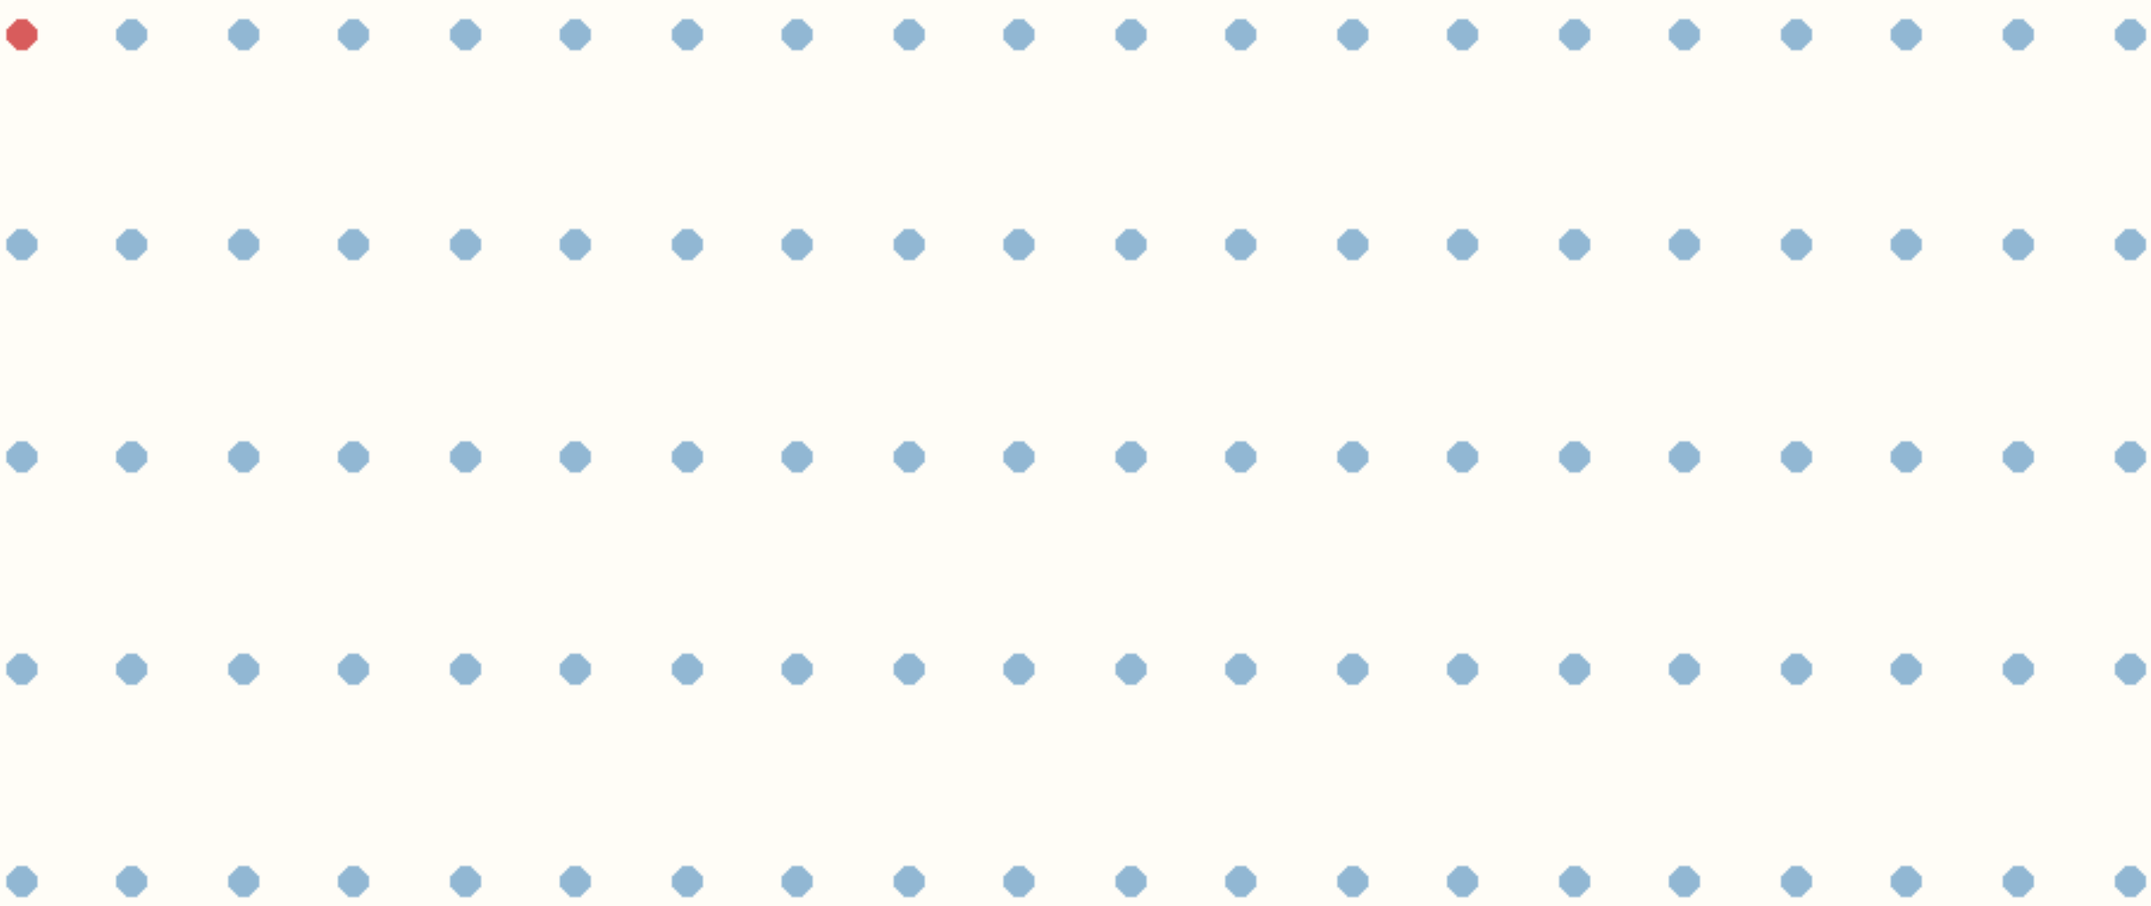
視覺記憶卡｜第 2／2 張

K5-4



ROC 往左上越好

K5-5



資料不平衡，別只看準確率

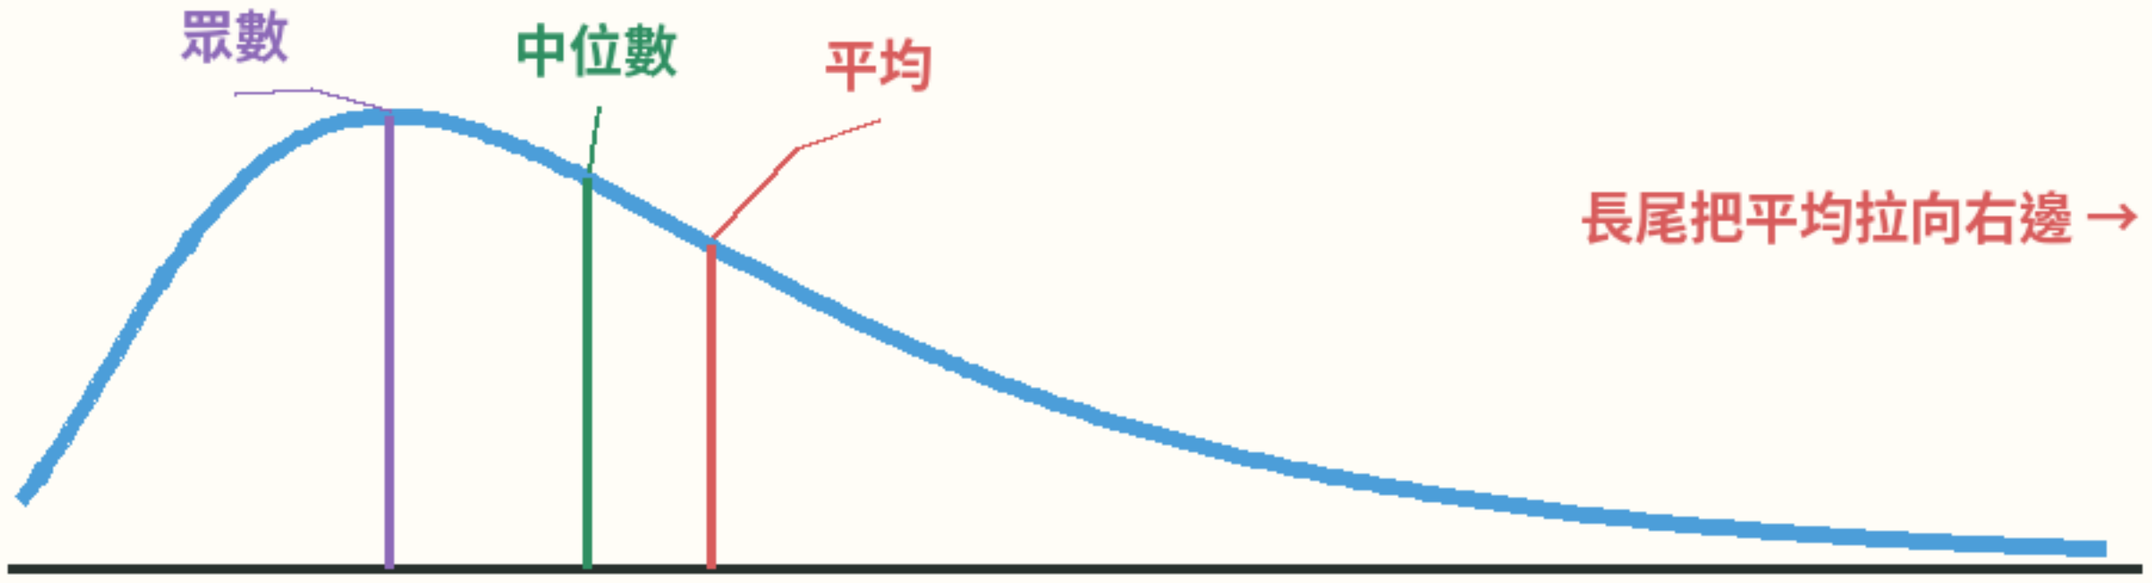
看圖默講觀念｜騎車時不看手機

‹ 回目錄

K1 敘述統計與相關

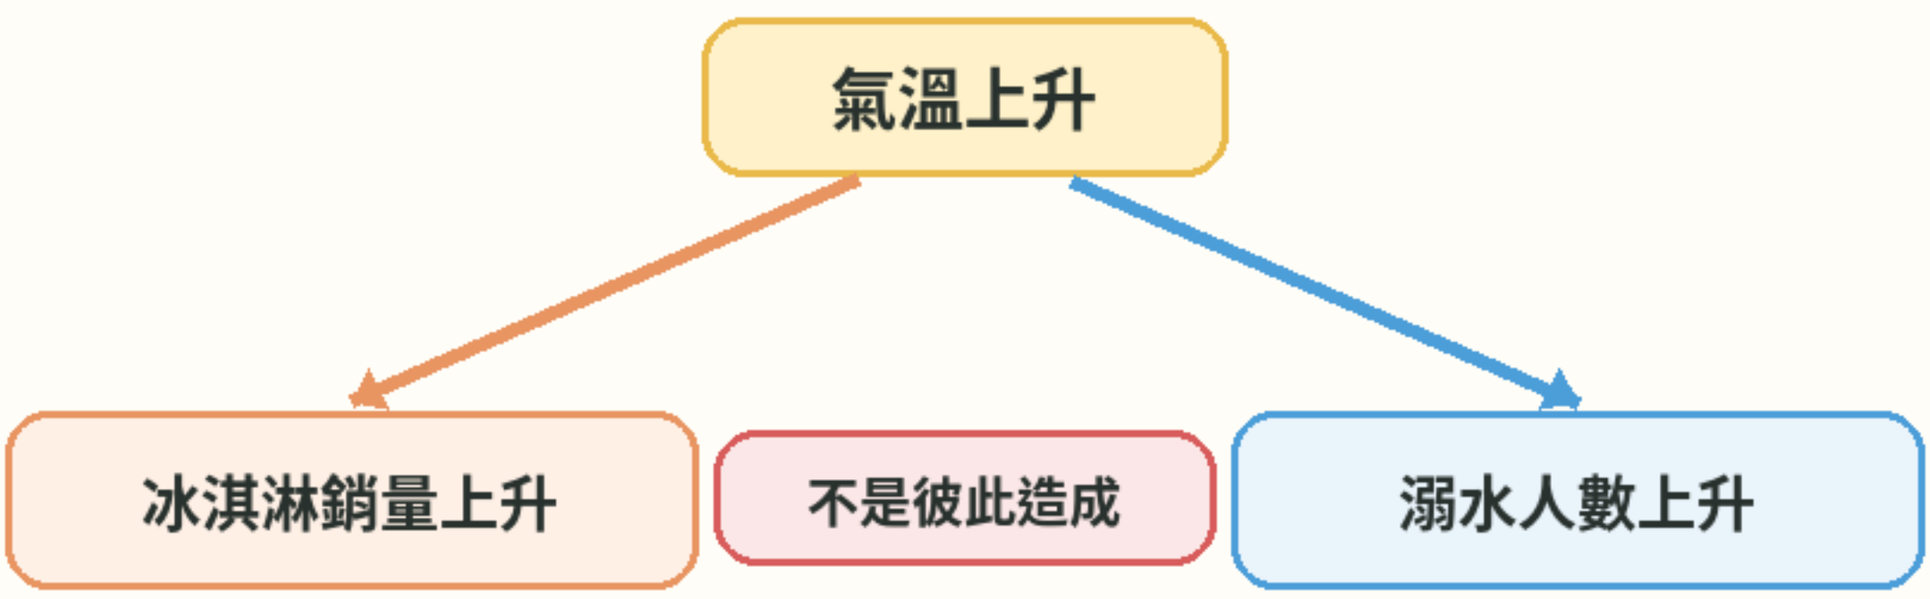
視覺記憶卡｜第 1／2 張

K1-1



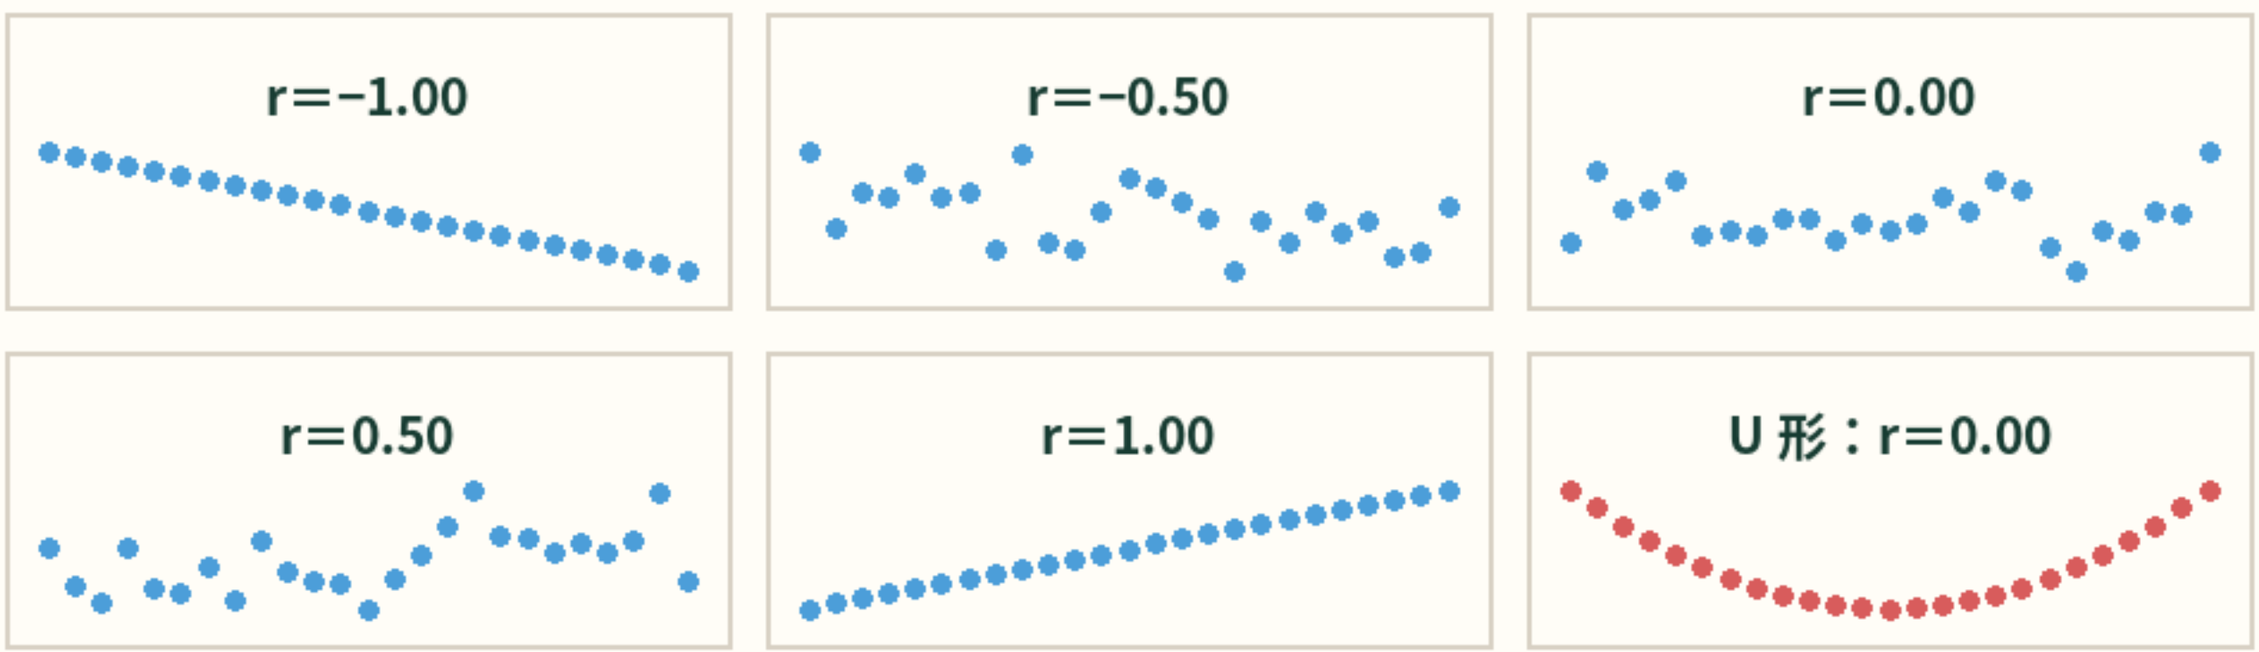
平均怕極端值，中位數不怕

K1-2



相關不等於因果。

K1-3



相關係數看方向和直線程度

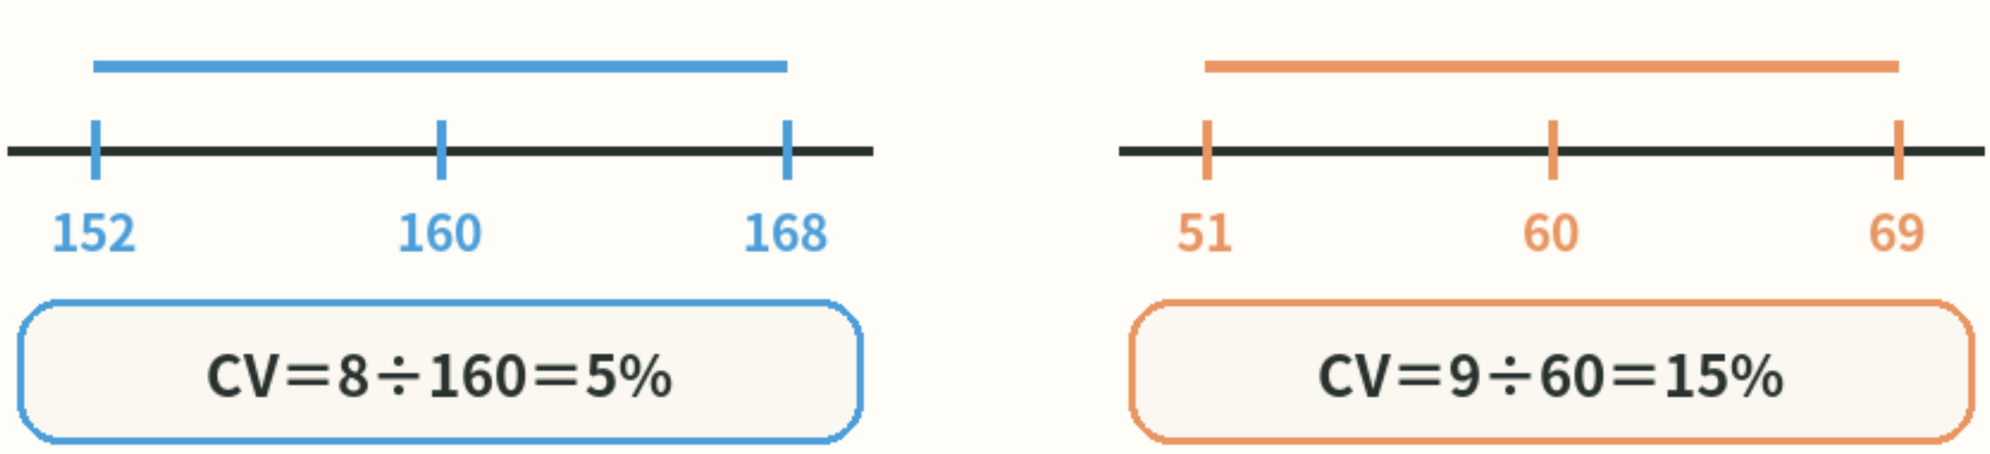
看圖默講觀念｜騎車時不看手機

‹ 回目錄

K1 敘述統計與相關

視覺記憶卡｜第 2／2 張

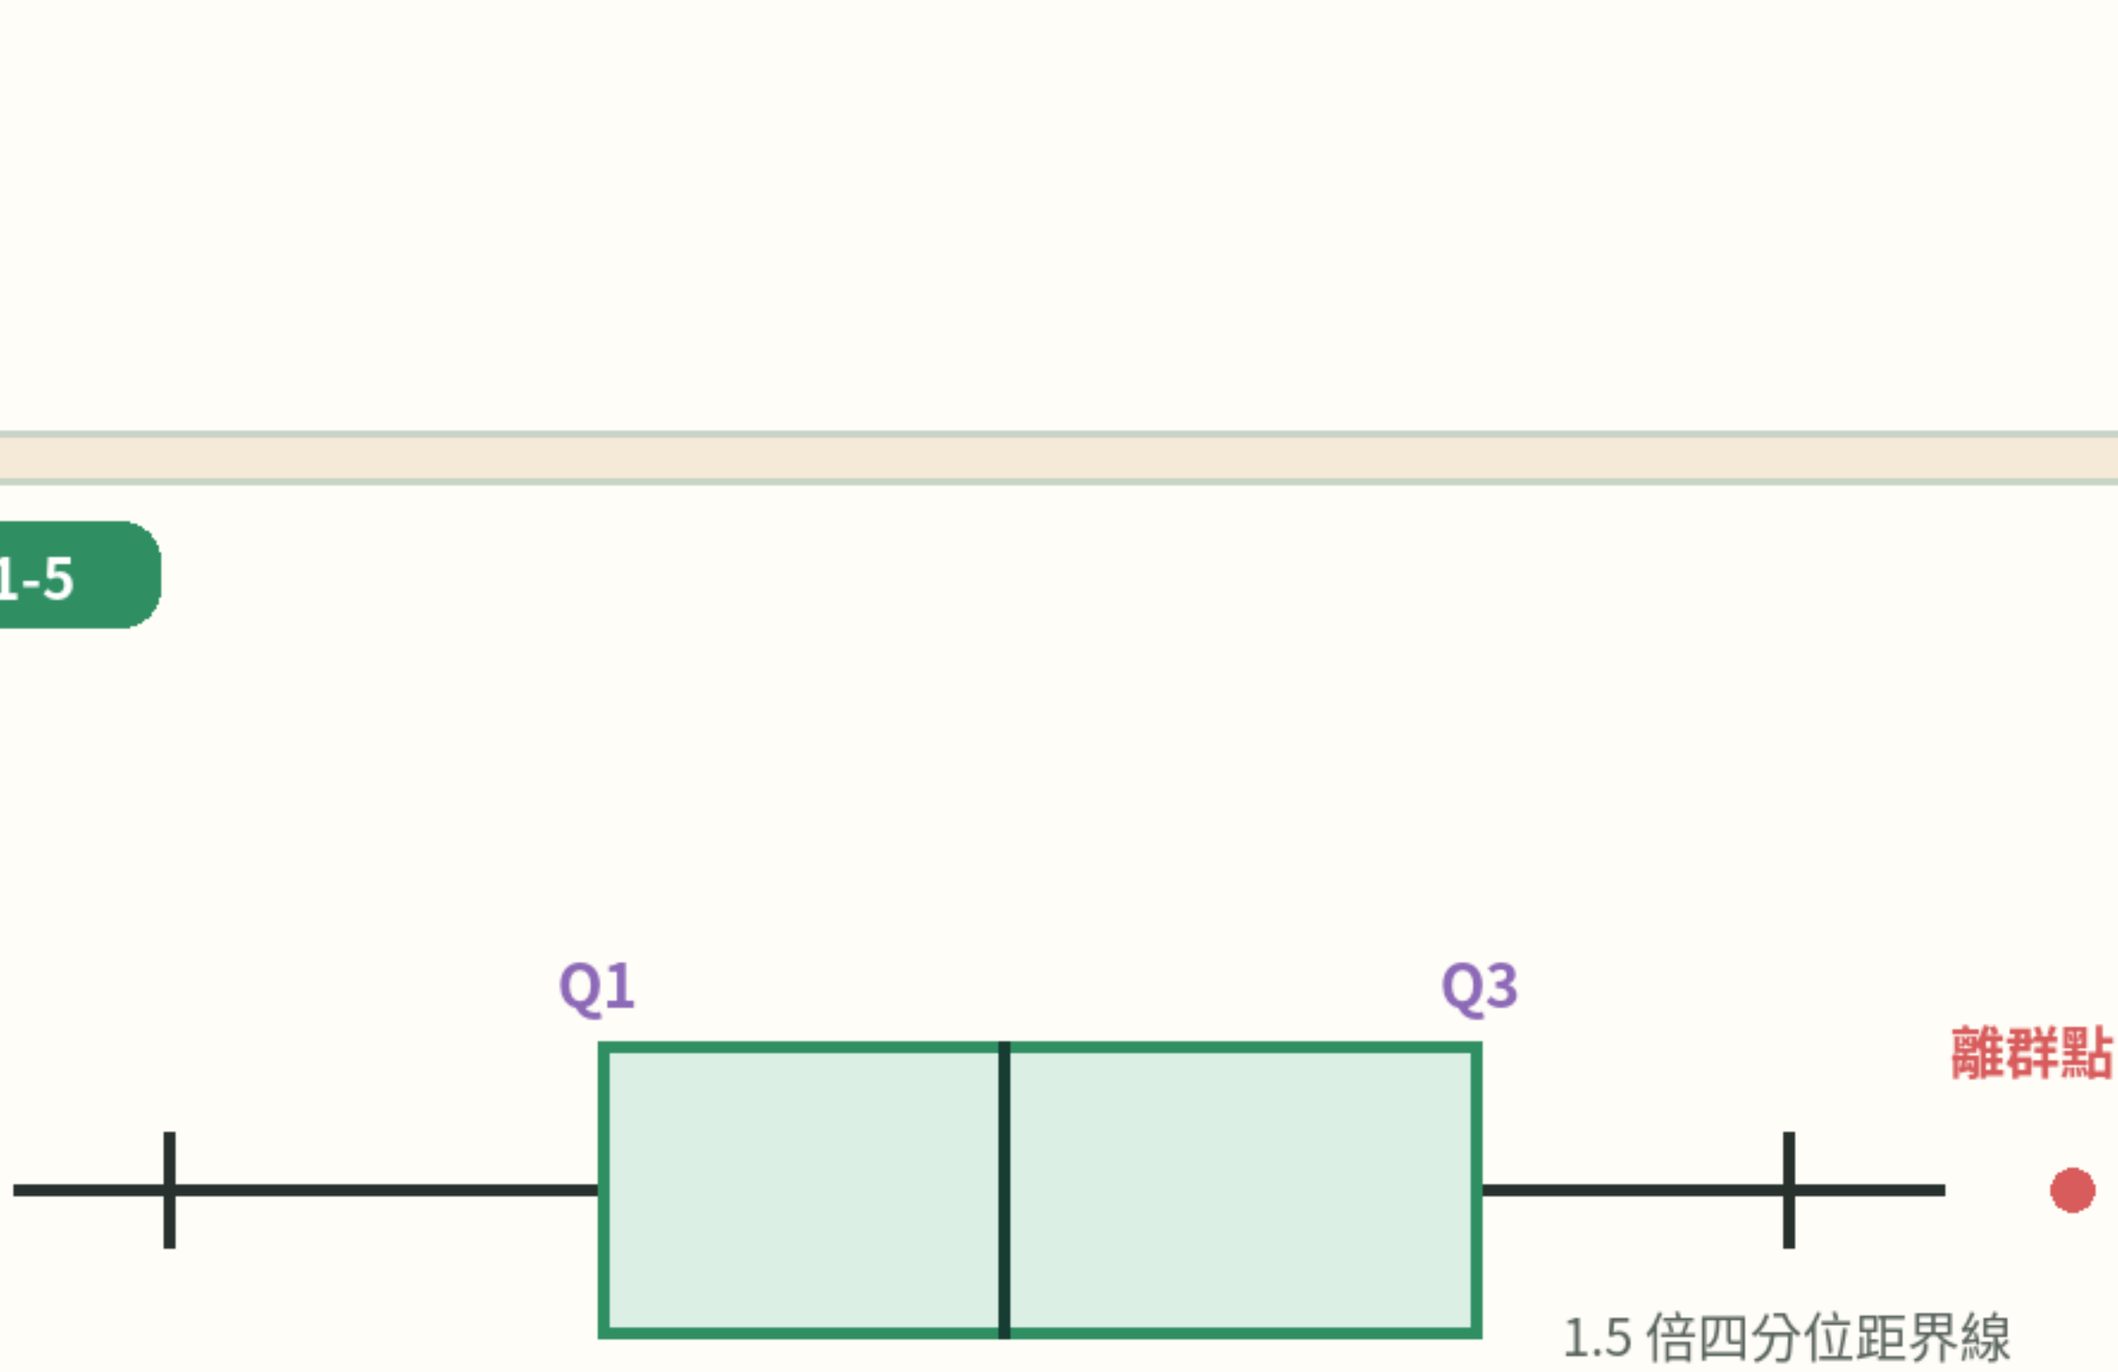
K1-4



體重相對分散較大（15% ＞ 5%）

標準差看分散，變異係數比不同單位

K1-5



四分位距看中間 50%

看圖默講觀念｜騎車時不看手機

‹ 回目錄

K2 機率分佈與定理

視覺記憶卡｜第 1／2 張

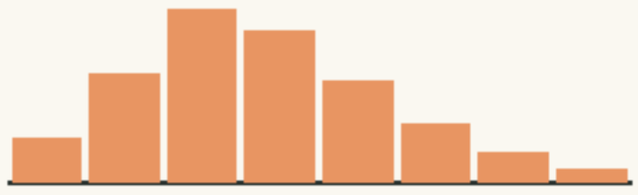
K2-1

投 10 次籃進幾次？



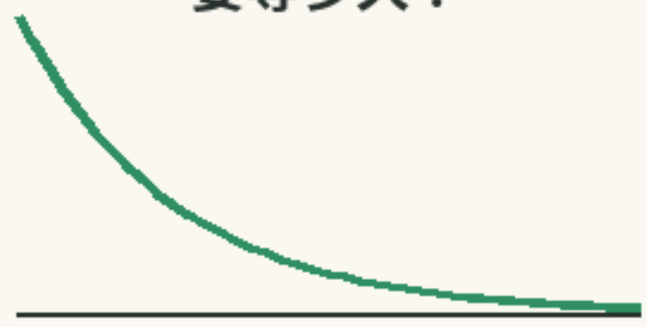
二項

一小時來幾位客人？



卜瓦松

下一位客人要等多久？

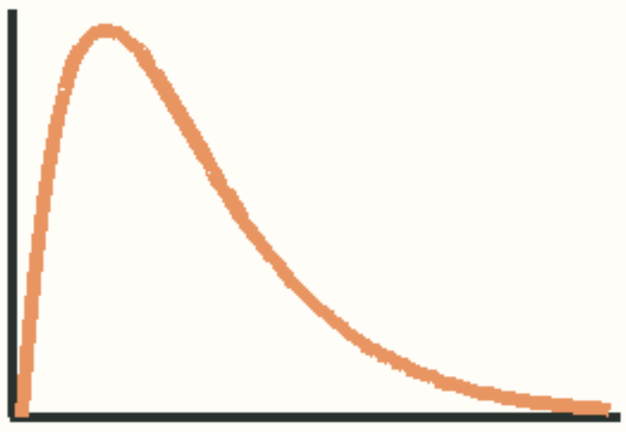


指數

成功幾次用二項，一段時間發生幾次用卜瓦松，要等多久用指數。

K2-2

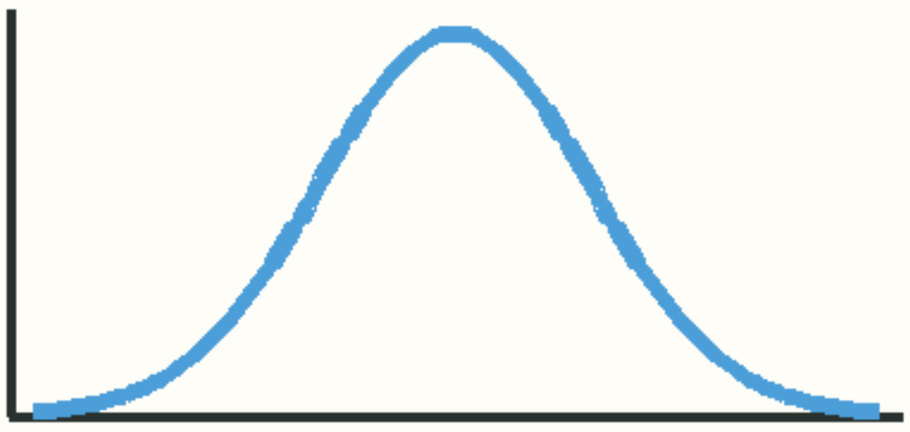
原本歪的分佈



反覆抽樣

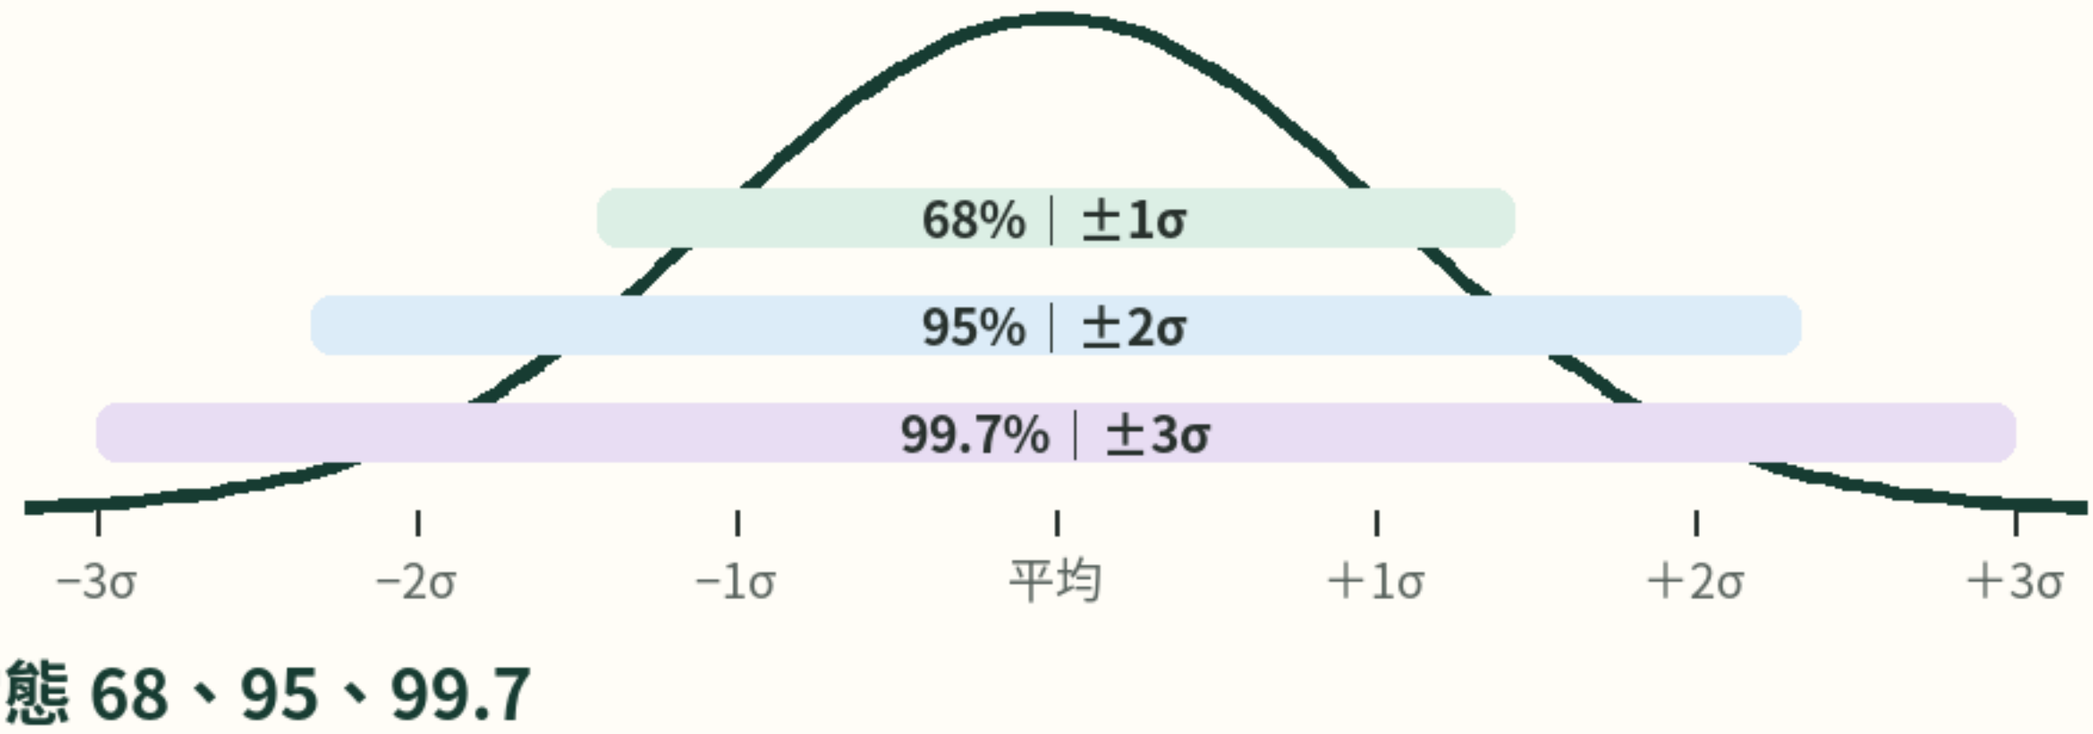
每次算平均

平均數近似常態



樣本夠大，平均數就近似常態

K2-3



常態 68、95、99.7

看圖默講觀念｜騎車時不看手機

‹ 回目錄

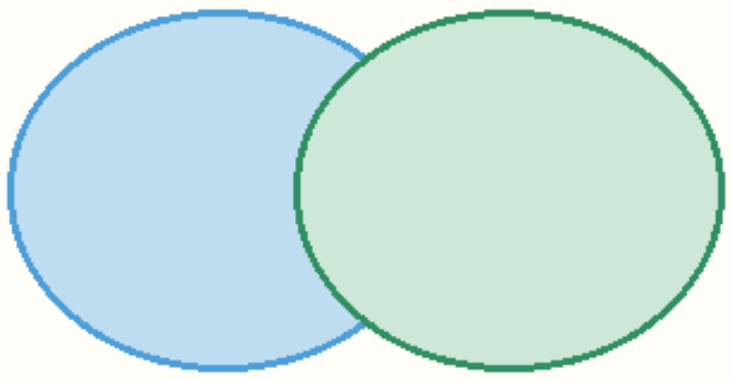
K2

機率分佈與定理

視覺記憶卡｜第 2／2 張

K2-4

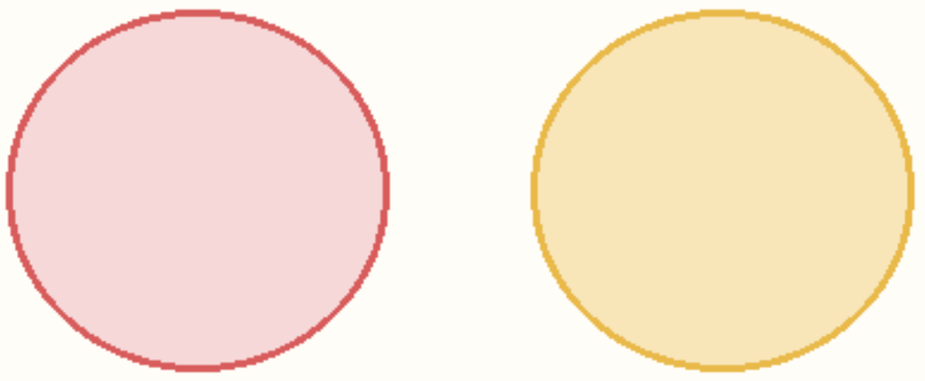
不互斥：可以同時發生



若 A、B 獨立：P(A且B)＝P(A)×P(B)

互斥：不能同時發生

互斥≠獨立



P(A或B)＝P(A)＋P(B)

獨立用相乘，互斥用相加

K2-5



事後＝事前 × 證據可能性 ÷ 證據機率

貝氏定理：看到證據後，更新原本的相信程度

K2-6



每面機率都是 1／6

期望值＝(1＋2＋3＋4＋5＋6) ÷ 6＝3.5

期望值是長期平均

看圖默講觀念｜騎車時不看手機

‹ 回目錄

K8 大數據元件

視覺記憶卡｜第 1／2 張

K8-1



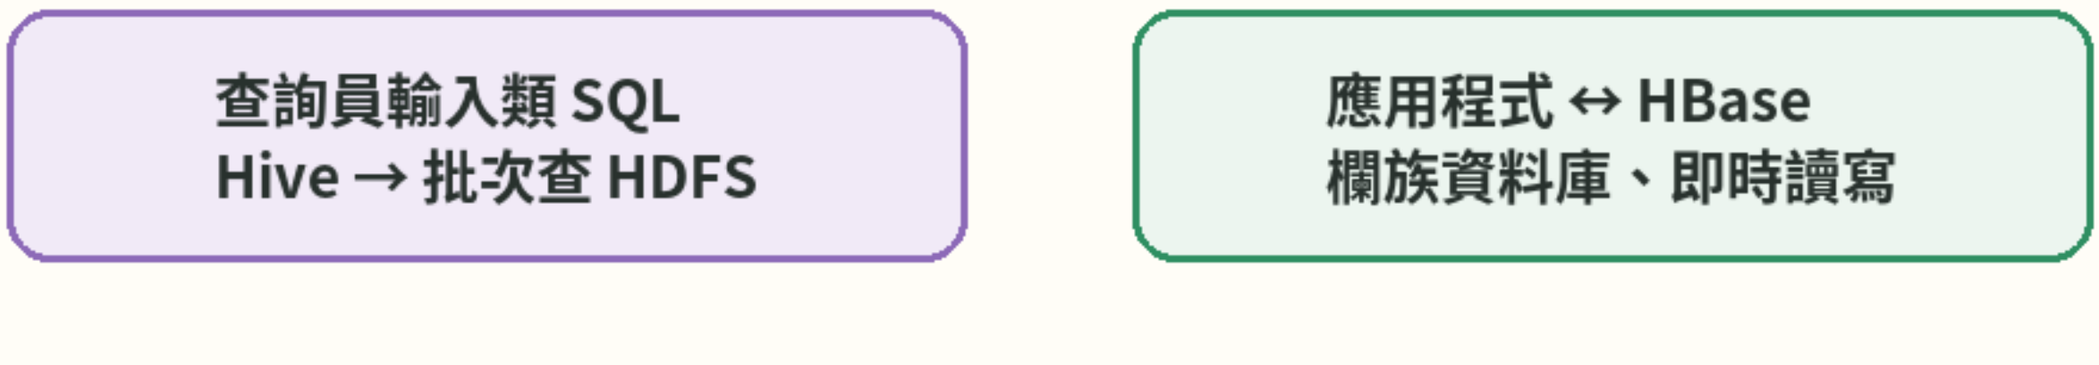
HDFS 負責存，MapReduce 負責算，YARN 負責分配資源。

K8-2



Spark 在記憶體裡算，所以比 MapReduce 快。

K8-3



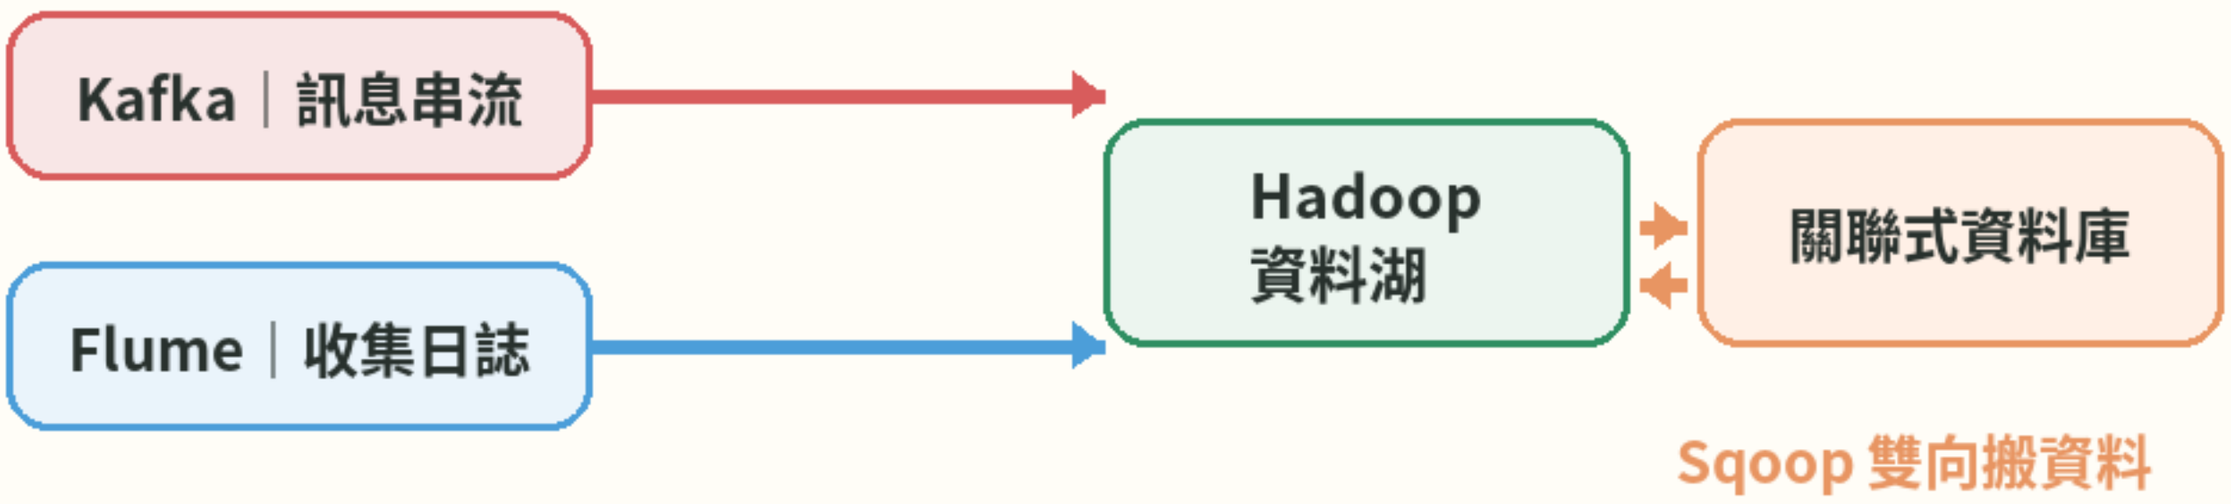
Hive 用類似 SQL 的語法查資料，HBase 是可以即時讀寫的欄族資料庫。

K8

大數據元件

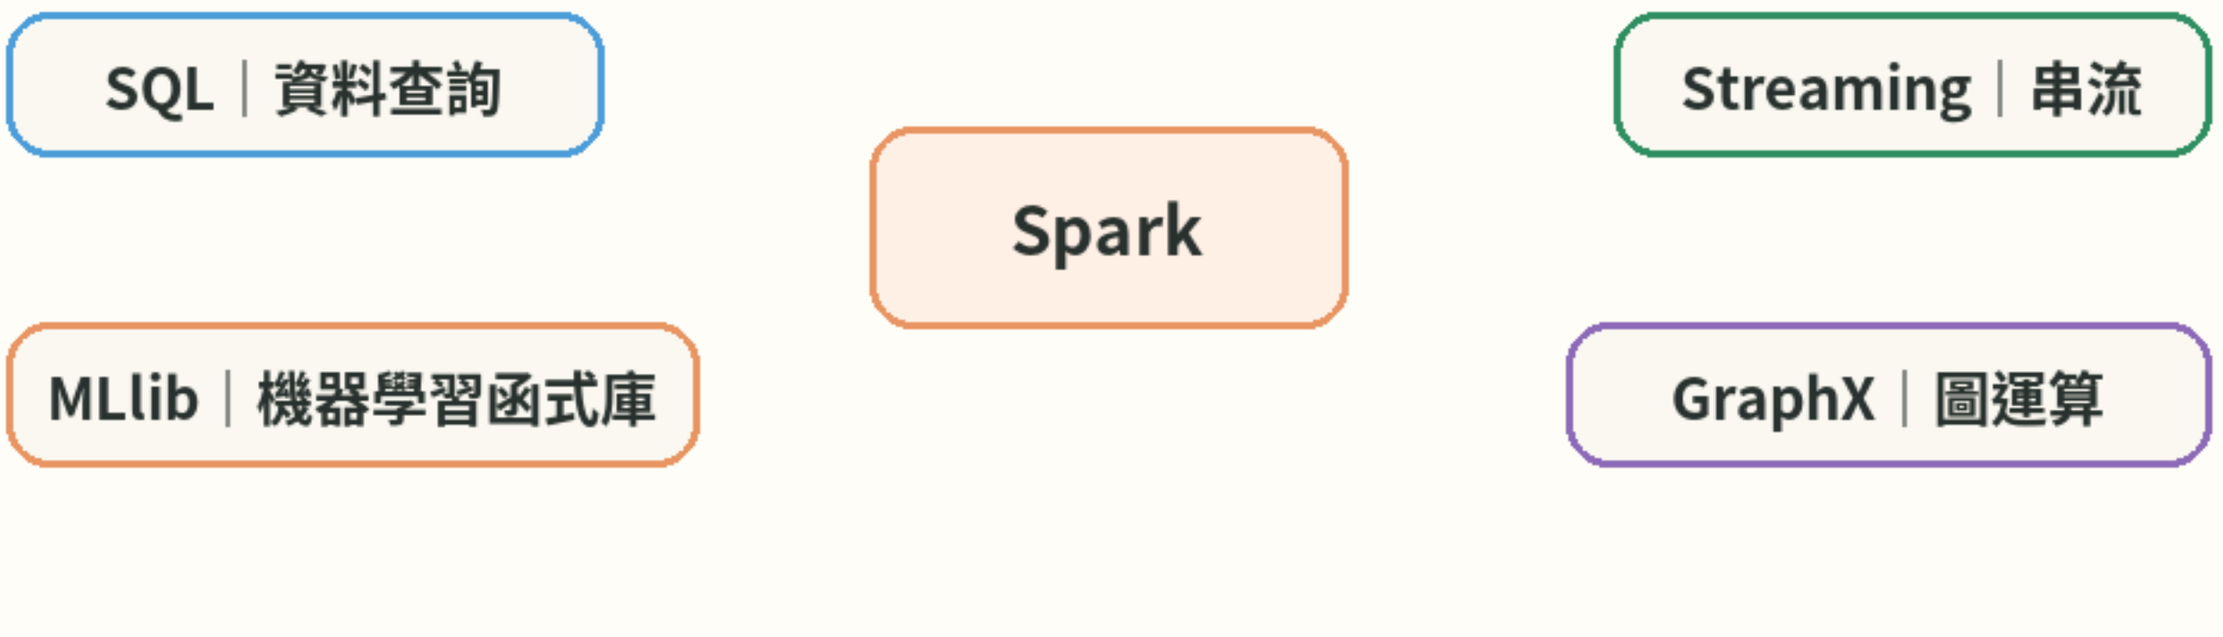
視覺記憶卡｜第 2／2 張

K8-4



Kafka 傳訊息串流，Flume 收集日誌，Sqoop 在關聯式資料庫和 Hadoop 之間搬資料。

K8-5



Spark 一家四口：SQL、串流、機器學習、圖運算。

K9 資料儲存與 NoSQL

視覺記憶卡｜第 1／2 張

K9-1

鑰 鍵值 Redis

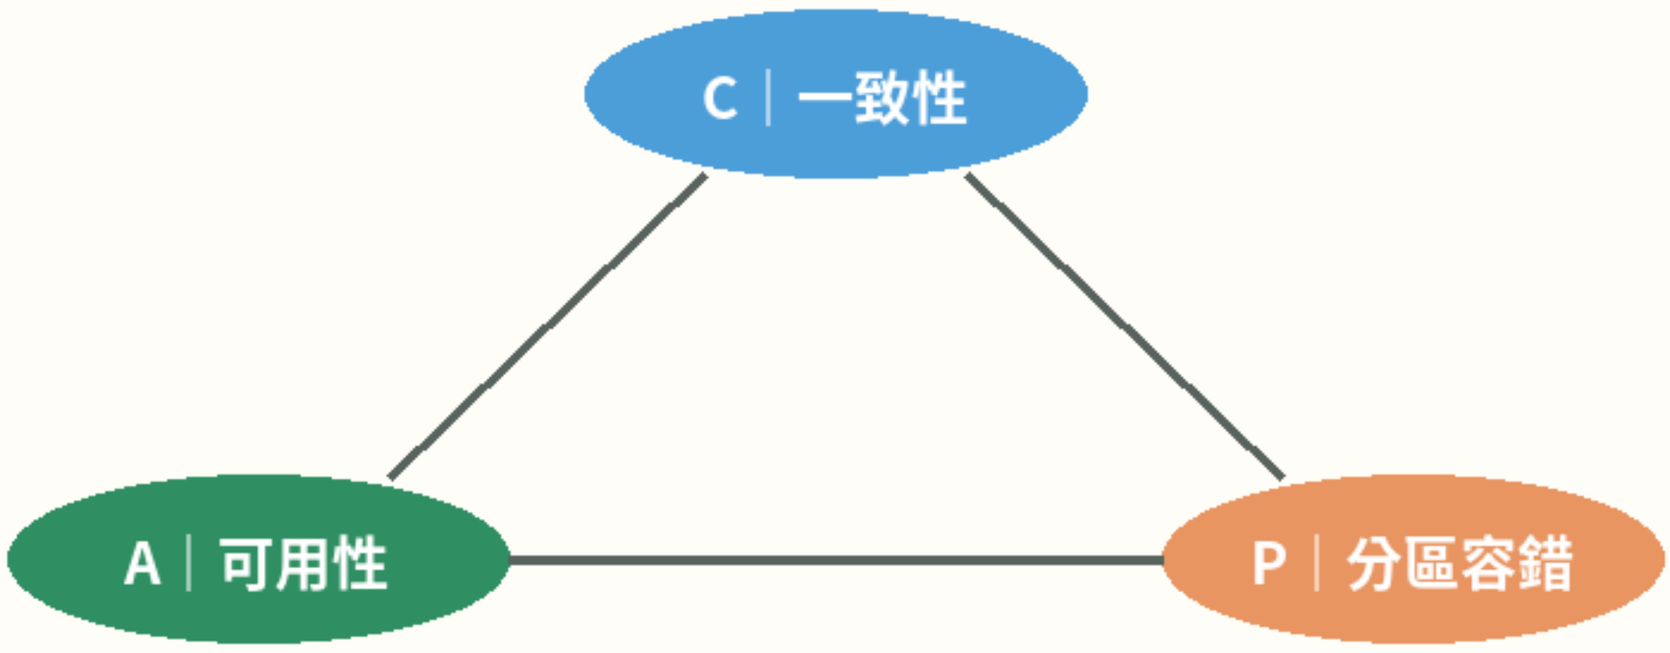
頁 文件 MongoDB

欄 欄族 Cassandra、HBase

網 圖資料庫 Neo4j

NoSQL 四兄弟

K9-2



斷線時：在 C 與 A 之間取捨

CAP 三選二

K9-3

照片 .jpg　影片 .mp4　備份 .zip → 物件儲存 用網址存取

物件儲存放大檔案

看圖默講觀念｜騎車時不看手機

‹ 回目錄

K9

資料儲存與 NoSQL

視覺記憶卡｜第 2／2 張

K9-4

分析快
同類資料壓縮好

只讀需要的綠色欄

欄式儲存適合分析

K9-5

類型 1｜覆蓋

台北 → 高雄

類型 2｜加一列

舊：台北

新：高雄

類型 3｜加一欄

現址：高雄

前址：台北

緩慢變更維度

看圖默講觀念｜騎車時不看手機

‹ 回目錄

K10

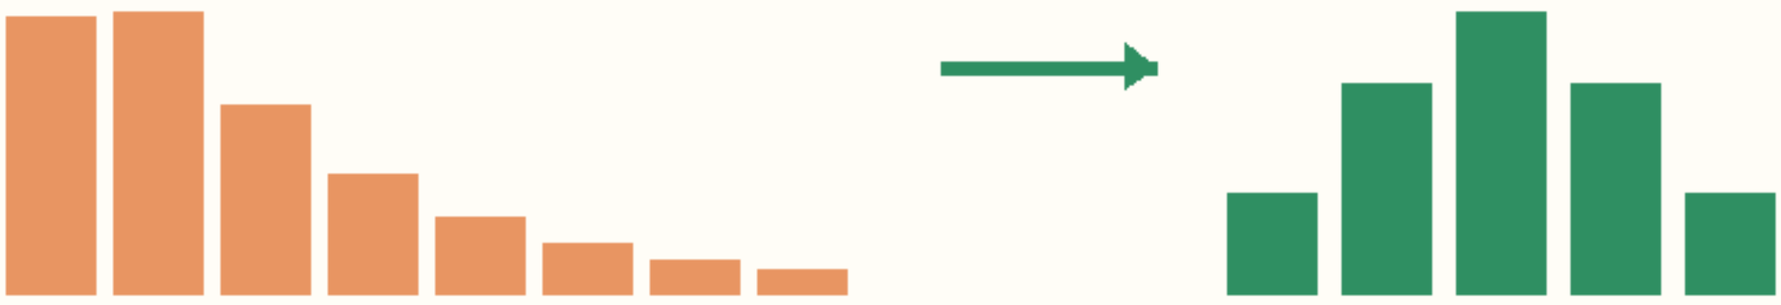
資料處理與特徵轉換

視覺記憶卡｜第 1／2 張

K10-1

右偏：左高、右長尾

取 log 後較對稱



原值 1、10、100、1000 → log10：0、1、2、3

右偏資料取對數，把長尾拉回來。

K10-2

原始值：40、50、60｜平均 50｜標準差 10

標準化 z 分數
-1、0、1

正規化到 0～1
0.0、0.5、1.0

標準化是減平均再除標準差，正規化是縮到 0 到 1 之間。

K10-3

18～34
青年

35～64
中年

65 以上
老年



離散化是把連續數字切成區間

看圖默講觀念｜騎車時不看手機

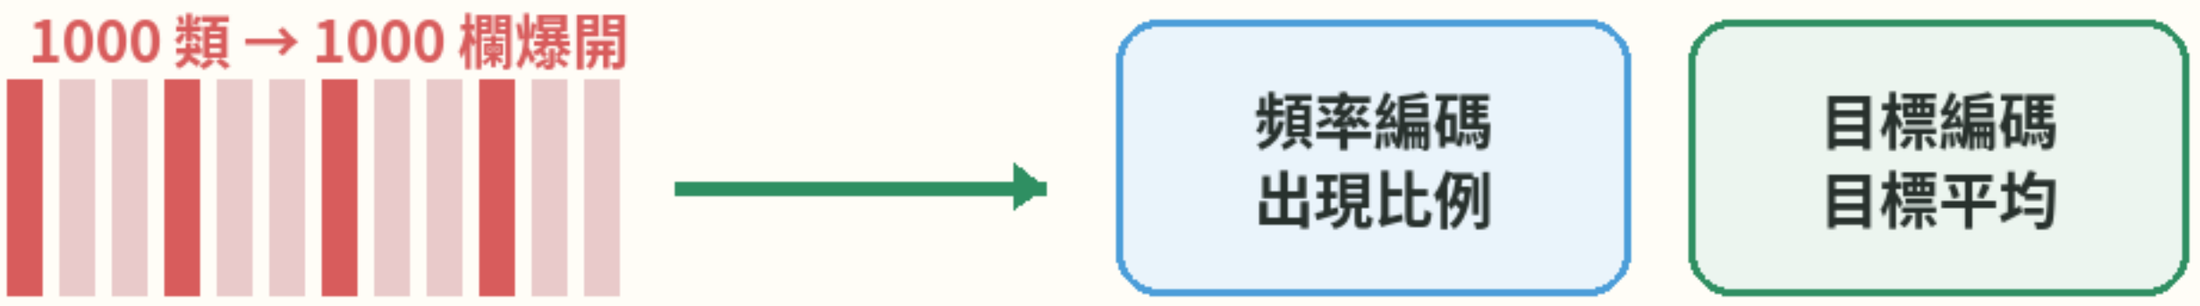
‹ 回目錄

K10

資料處理與特徵轉換

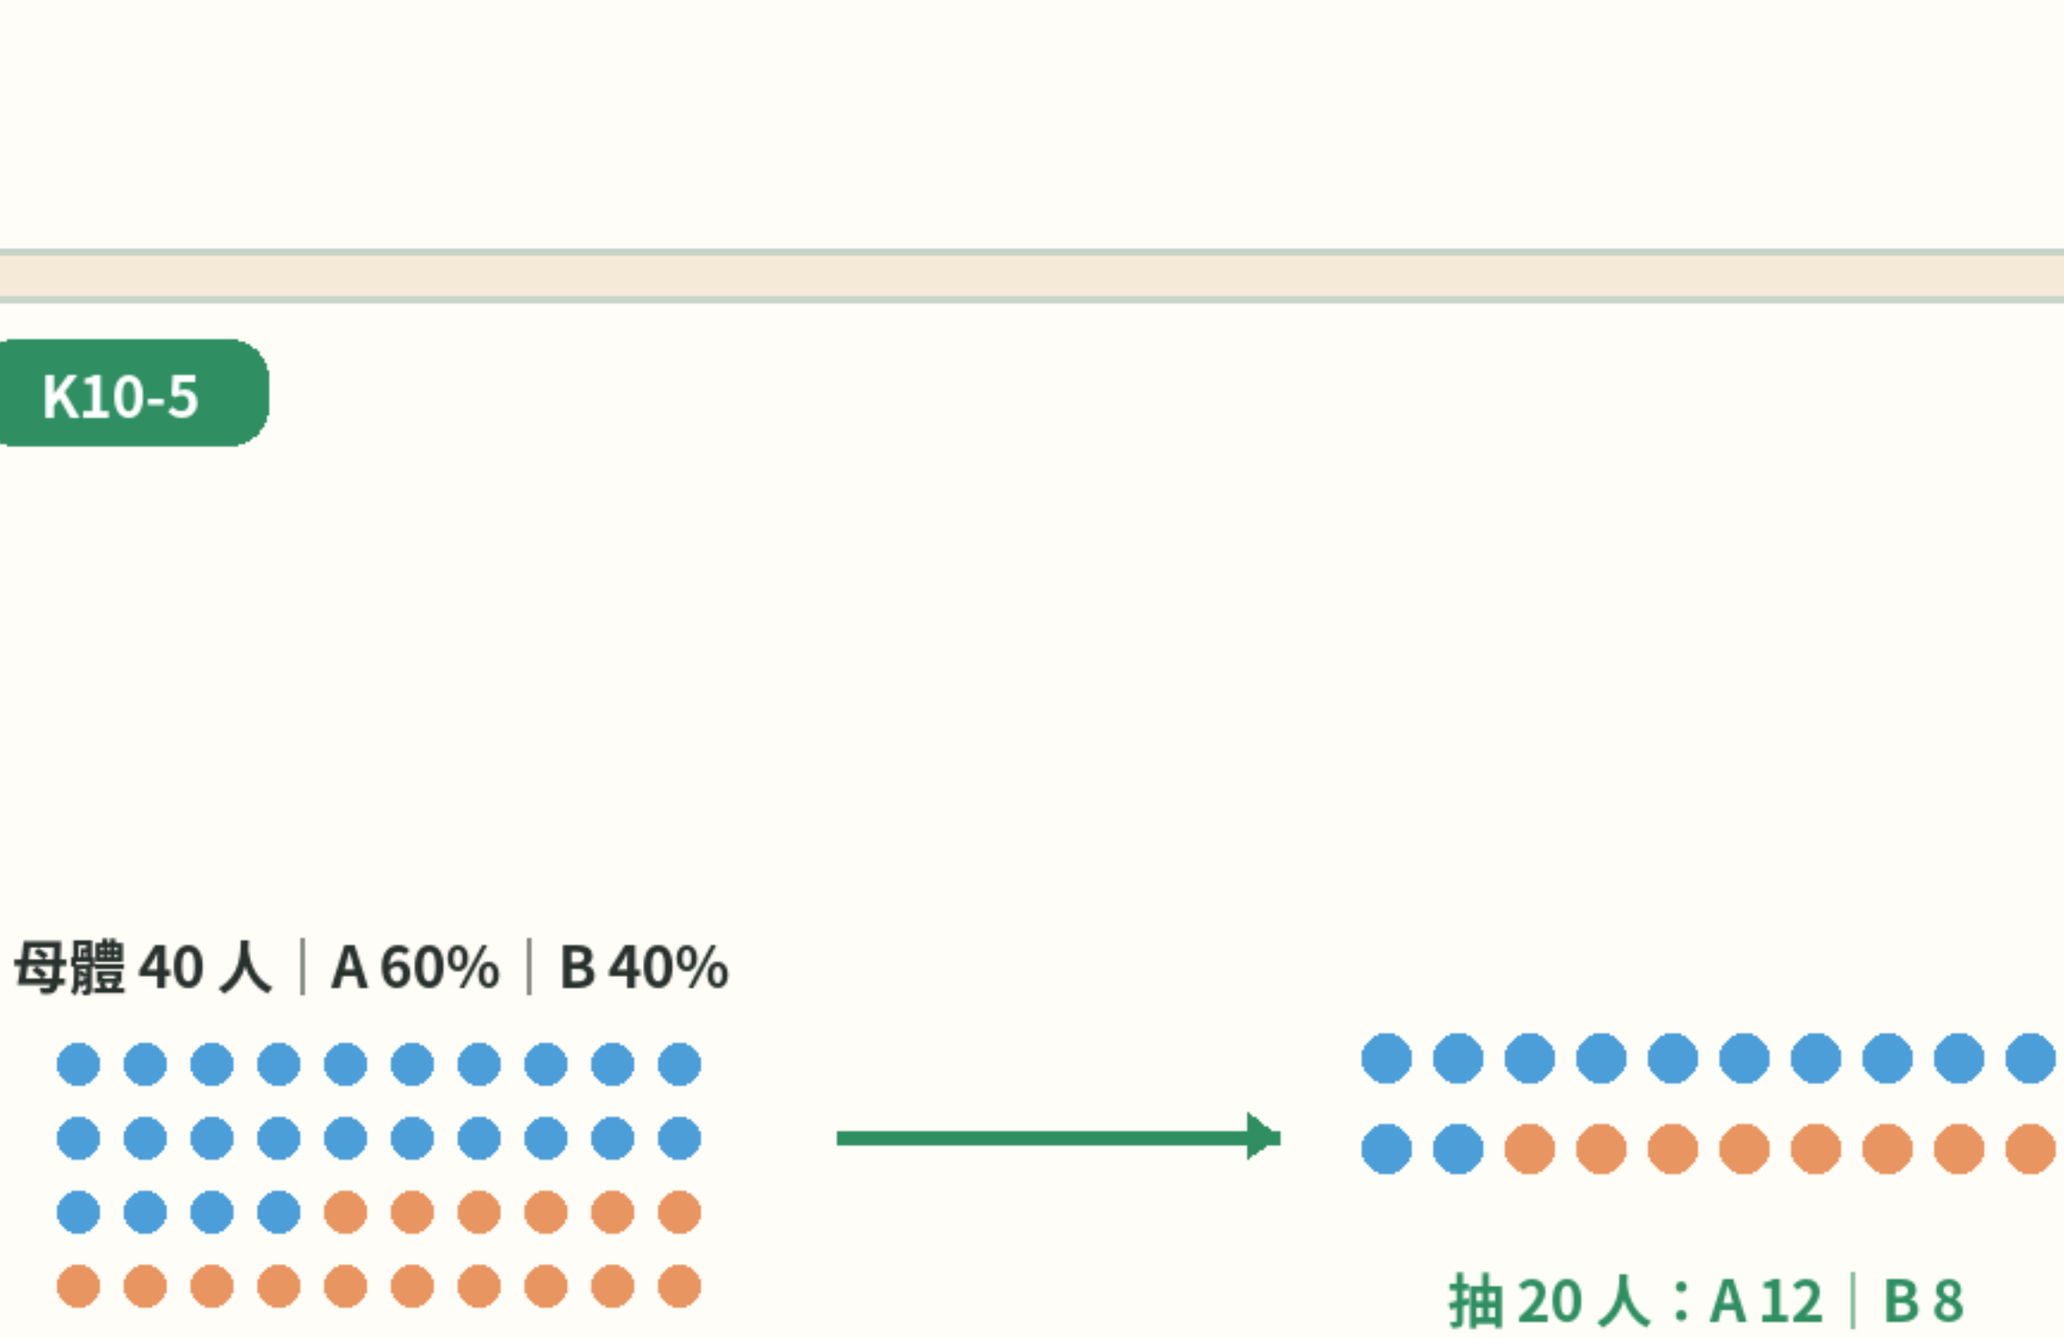
視覺記憶卡｜第 2／2 張

K10-4



類別太多別硬做獨熱編碼，欄位會爆

K10-5



分層抽樣保持各群比例。

看圖默講觀念｜騎車時不看手機

‹ 回目錄

K13 隱私與治理

視覺記憶卡｜第 1／2 張

K13-1

遮罩
0912-***-***

一般化
42 歲 → 40～49

加雜訊
金額 100 → 103

去識別化三招：遮罩、一般化、加雜訊。

K13-2

身分比對欄位*
40～49｜台北
3 人：病名 A／B／C

身分比對欄位*
50～59｜台中
3 人：病名 D／E／F

每組至少 3 人長得一樣｜病名是敏感欄位

k 匿名：每一筆資料至少有 k 個人長得一樣。

K13-3

含某人：原值 100
＋雜訊 0.4 → 輸出 100.4

不含某人：原值 100
＋雜訊 0.1 → 輸出 100.1

兩個輸出很接近 → 分不出某人是否在場

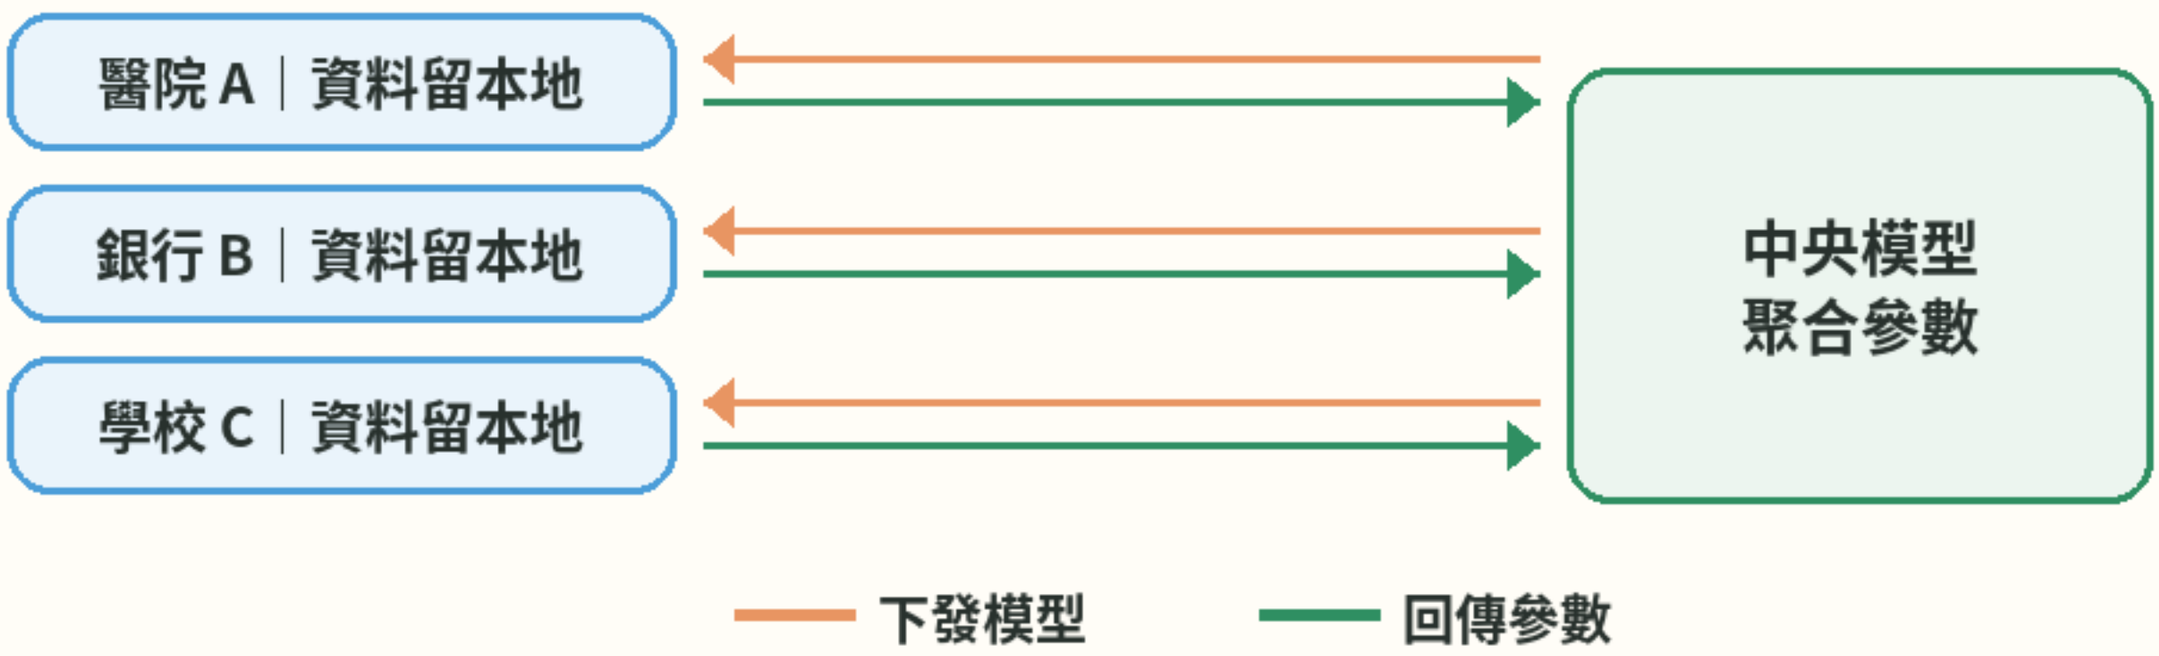
差分隱私：加雜訊，讓人看不出某一個人在不在資料裡。

K13

隱私與治理

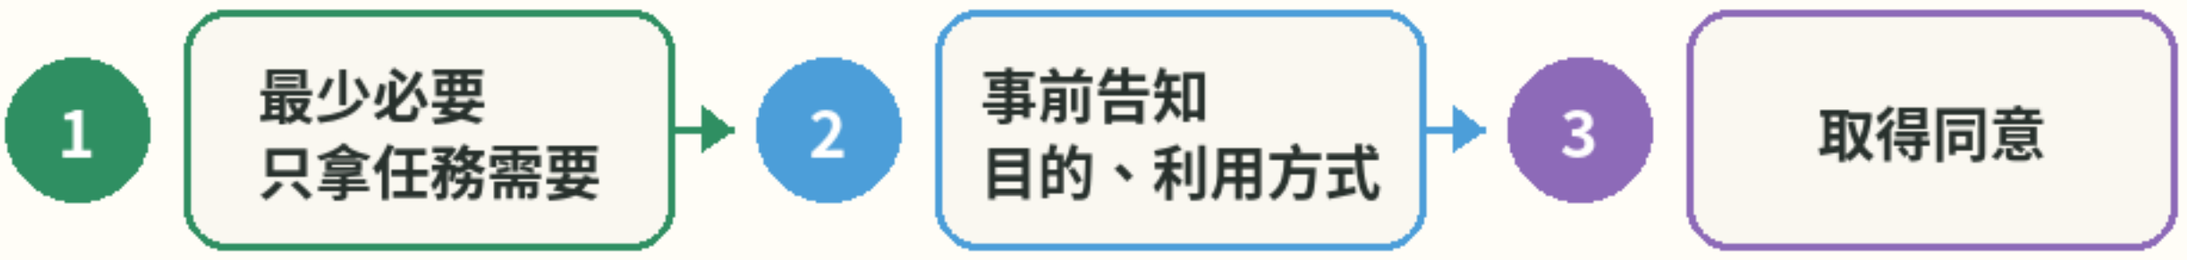
視覺記憶卡｜第 2／2 張

K13-4



聯邦學習：資料不動，模型去跑。

K13-5



個資蒐集只拿最少必要的，而且要告知、取得同意。

看圖默講觀念｜騎車時不看手機

‹ 回目錄

K6

分析方法辨識

視覺記憶卡｜第 1／3 張

K6-1

資料有標準答案嗎？

有 → 監督式
分類、迴歸

沒有 → 非監督式
分群、降維

有標準答案用監督式，沒有用非監督式

K6-2



垃圾信／正常信
→ 分類

屋

房價 1,250 萬
→ 迴歸

預測類別是分類，預測數字是迴歸。

K6-3



K 平均法：先指定 K＝3

分群是把像的歸成一群

看圖默講觀念｜騎車時不看手機

‹ 回目錄

K6 分析方法辨識

視覺記憶卡｜第 2／3 張

K6-4

共 100 筆｜A 有 40｜B 有 30｜同時買 20

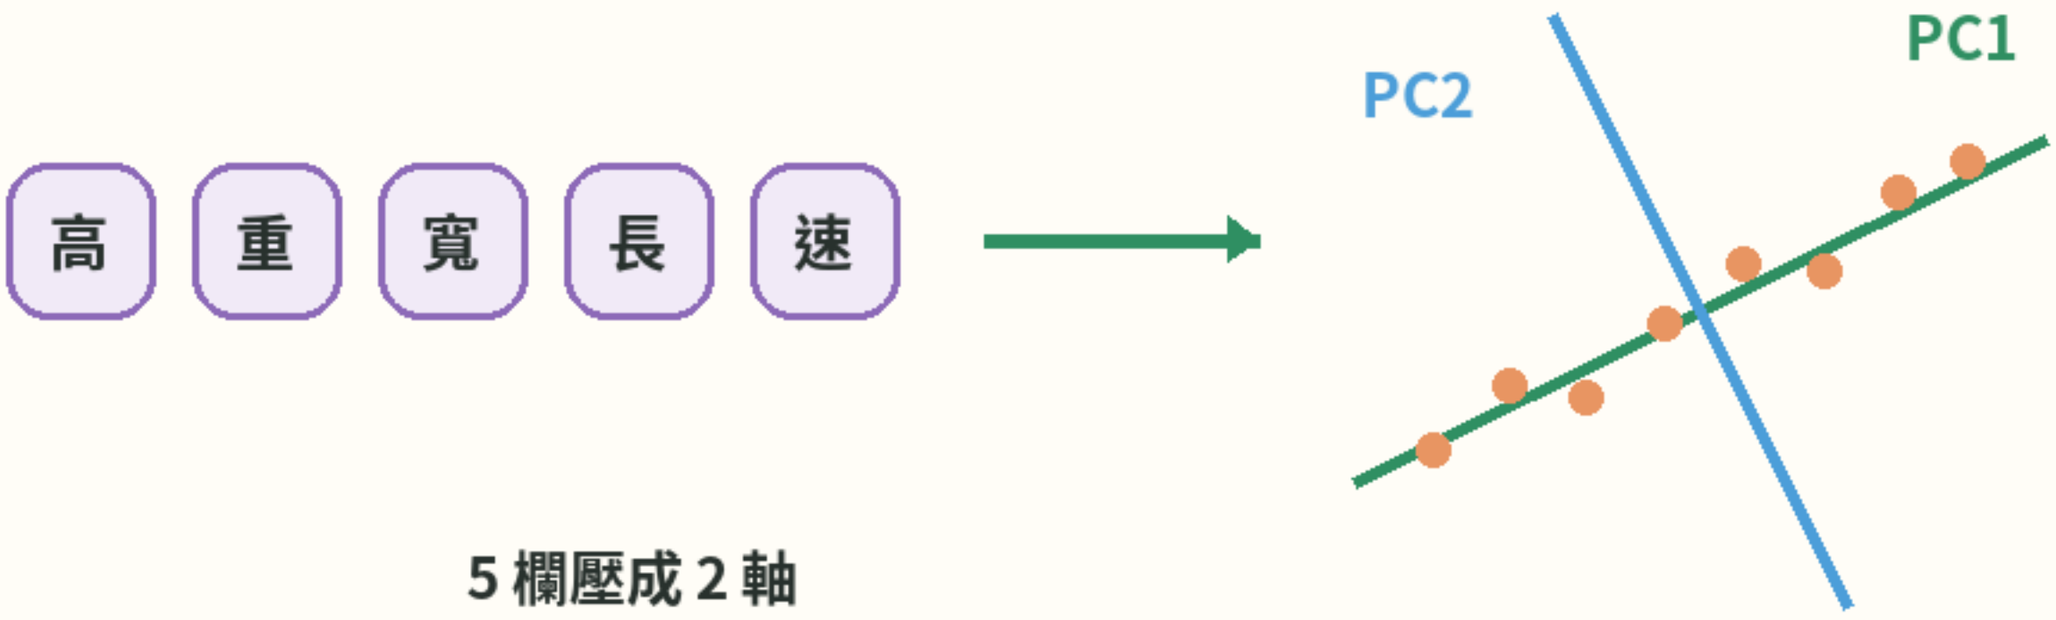
支持度＝20 ÷ 100＝20%

信賴度＝20 ÷ 40＝50%

提升度＝0.50 ÷ 0.30＝1.67 ＞ 1

關聯規則：買了這個也會買那個

K6-5



5 欄壓成 2 軸
保留最多變異

主成分分析：把很多欄壓成少數幾欄，保留最多變異。

看圖默講觀念｜騎車時不看手機

‹ 回目錄

K6

分析方法辨識

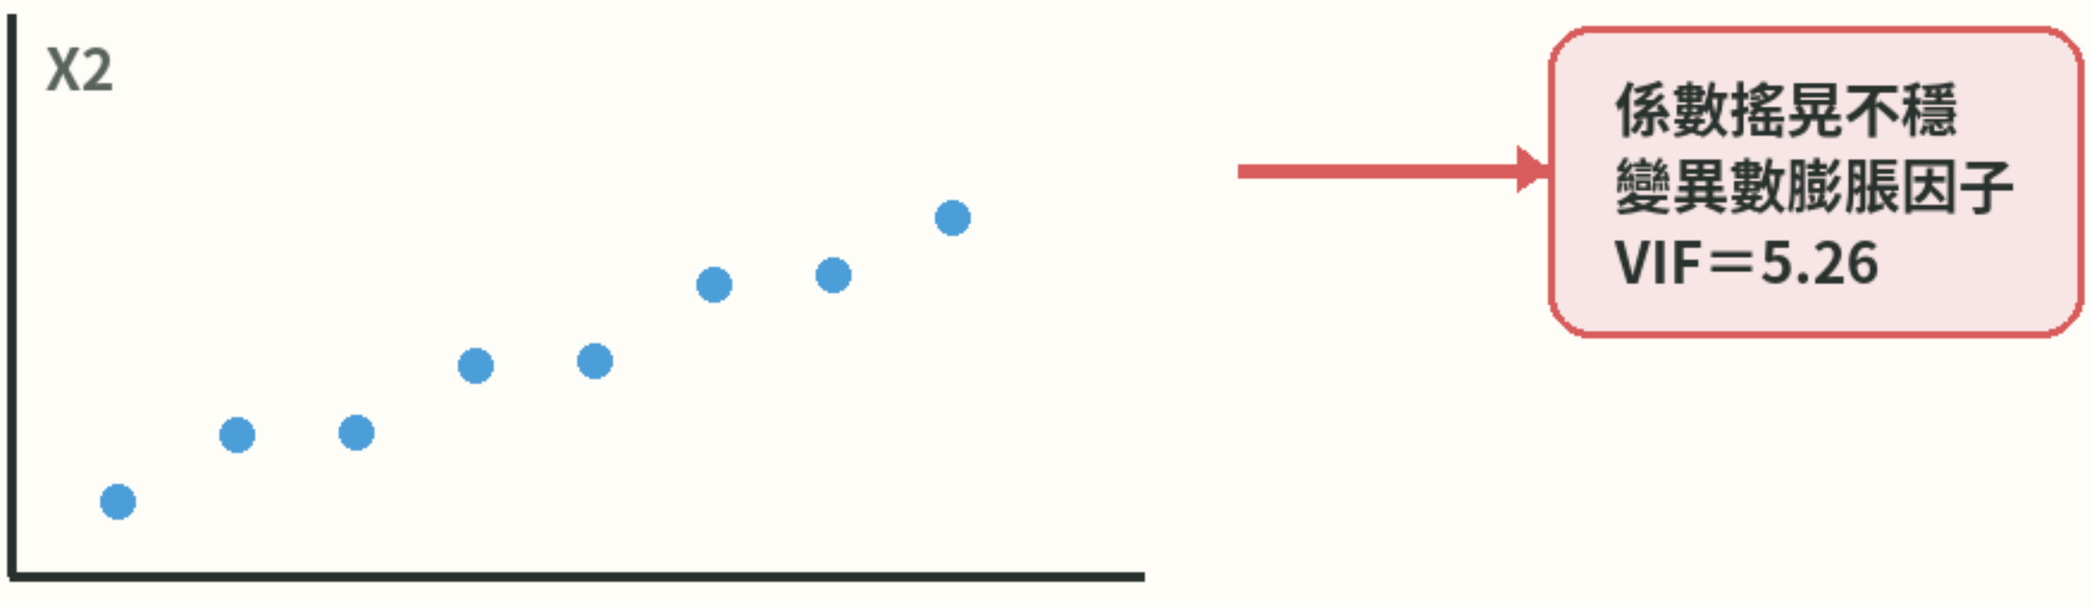
視覺記憶卡｜第 3／3 張

K6-6



主題模型：從一堆文章裡找出共同話題。

K6-7



共線性：自變數彼此太像，係數會不穩

看圖默講觀念｜騎車時不看手機

‹ 回目錄

K7 模型訓練與調校

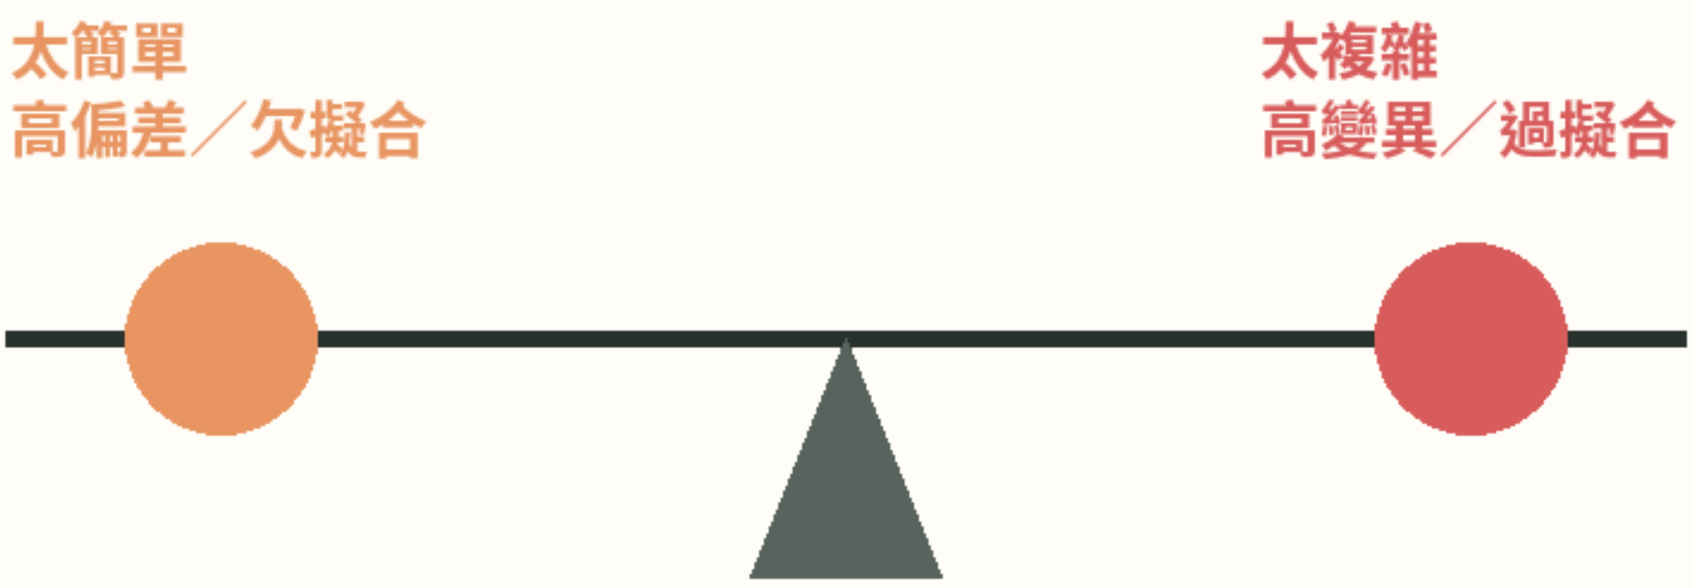
視覺記憶卡｜第 1／2 張

K7-1



訓練好、測試差是過擬合；兩邊都差是欠擬合。

K7-2



偏差高是想得太簡單，變異高是想得太複雜。

K7-3



裝袋法平行投票降變異，提升法接力補錯降偏差

看圖默講觀念｜騎車時不看手機

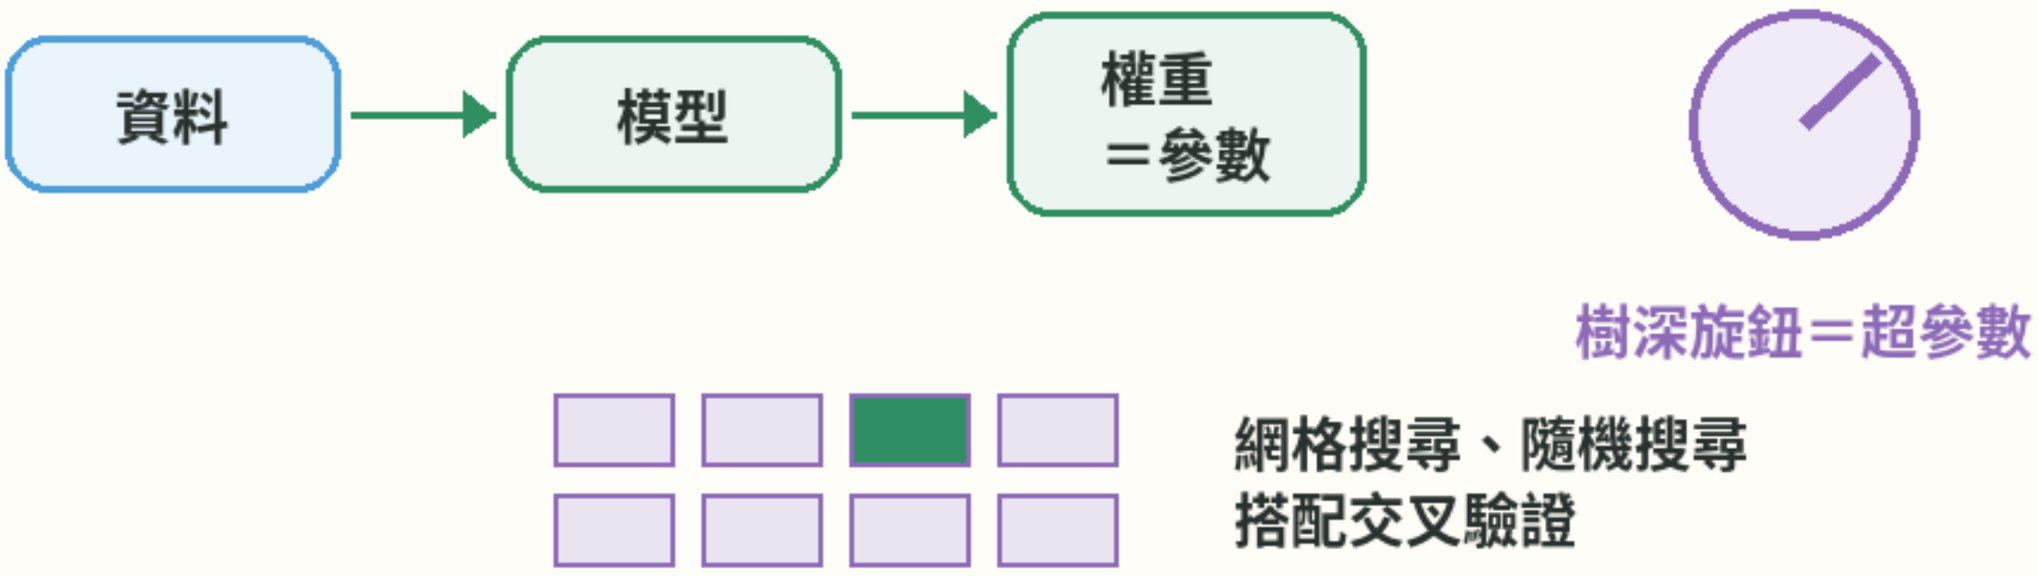
‹ 回目錄

K7

模型訓練與調校

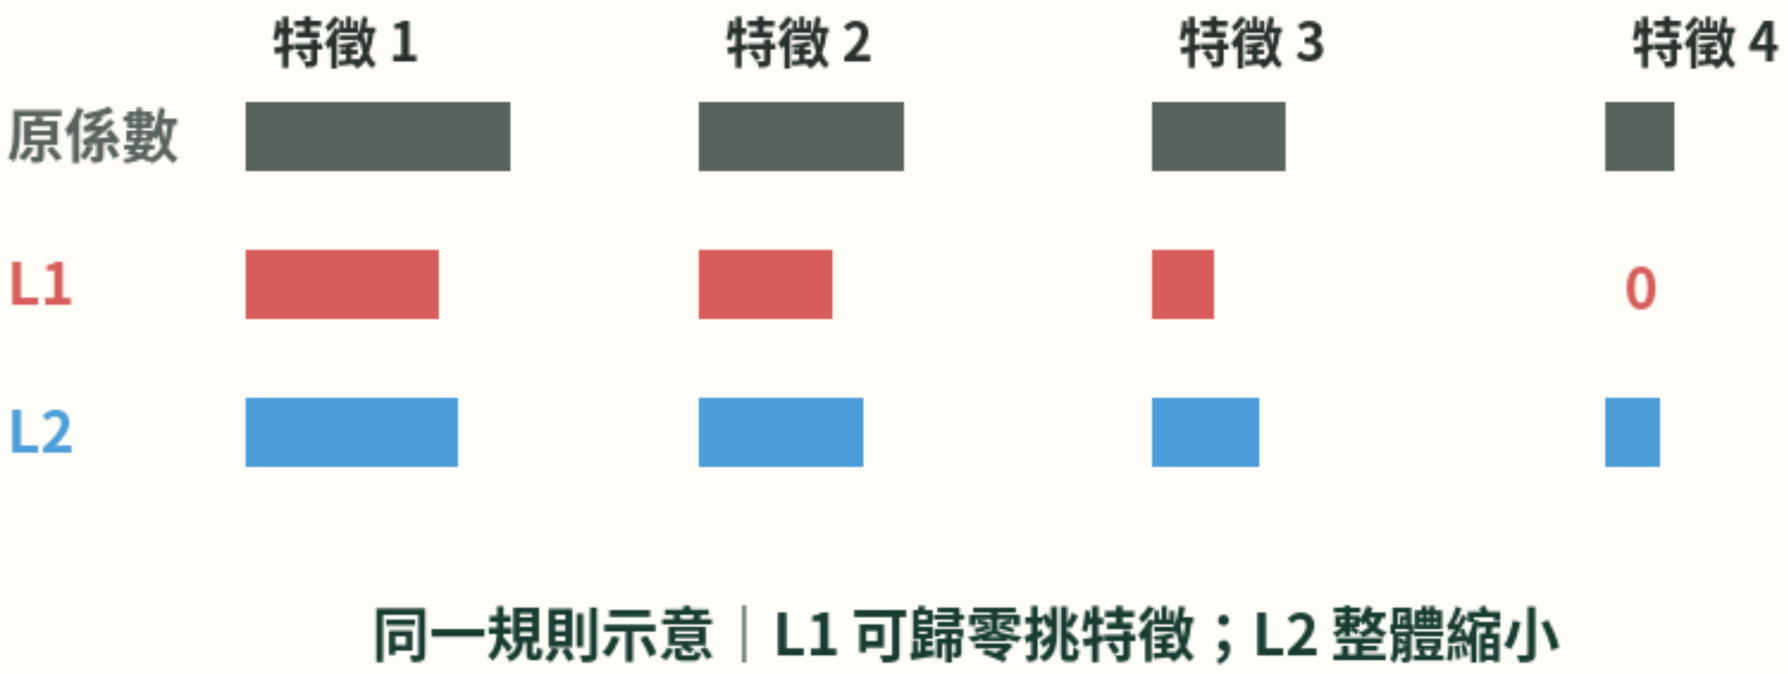
視覺記憶卡｜第 2／2 張

K7-4



參數是模型學出來的，超參數是人先設定的

K7-5



同一規則示意｜L1 可歸零挑特徵；L2 整體縮小

正則化是對複雜度罰款

看圖默講觀念｜騎車時不看手機

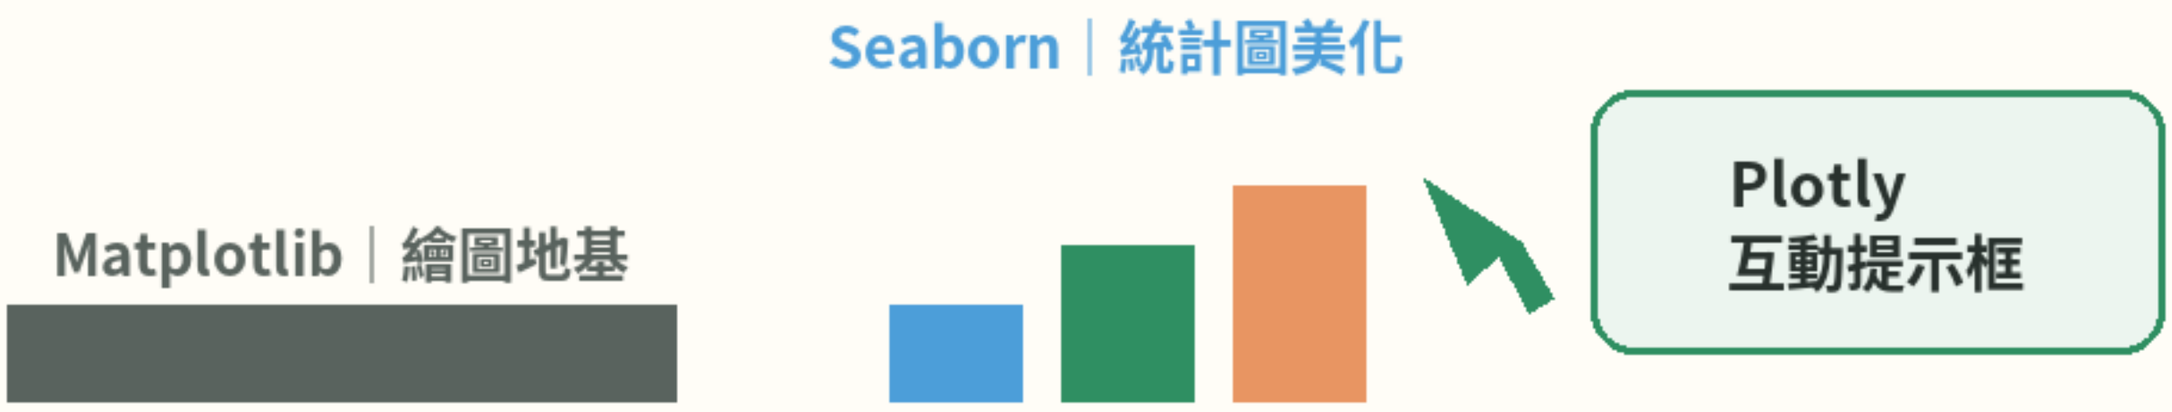
‹ 回目錄

K11

視覺化工具

視覺記憶卡｜第 1／1 張

K11-1



Matplotlib 是地基，Seaborn 是美化統計圖，Plotly 是可互動。

K11-2

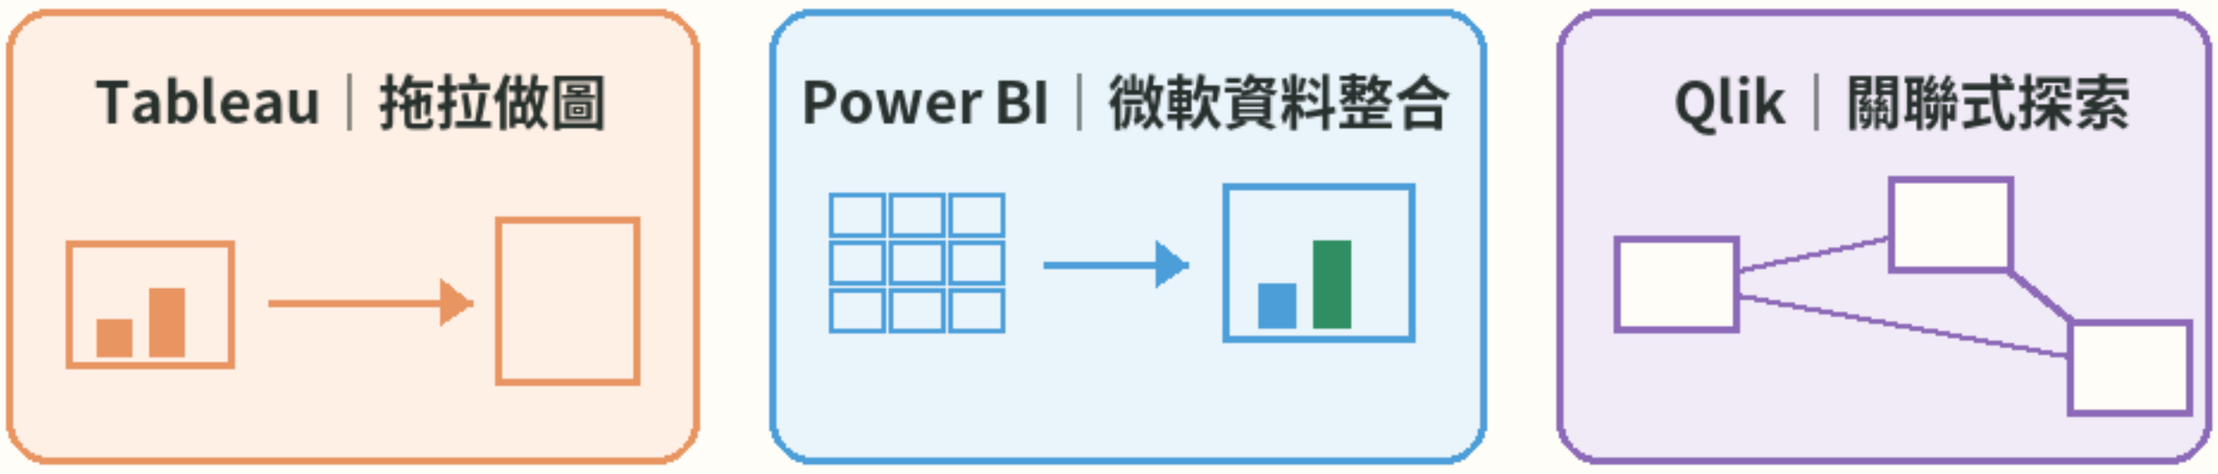


Tableau 拖拉做圖，Power BI 是微軟家族，Qlik 靠關聯引擎。

看圖默講觀念｜騎車時不看手機

‹ 回目錄

K12

視覺化設計原則

視覺記憶卡｜第 1／1 張

K12-1

長條
比大小

折線
看趨勢

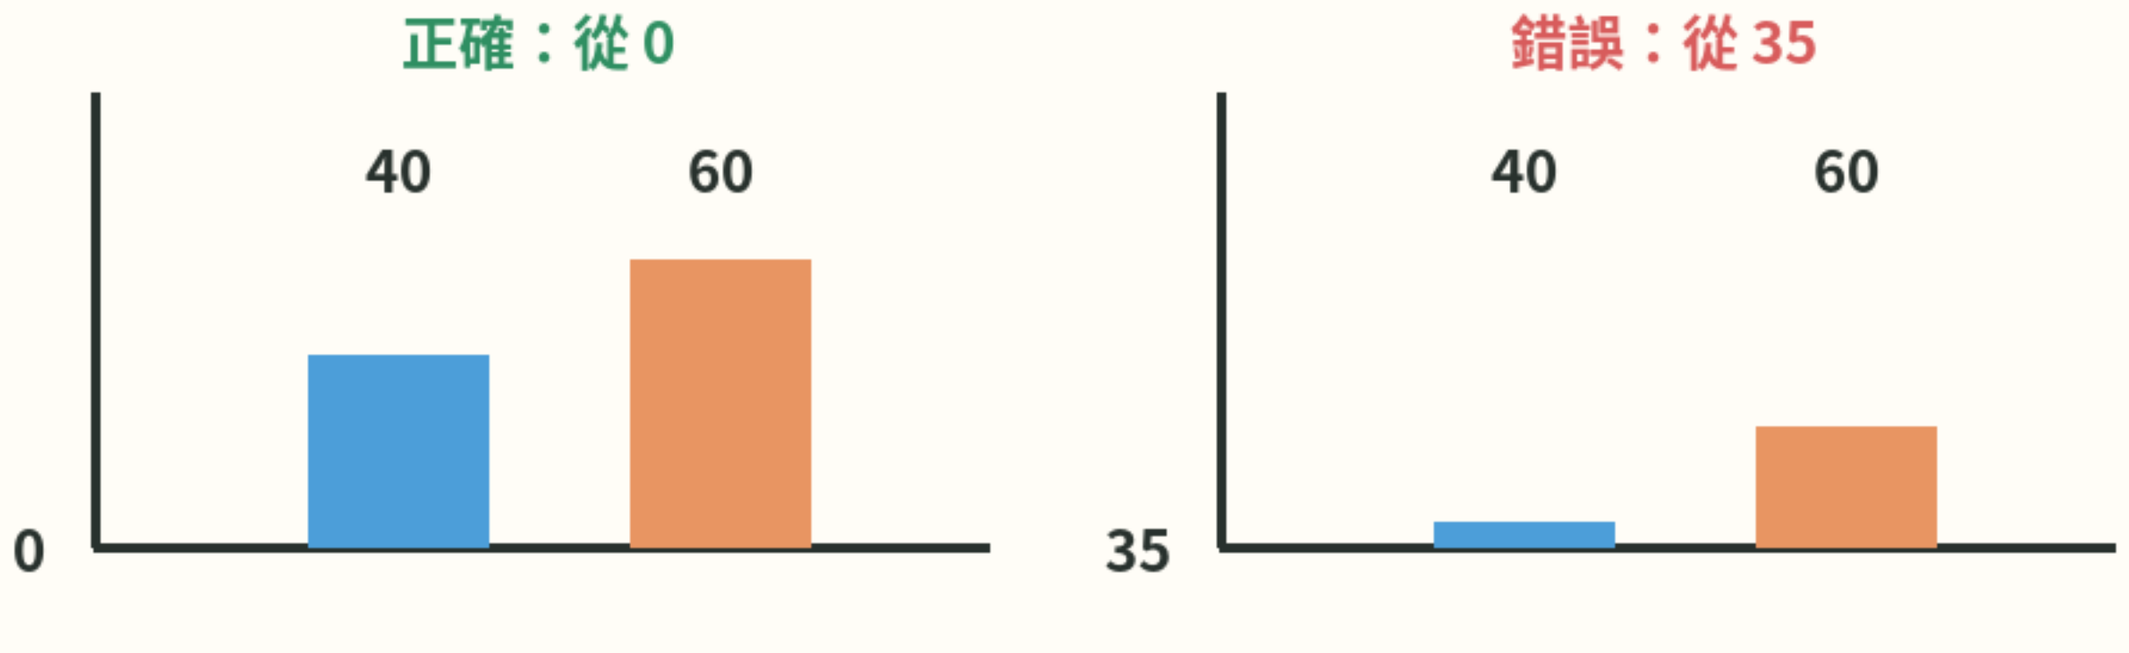
圓餅
看組成
類別要少

散布
看關係

直方／箱形
看分佈

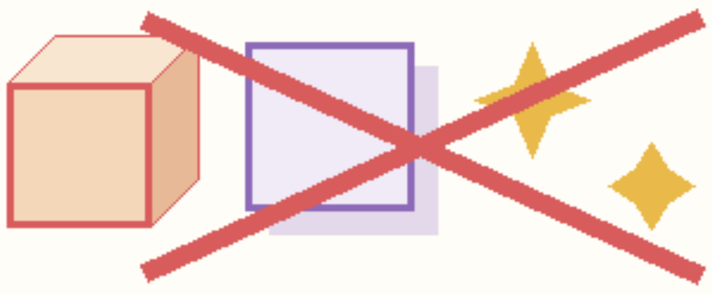
比大小用長條，看趨勢用折線，看組成用圓餅（類別要少），看關係用散布圖，看分佈用直方圖或箱形圖。

K12-2



長條圖的縱軸從 0 開始

K12-3



保留真正要讀的
數據｜標籤｜重點

3D｜陰影｜花邊

不傳達資訊的裝飾就刪掉。

假設檢定四步驟：像法院判案

先假設「沒事」，再看證據夠不夠強到推翻它

① 立虛無假設 H0

「被告無罪」＝「A、B 沒差別」

H0 寫成等號：μ = μ0

▼

② 事先定門檻 α

法官先講好：機率低於 5% 就判

α 常用 0.05，看資料前就定

▼

③ 收資料，算 p 值

假如 H0 是真的，光靠運氣

看到這麼極端（或更極端）的機率

▼

④ 拿 p 值跟 α 比

p < α

拒絕 H0

＝有顯著差異

（判有罪）

p ≥ α

不拒絕 H0

＝證據不足

不是「證明沒差」

同一個判決，兩把尺

尺一：p 值 < α → 拒絕

尺二：檢定統計量的絕對值 > 臨界值 → 拒絕

兩把尺會給出同樣的結論

‹ 回目錄

4. 型一與型二錯誤

在進行統計檢定時，研究者的目的是透過樣本資料對母體做出推論。然而，無論方法如何嚴謹，由於推論基於樣本而非全體，難以完全避免判斷錯誤。因此，假設檢定中可能會產生兩種類型的錯誤：型一錯誤與型二錯誤。

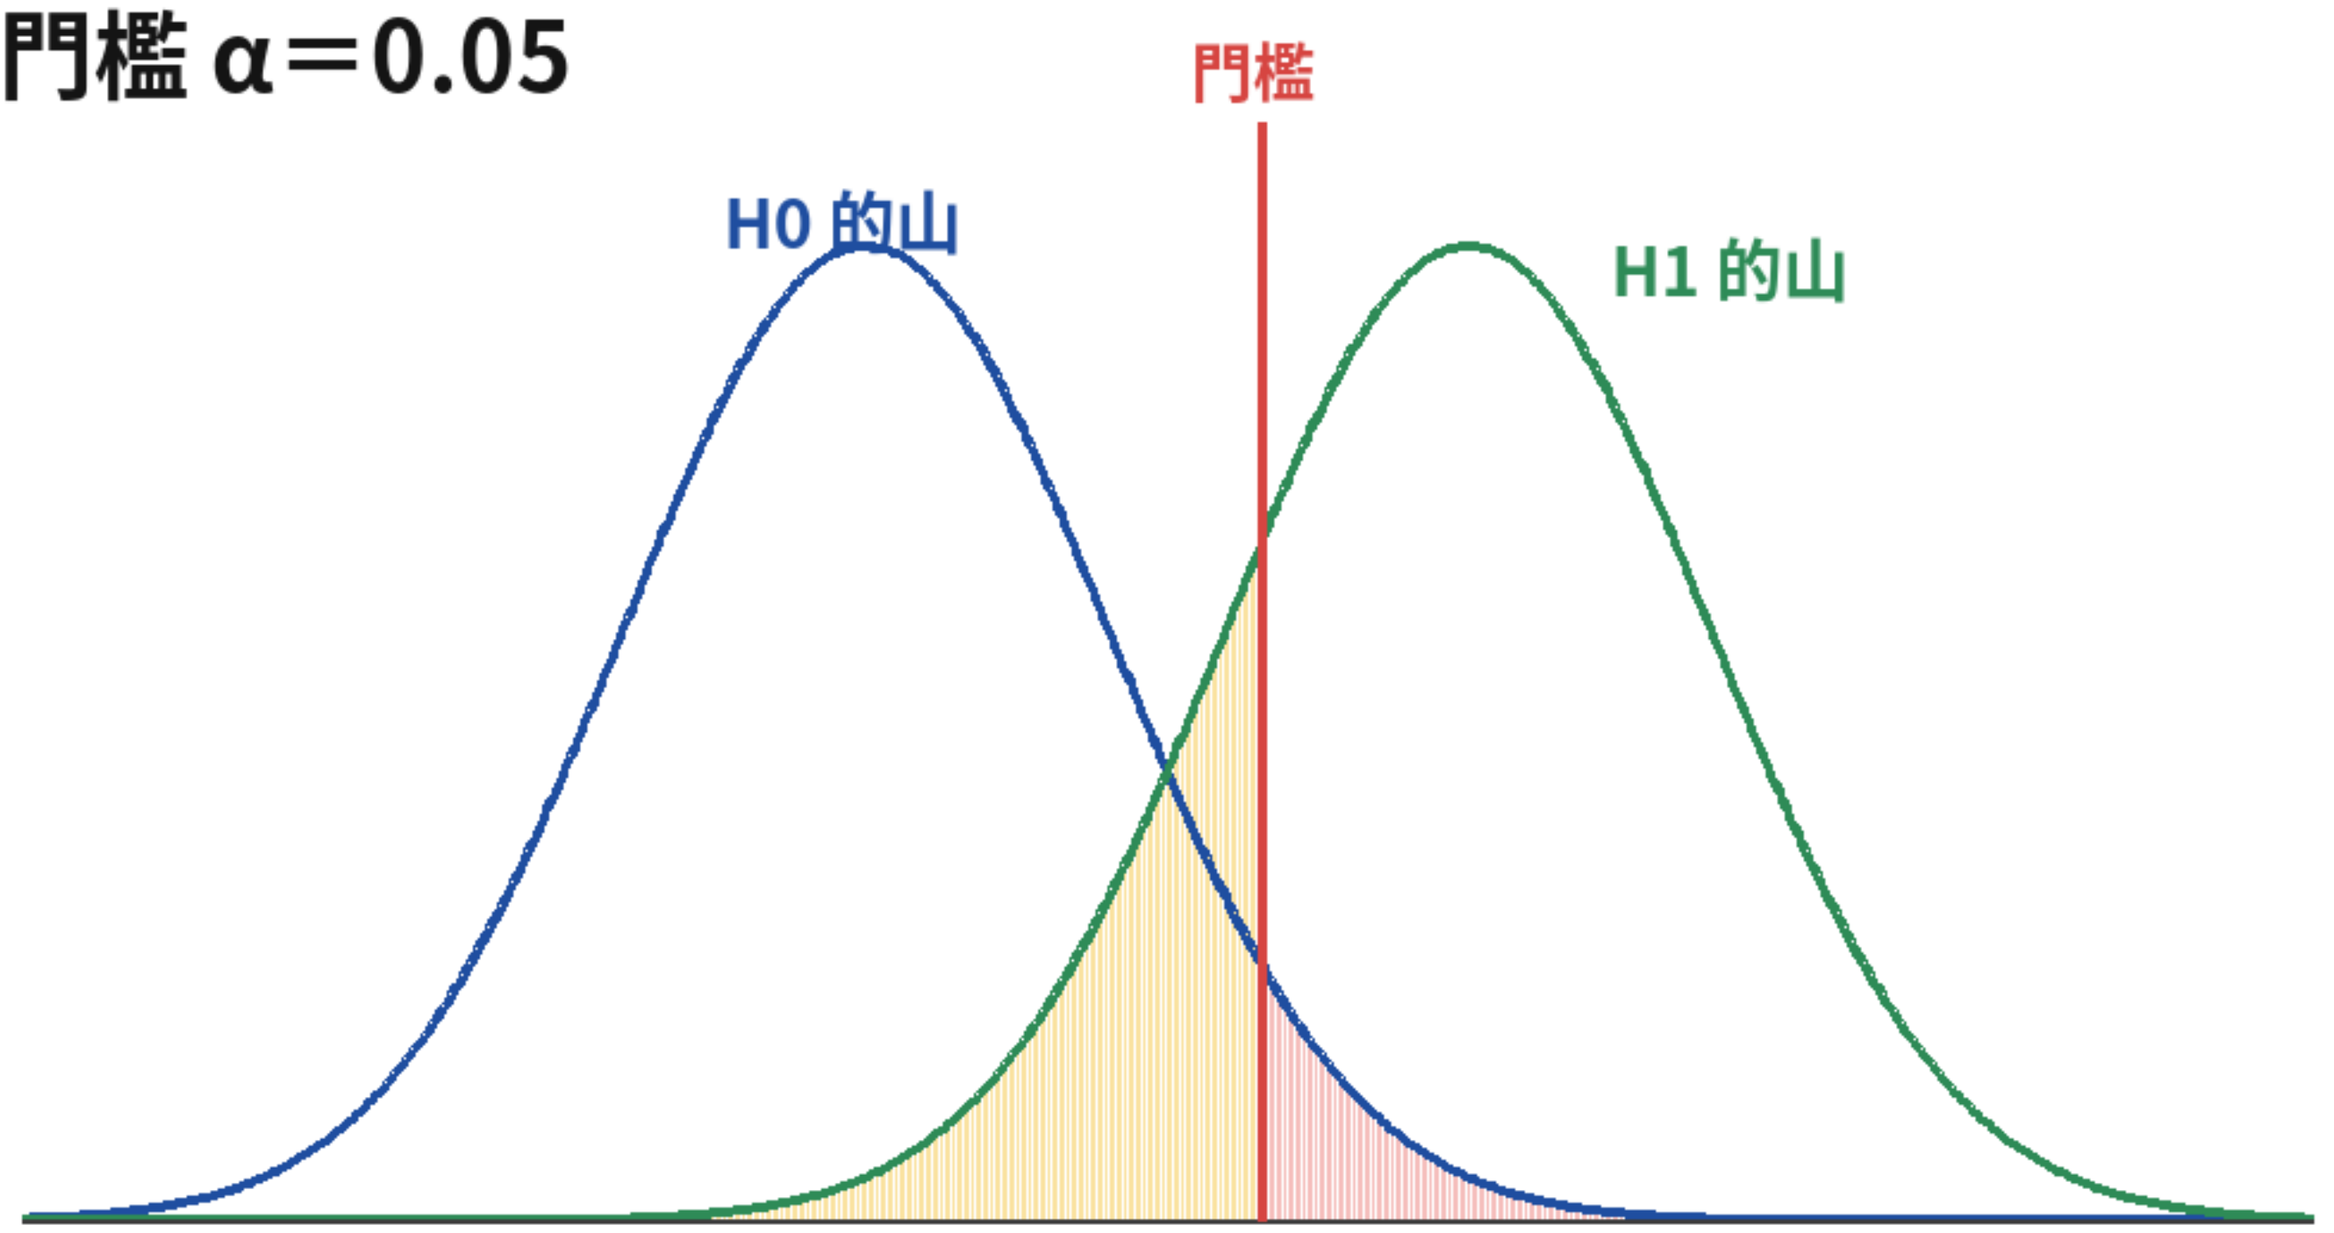
研究判斷結果	真實情況：H_0為真	真實情況：H_0為假
保留 H_0	正確判斷 機率 $= 1 - \alpha$	型二錯誤（漏判） 機率 $= \beta$
拒絕 H_0	型一錯誤（誤判） 機率 $= \alpha$	正確判斷（檢定力） 機率 =

‹ 回目錄

α 調小，冤枉變少、放走變多

左邊山＝H0 為真（沒差）；右邊山＝H1 為真（真的有差）
紅線＝門檻（臨界值），紅線右邊就拒絕 H0

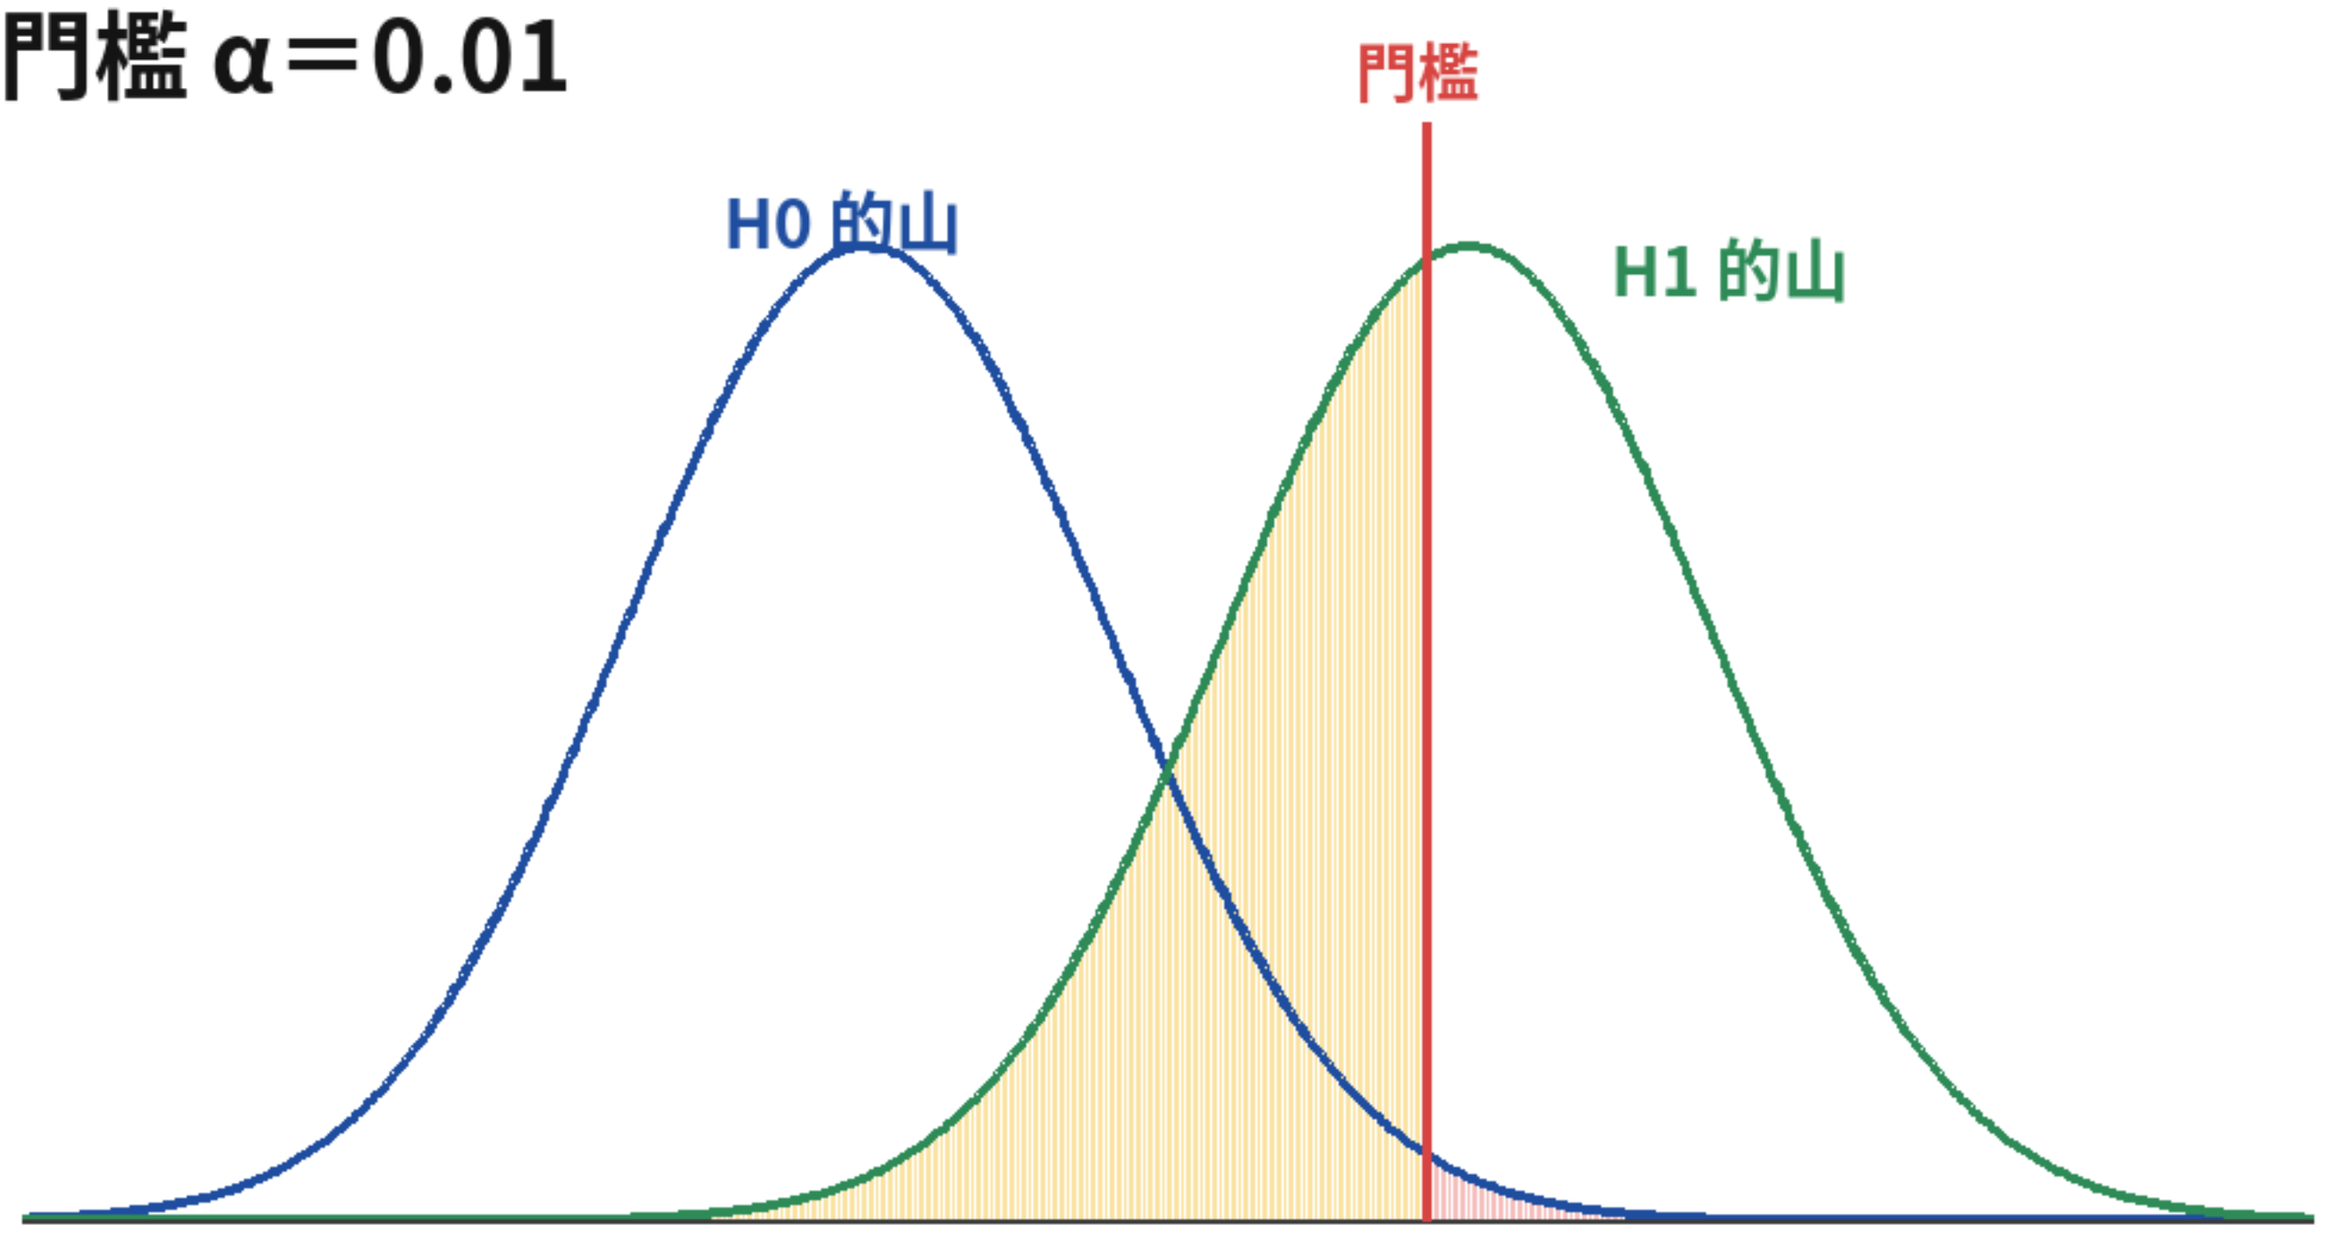
門檻 α＝0.05



紅區＝型一（冤枉）α＝5%
H0 對卻被拒絕

黃區＝型二（放走）β≈20%
檢定力 1−β≈80%

門檻 α＝0.01



紅區＝型一（冤枉）α＝1%
H0 對卻被拒絕

黃區＝型二（放走）β≈43%
檢定力 1−β≈57%

門檻往右移：紅區 5%→1%，黃區 20%→43%（樣本數不變）

示意：右尾單尾檢定，兩山相距 2.5 個標準誤

‹ 回目錄

舉例示意：

情境	虛無假設（H_0）	型一錯誤	型二錯誤
緊急地震預警系統	沒有即將發生的強震	發出錯誤警報，實際上沒有地震	未發出警報，實際上發生強震
銀行防詐騙機制	交易為正常行為	誤判為詐騙交易，阻擋用戶的合法交易	誤判為正常交易，放行實際的詐騙行為
製造業品管	出廠產品為合格品	判定合格品為不合格品，浪費良品	判定不合格品為合格品，讓瑕疵品流入市場
招生測驗篩選	考生不具備入學資格	錄取不符合能力標準的考生	錯失具備優秀能力但未被錄取的考生
電商評論過濾	使用者評論為正常留言	正常評論誤判為違規，遭到刪除	違規內容未被識別，繼續顯示

‹ 回目錄

（2）型二錯誤（Type II Error）

型二錯誤則是指在對立假設實際為真的情況下，卻未能拒絕虛無假設。也就是「有差異，卻誤以為沒差異」。

型二錯誤的機率以 β 表示，與檢定力（power）有關。檢定力指的是當對立假設為真時，能正確拒絕虛無假設的機率，計為 1−β。若樣本數不足、變異數過大、或效應太小，則檢定力會降低，型二錯誤的風險也會上升。

‹ 回目錄

檢定力：綠區越大，越抓得到

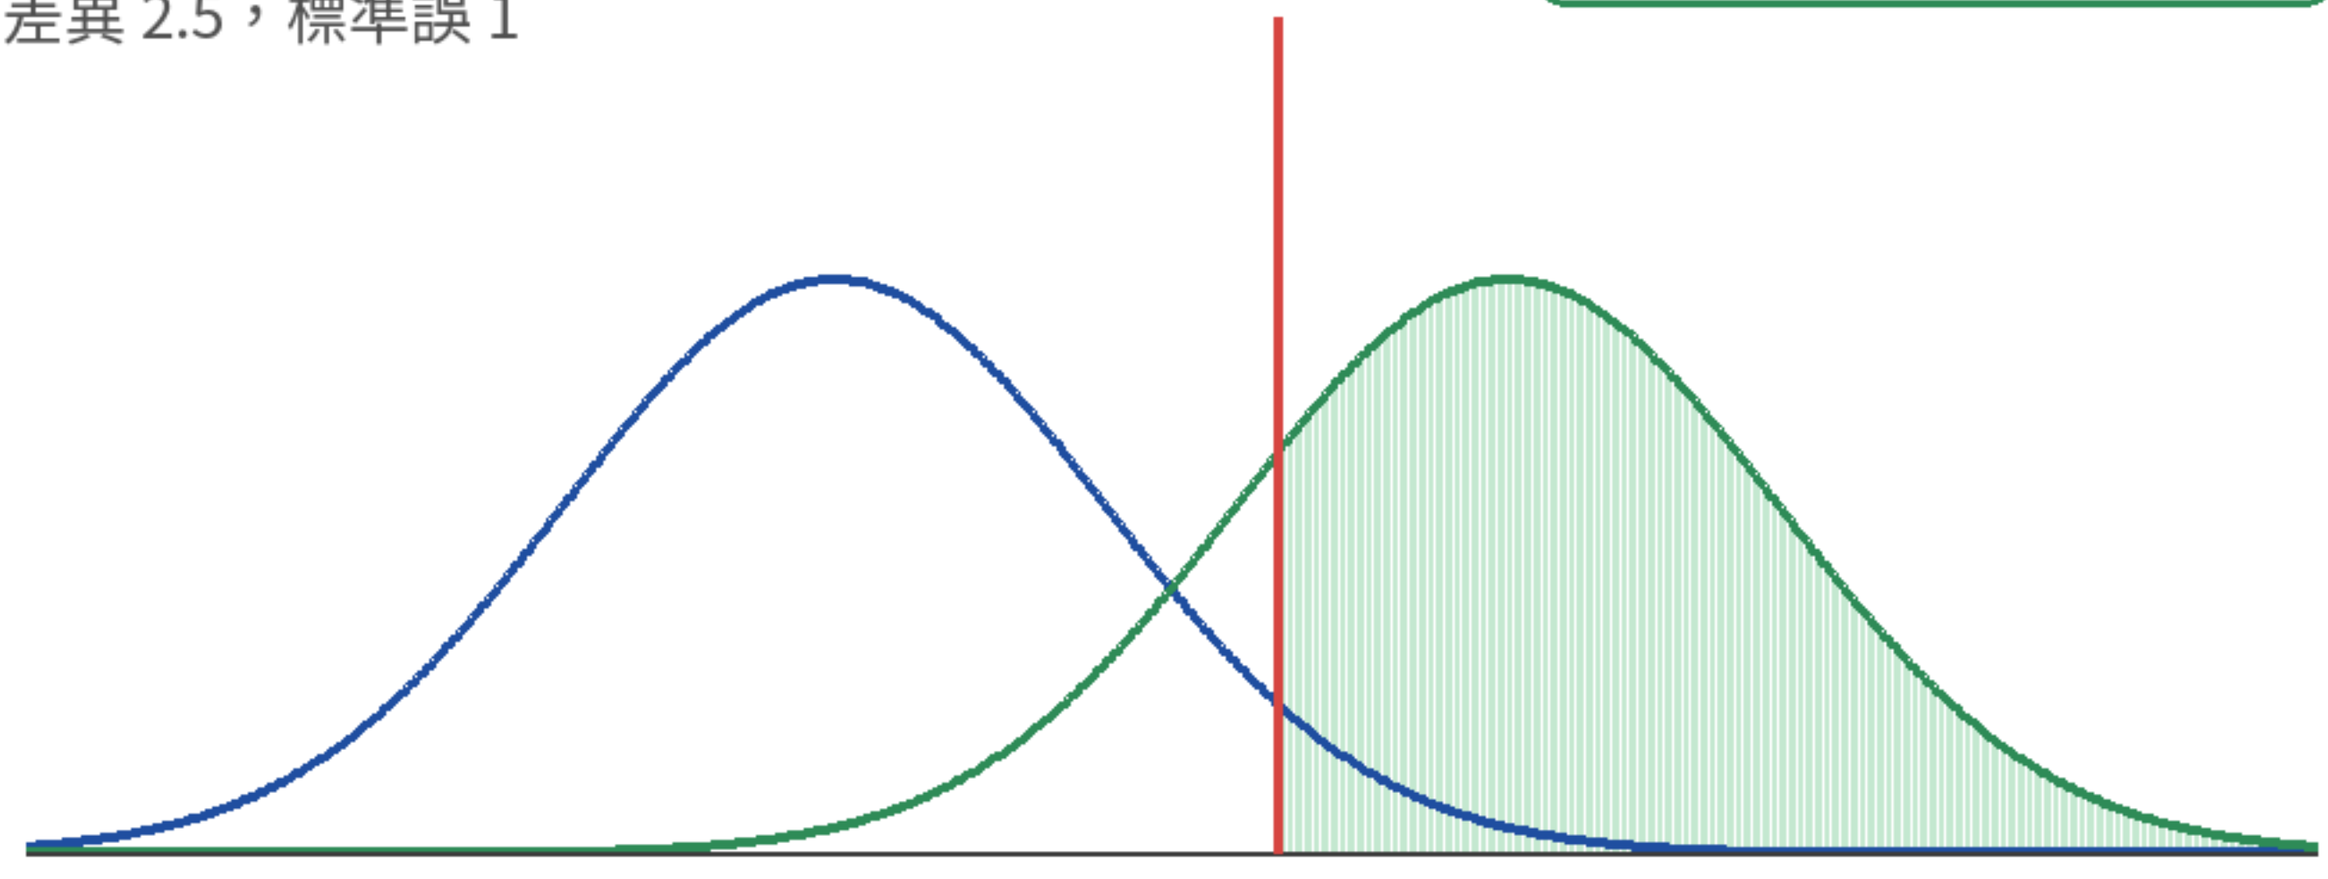
藍山＝H0（沒差）　綠山＝H1（真的有差）　紅線＝門檻 α＝0.05

綠山越過紅線的部分＝檢定力（1−β）

① 基準

差異 2.5，標準誤 1

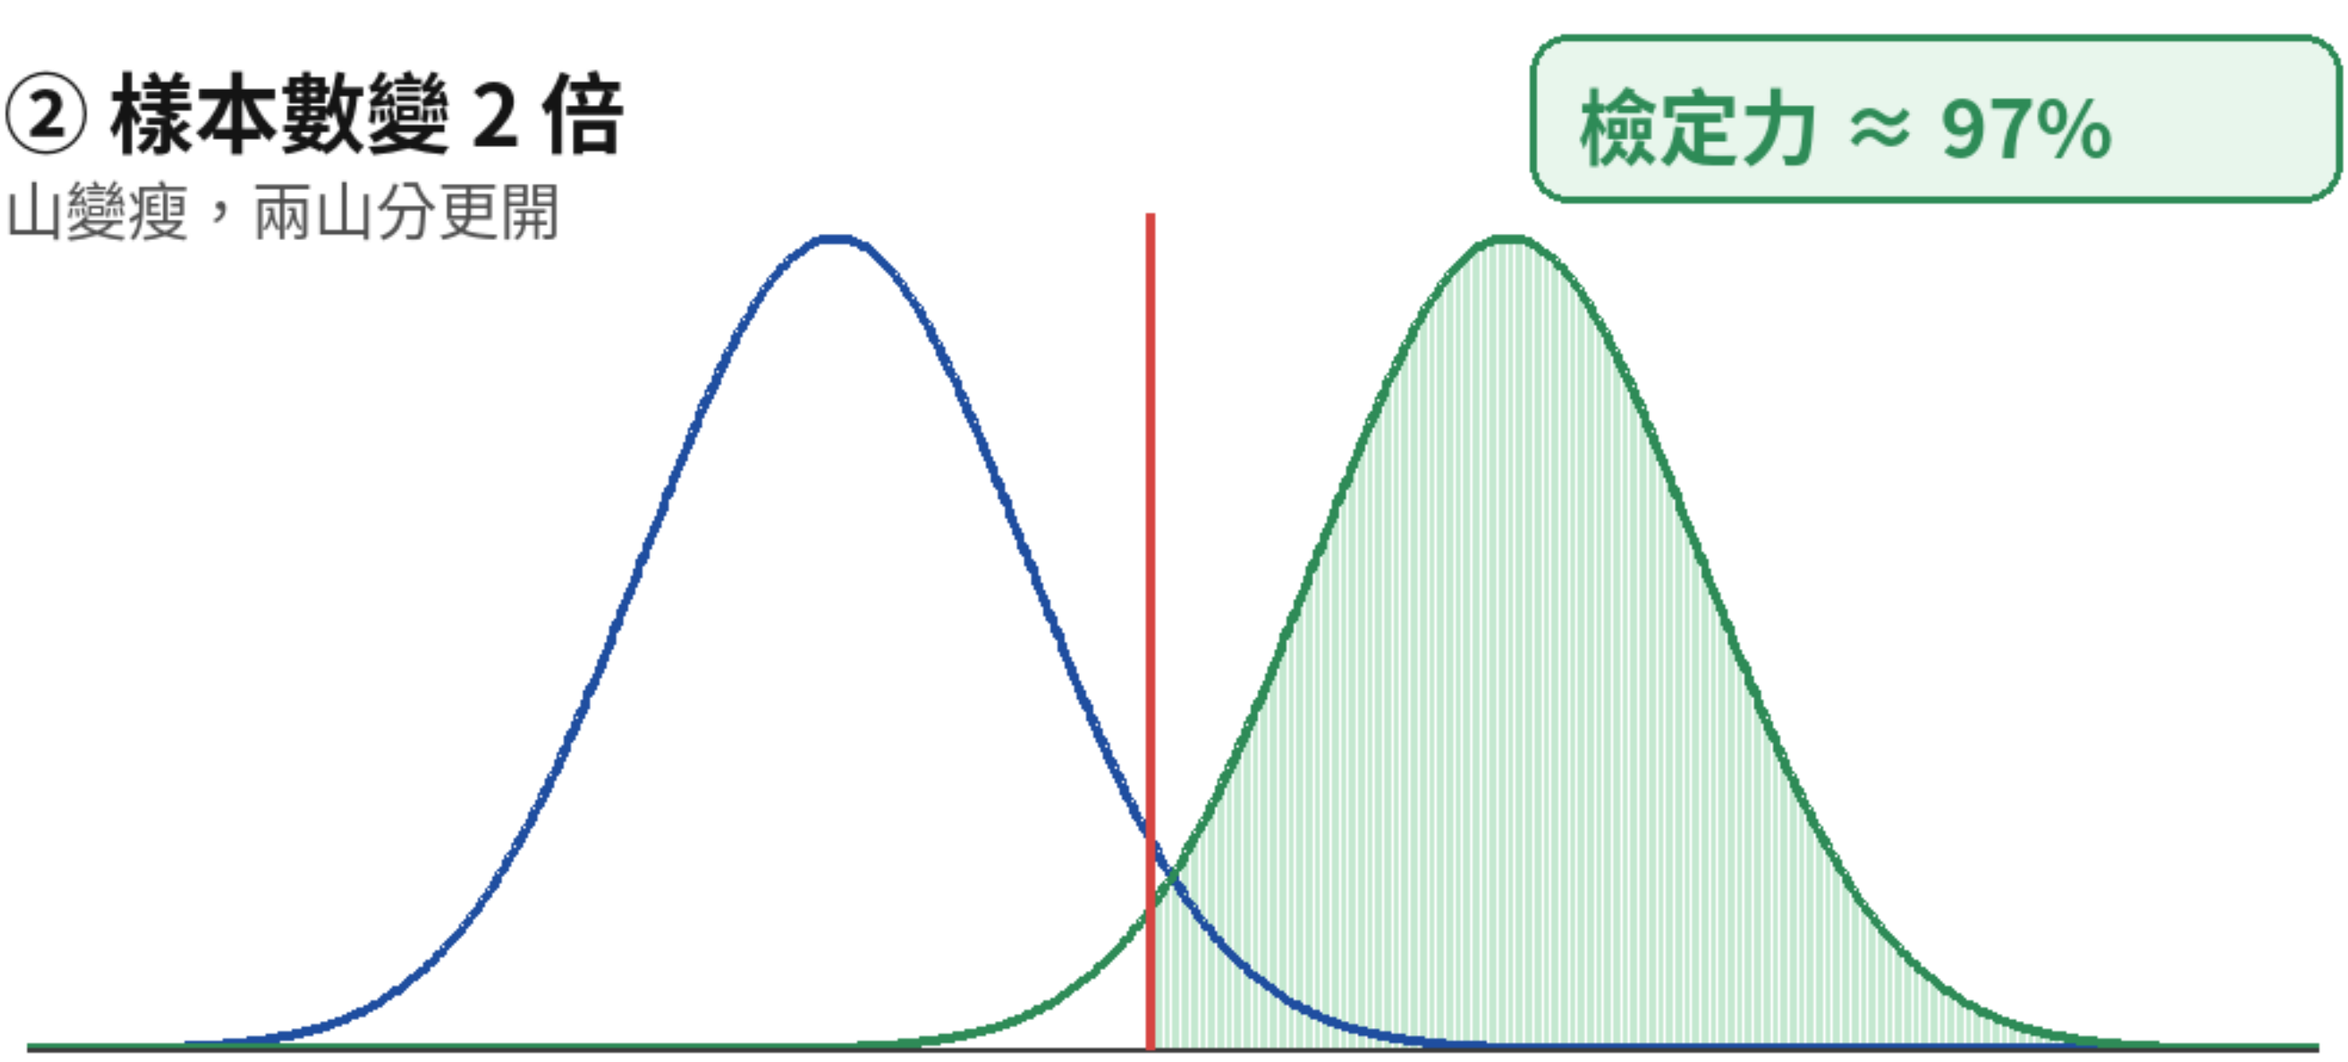
檢定力 ≈ 80%



② 樣本數變 2 倍

山變瘦，兩山分更開

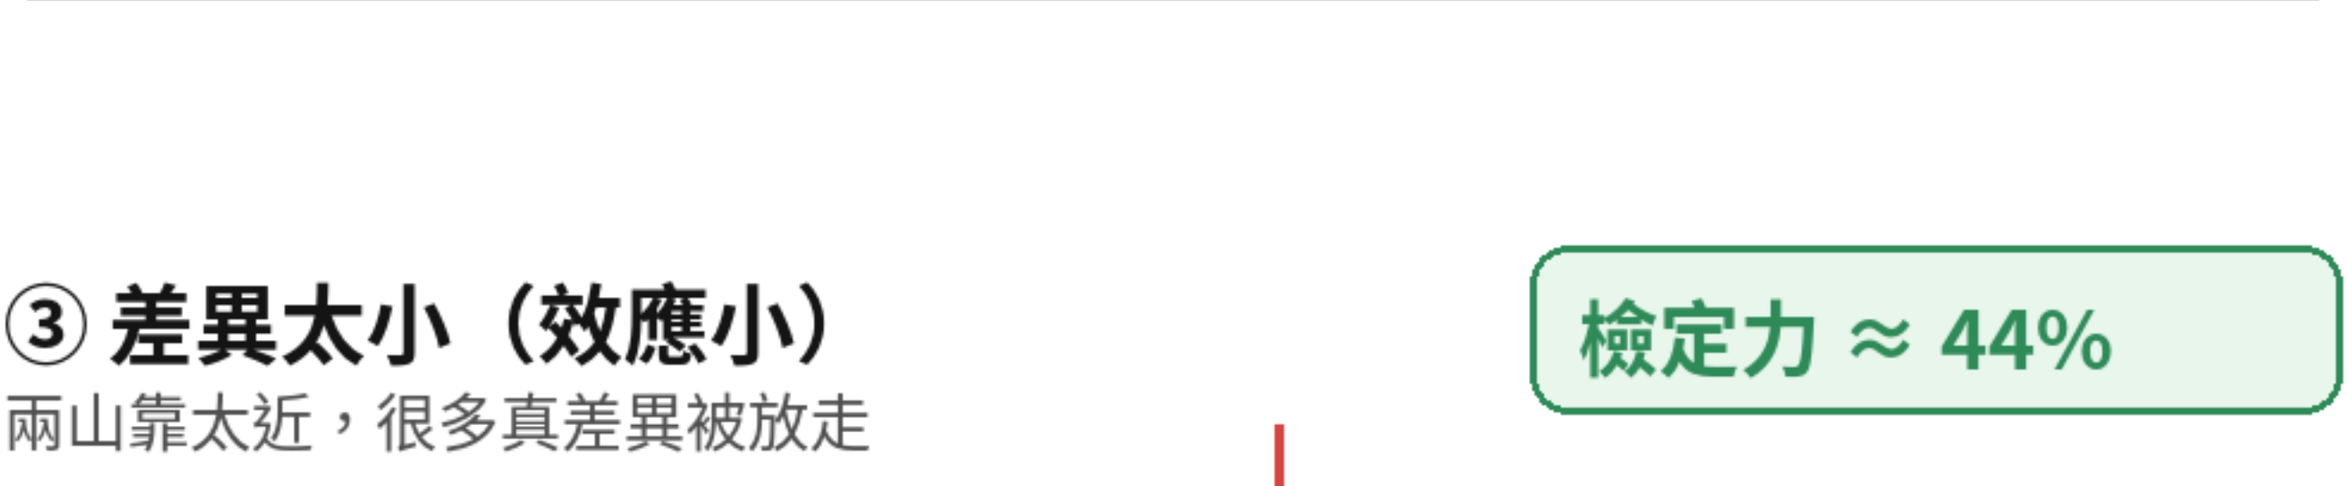
檢定力 ≈ 97%



③ 差異太小（效應小）

兩山靠太近，很多真差異被放走

檢定力 ≈ 44%



學習指引 3-30：樣本數不足、變異數過大、效應太小 → 檢定力降低

示意：右尾單尾檢定，數字由常態分佈程式實算

‹ 回目錄

招生篩選：學校預設「你還沒資格」

H0＝考生不具備入學資格（要靠成績證明自己，才推翻它）

拒絕 H0＝學校採取行動：錄取

	事實：H0 為真（真的不夠格）	事實：H0 為假（其實很優秀）
不錄取（保留 H0）	正確 1−α 不夠格的人沒錄取	型二錯誤 β 該錄取卻沒錄取 ＝錯失優秀考生
錄取（拒絕 H0）	型一錯誤 α 不該錄取卻錄取了 ＝錄取不夠格的人	正確 1−β（檢定力） 優秀的人被錄取

跟法院一模一樣：法官預設「被告無罪」，學校預設「考生不夠格」

都是「先站在保守那一邊，證據夠強才改判」

萬用判斷法：先找出「拒絕 H0 時要做的行動」

型一＝不該做卻做了　　型二＝該做卻沒做

情境	H0（預設）	拒絕 H0 要做的行動	型一 不該做卻做	型二 該做卻沒做
地震預警	沒有強震	發警報	亂發警報	漏發警報
銀行防詐	交易正常	擋下交易	擋了好人	放走詐騙
品管	產品合格	判不合格	丟掉良品	放走瑕疵
招生篩選	**考生不夠格**	**錄取**	**錄取不夠格**	**錯失優秀**
評論過濾	留言正常	刪除留言	刪錯好留言	漏刪違規

上表排法同學習指引 3-29：上列保留 H0、下列拒絕 H0；下表取自 3-30 舉例示

‹ 回目錄

項目	參數估計	統計假設檢定
目的	推測母體參數的「值」或「區間」	驗證某個關於母體參數的「主張」是否成立
重點問題	這個母體參數大約是多少？（例如：平均收入是多少？）	我們是否有足夠證據拒絕一個假設？（例如：新藥是否有效？）
輸出結果	提供點估計值（如平均數）與信賴區間（如 95% CI）	提供 p 值、檢定統計量，並根據顯著水準決定是否拒絕虛無假設
依據	基於樣本資料，計算出母體參數的估計值	基於假設前提與樣本結果，進行推論判斷
例子	根據樣本估計出平均體重為 68 公斤，95%信賴區間為[66, 70]	假設新運動課程能降低體重（對立假設），檢定結果 $p = 0.03$，小於 0.05，拒絕虛無零假設，接受對立假設，認為有效

‹ 回目錄

- 區間估計（Interval Estimation）：

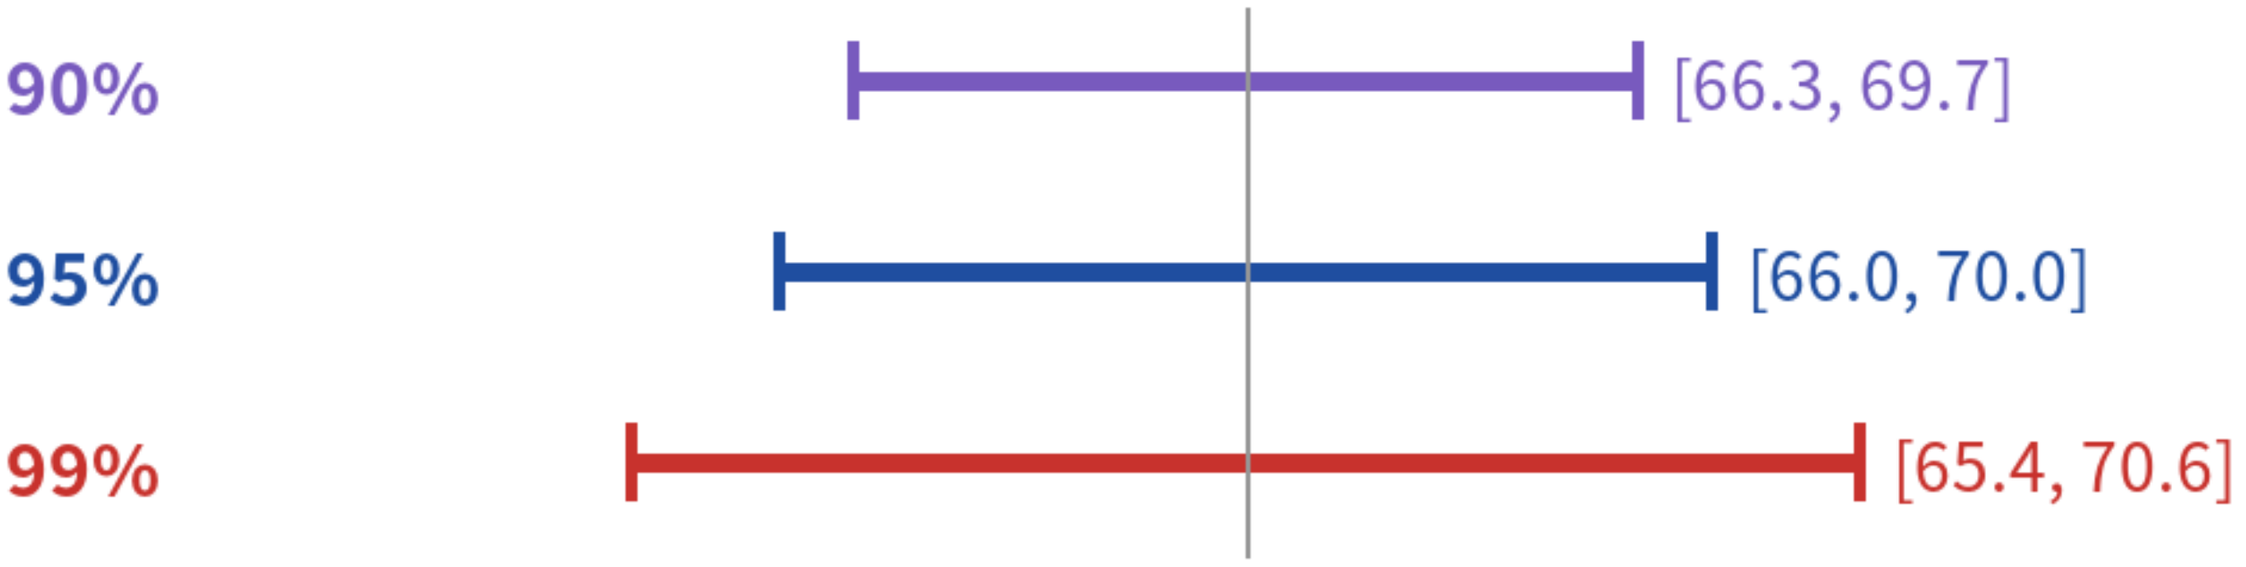
進一步提供一個數值範圍，表示我們對母體參數所在區間的信心程度。這個範圍稱為信賴區間（Confidence Interval）。以 95%信賴區間為例，其意義並非母體參數有 95%的機率落在某一特定區間內，而是指：若以相同方式重複進行大量抽樣並對每個樣本建立信賴區間，則預期這些區間中約有 95%會包含母體的真實參數值。

‹ 回目錄

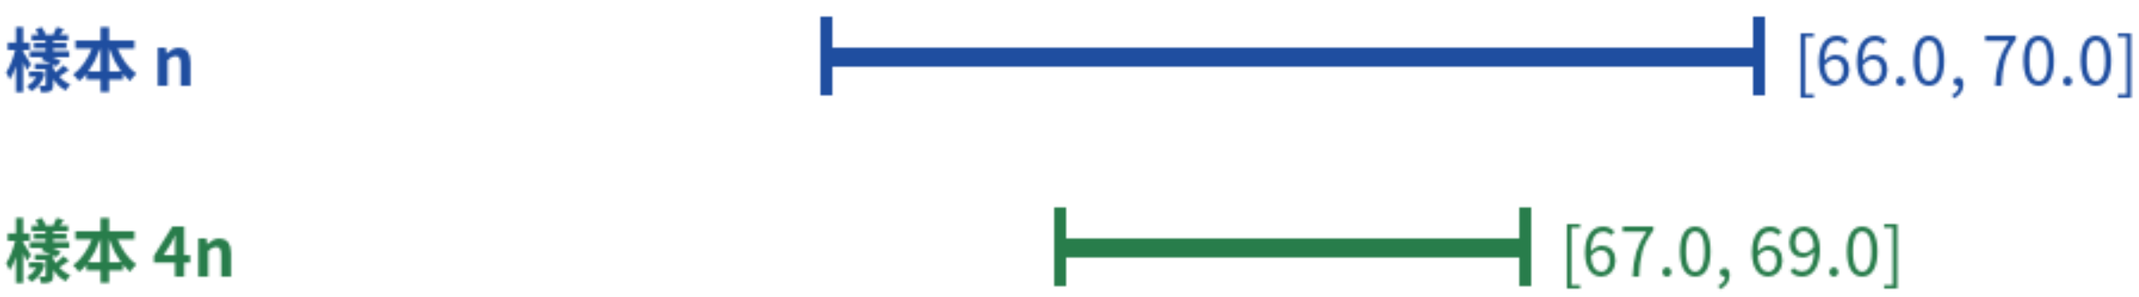
信賴區間：像撒網撈真正的平均

例子取自學習指引 3-24：平均體重 68 公斤，95% 信賴區間 [66, 70]

① 想更有把握 → 網撒更寬（樣本數不變）

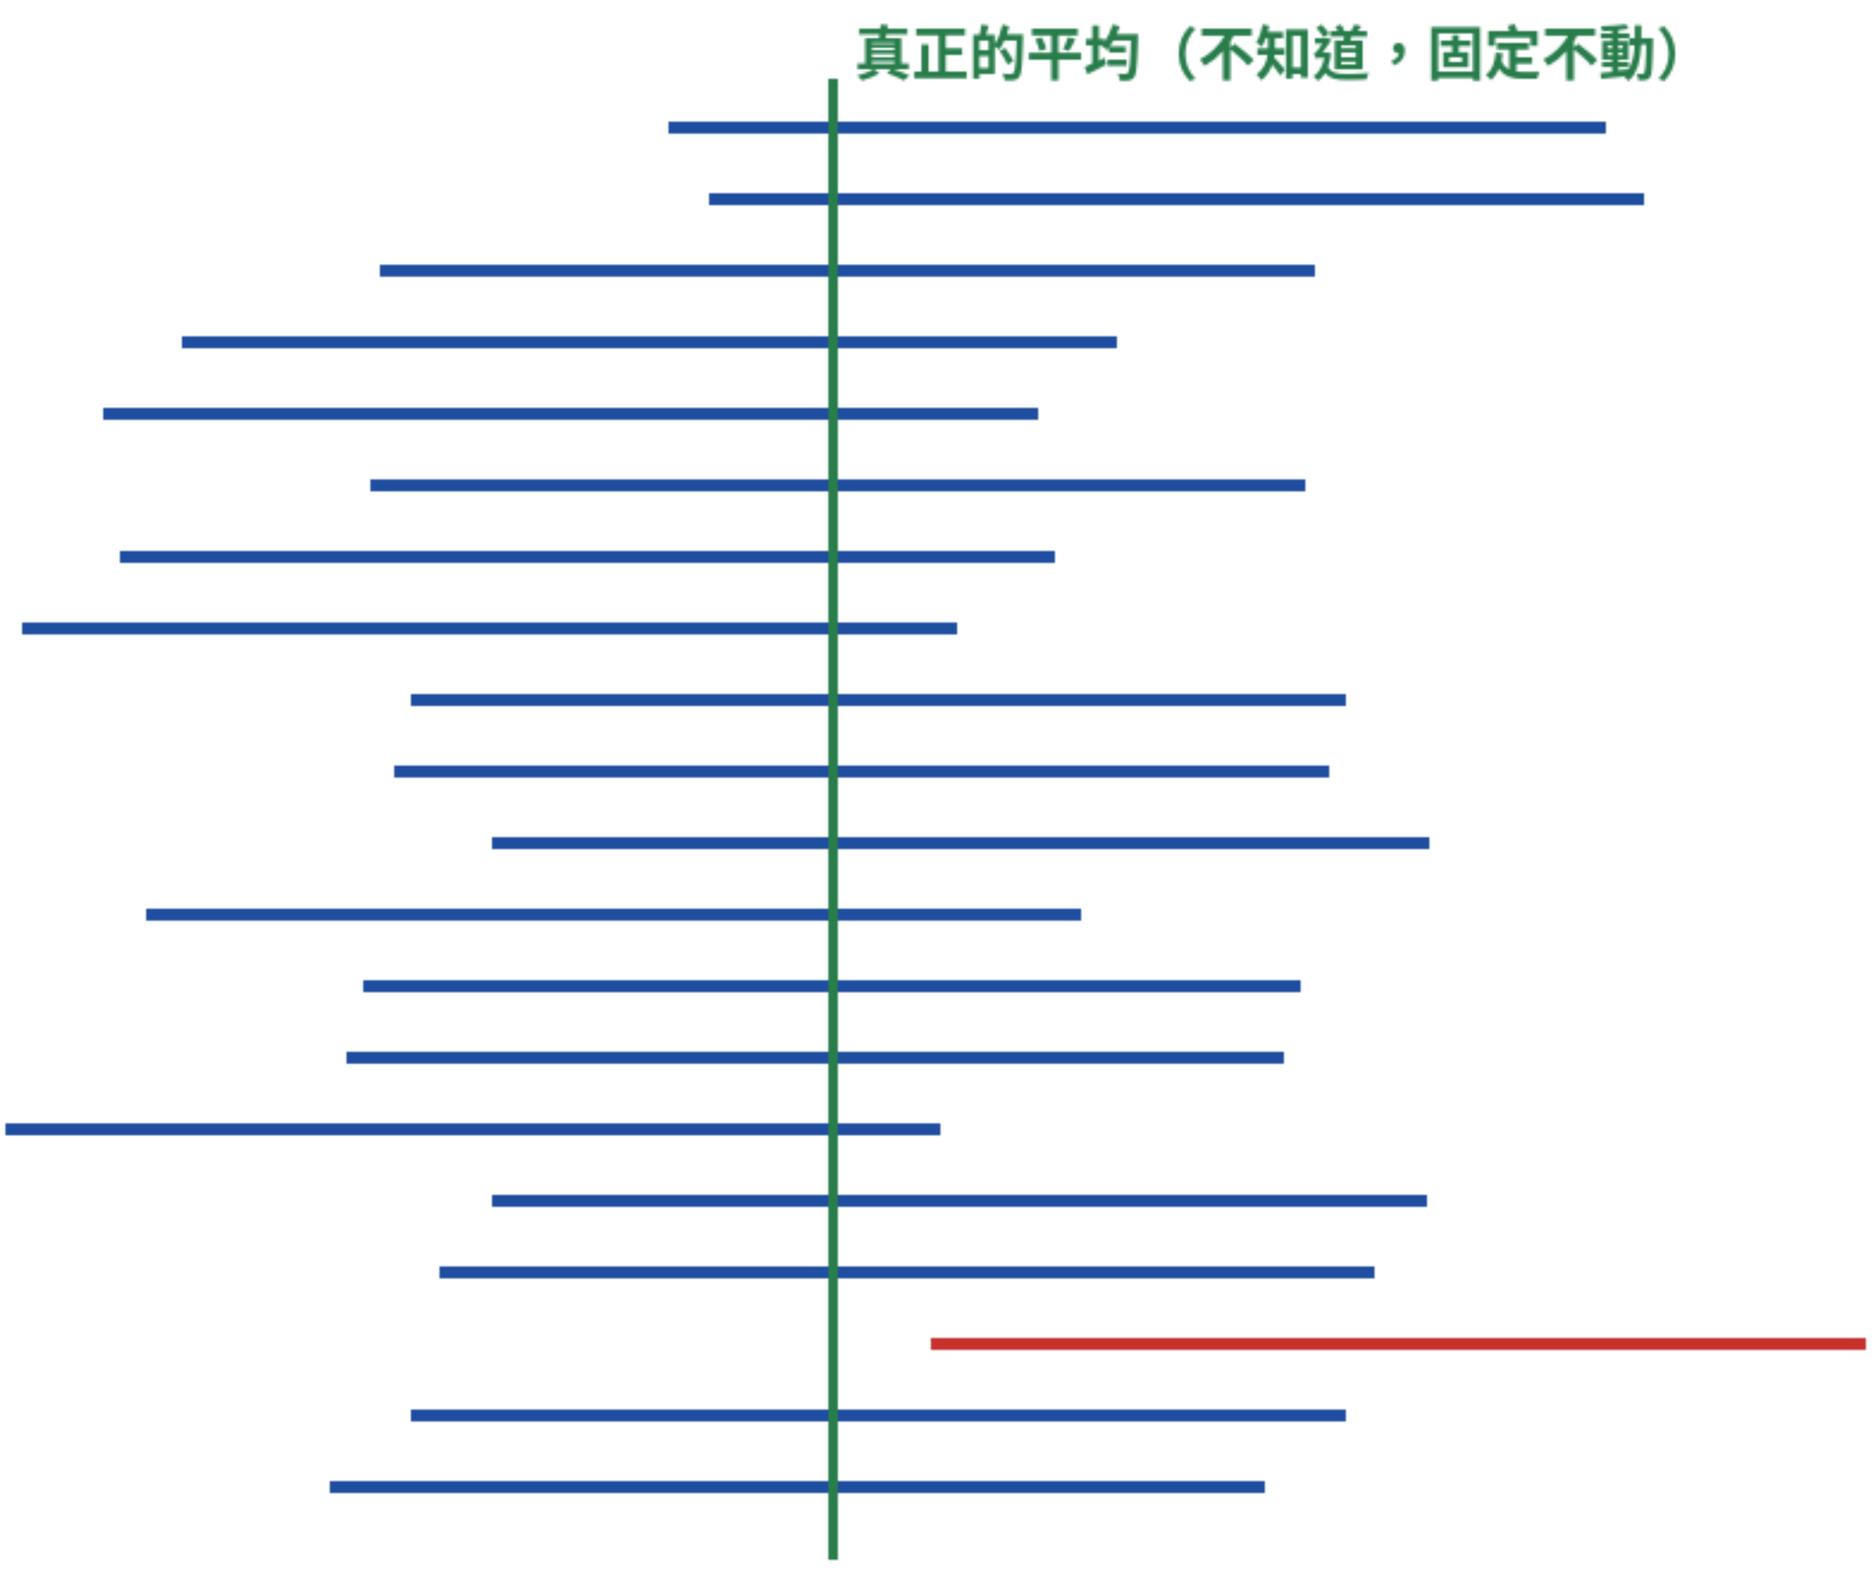


② 樣本變多 → 網變窄、估得更準（95%）



標準誤＝標準差÷√樣本數：樣本變 4 倍，標準誤變一半，區間寬度也變一半

③ 95% 說的是「方法」：重抽 20 次，大約 19 次撈到



這次模擬：20 條中 19 條撈到真值（藍），1 條沒撈到（紅）

每次抽樣，網的位置都會動；真值不會動

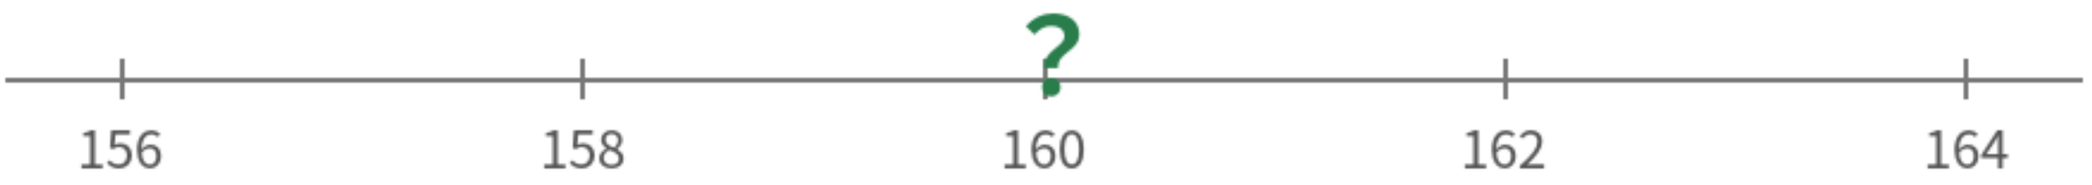
所以不能說「真值有 95% 機率在 [66, 70] 裡」

‹ 回目錄

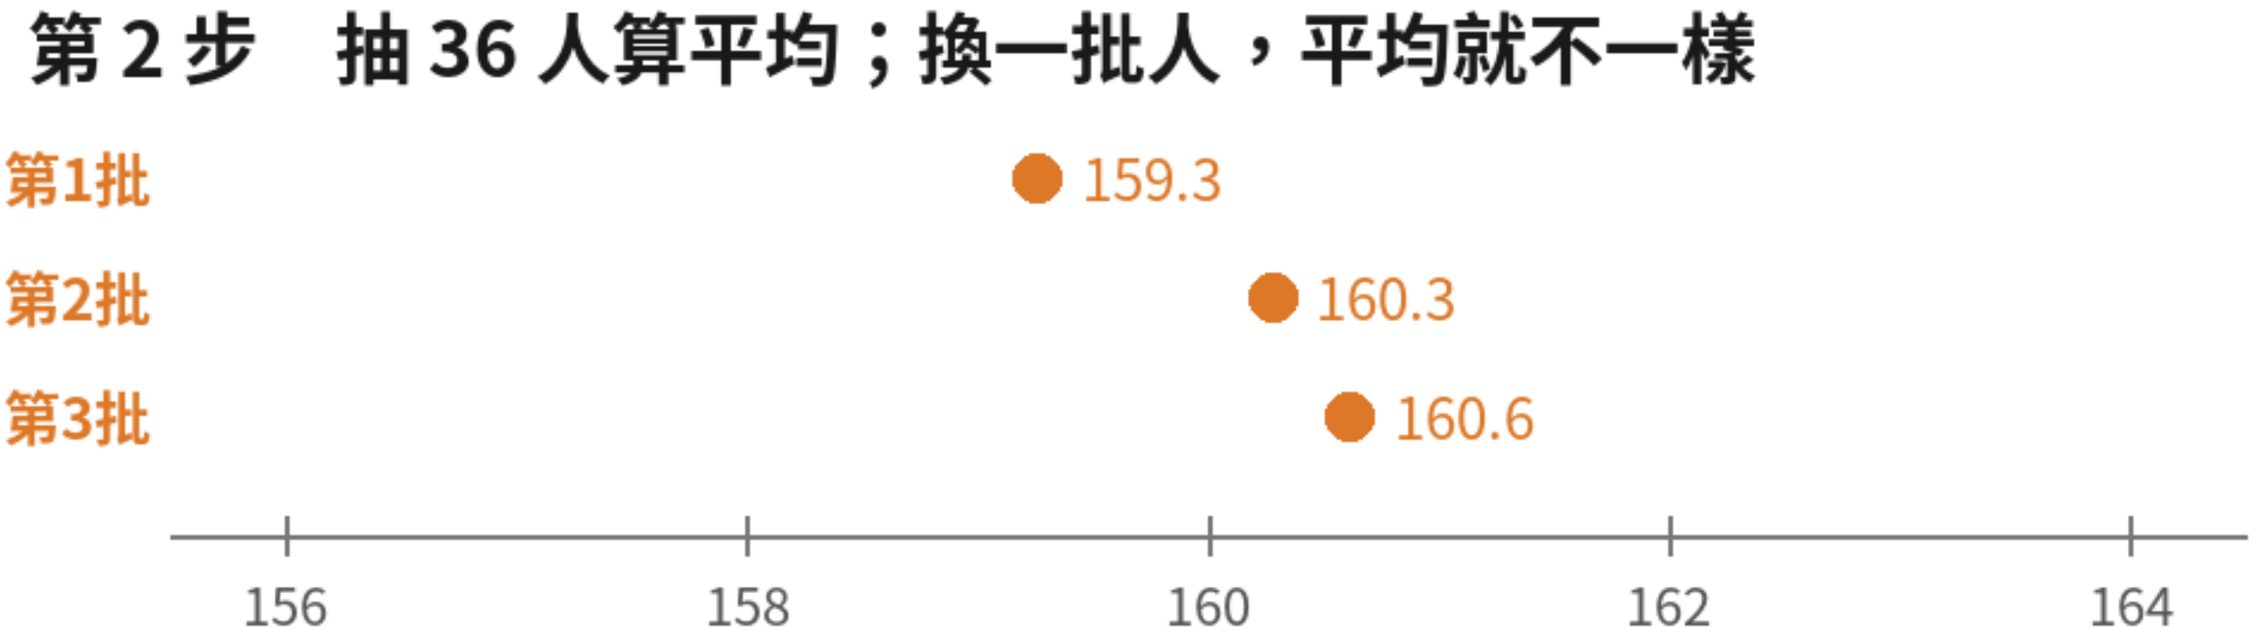
信賴區間怎麼來的：猜全台成年女生平均身高

第 1 步　真正的平均在某處，但我們不知道

不可能量全台灣的人，只能抽一部分人來量

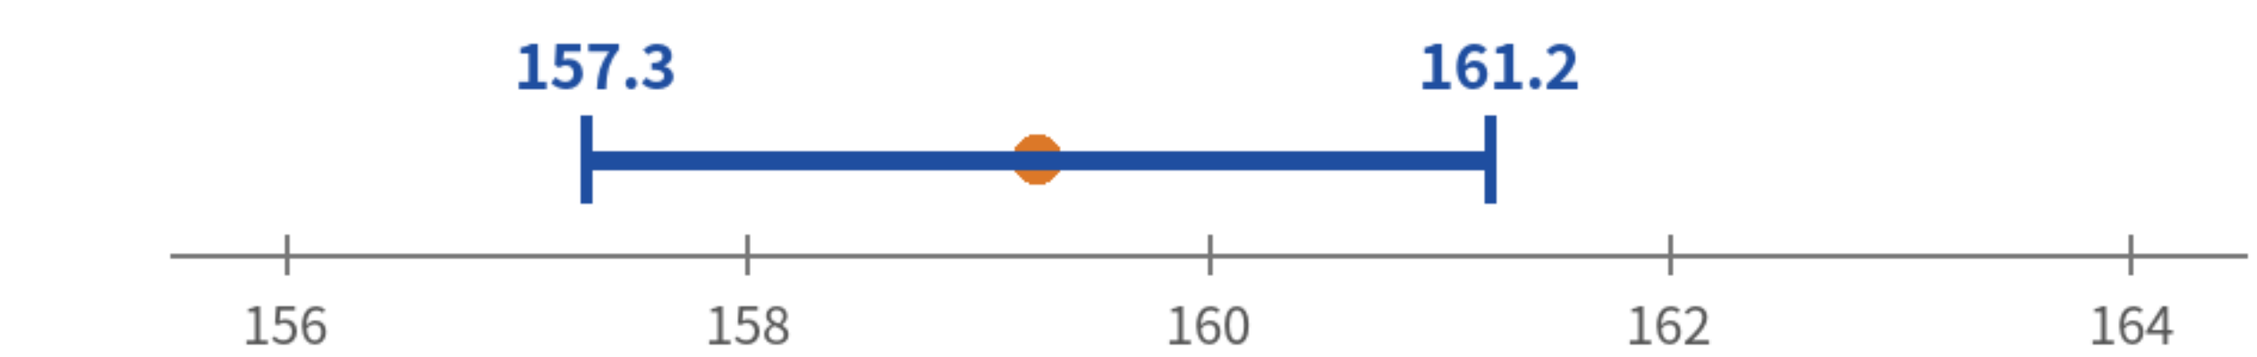


第 2 步　抽 36 人算平均；換一批人，平均就不一樣



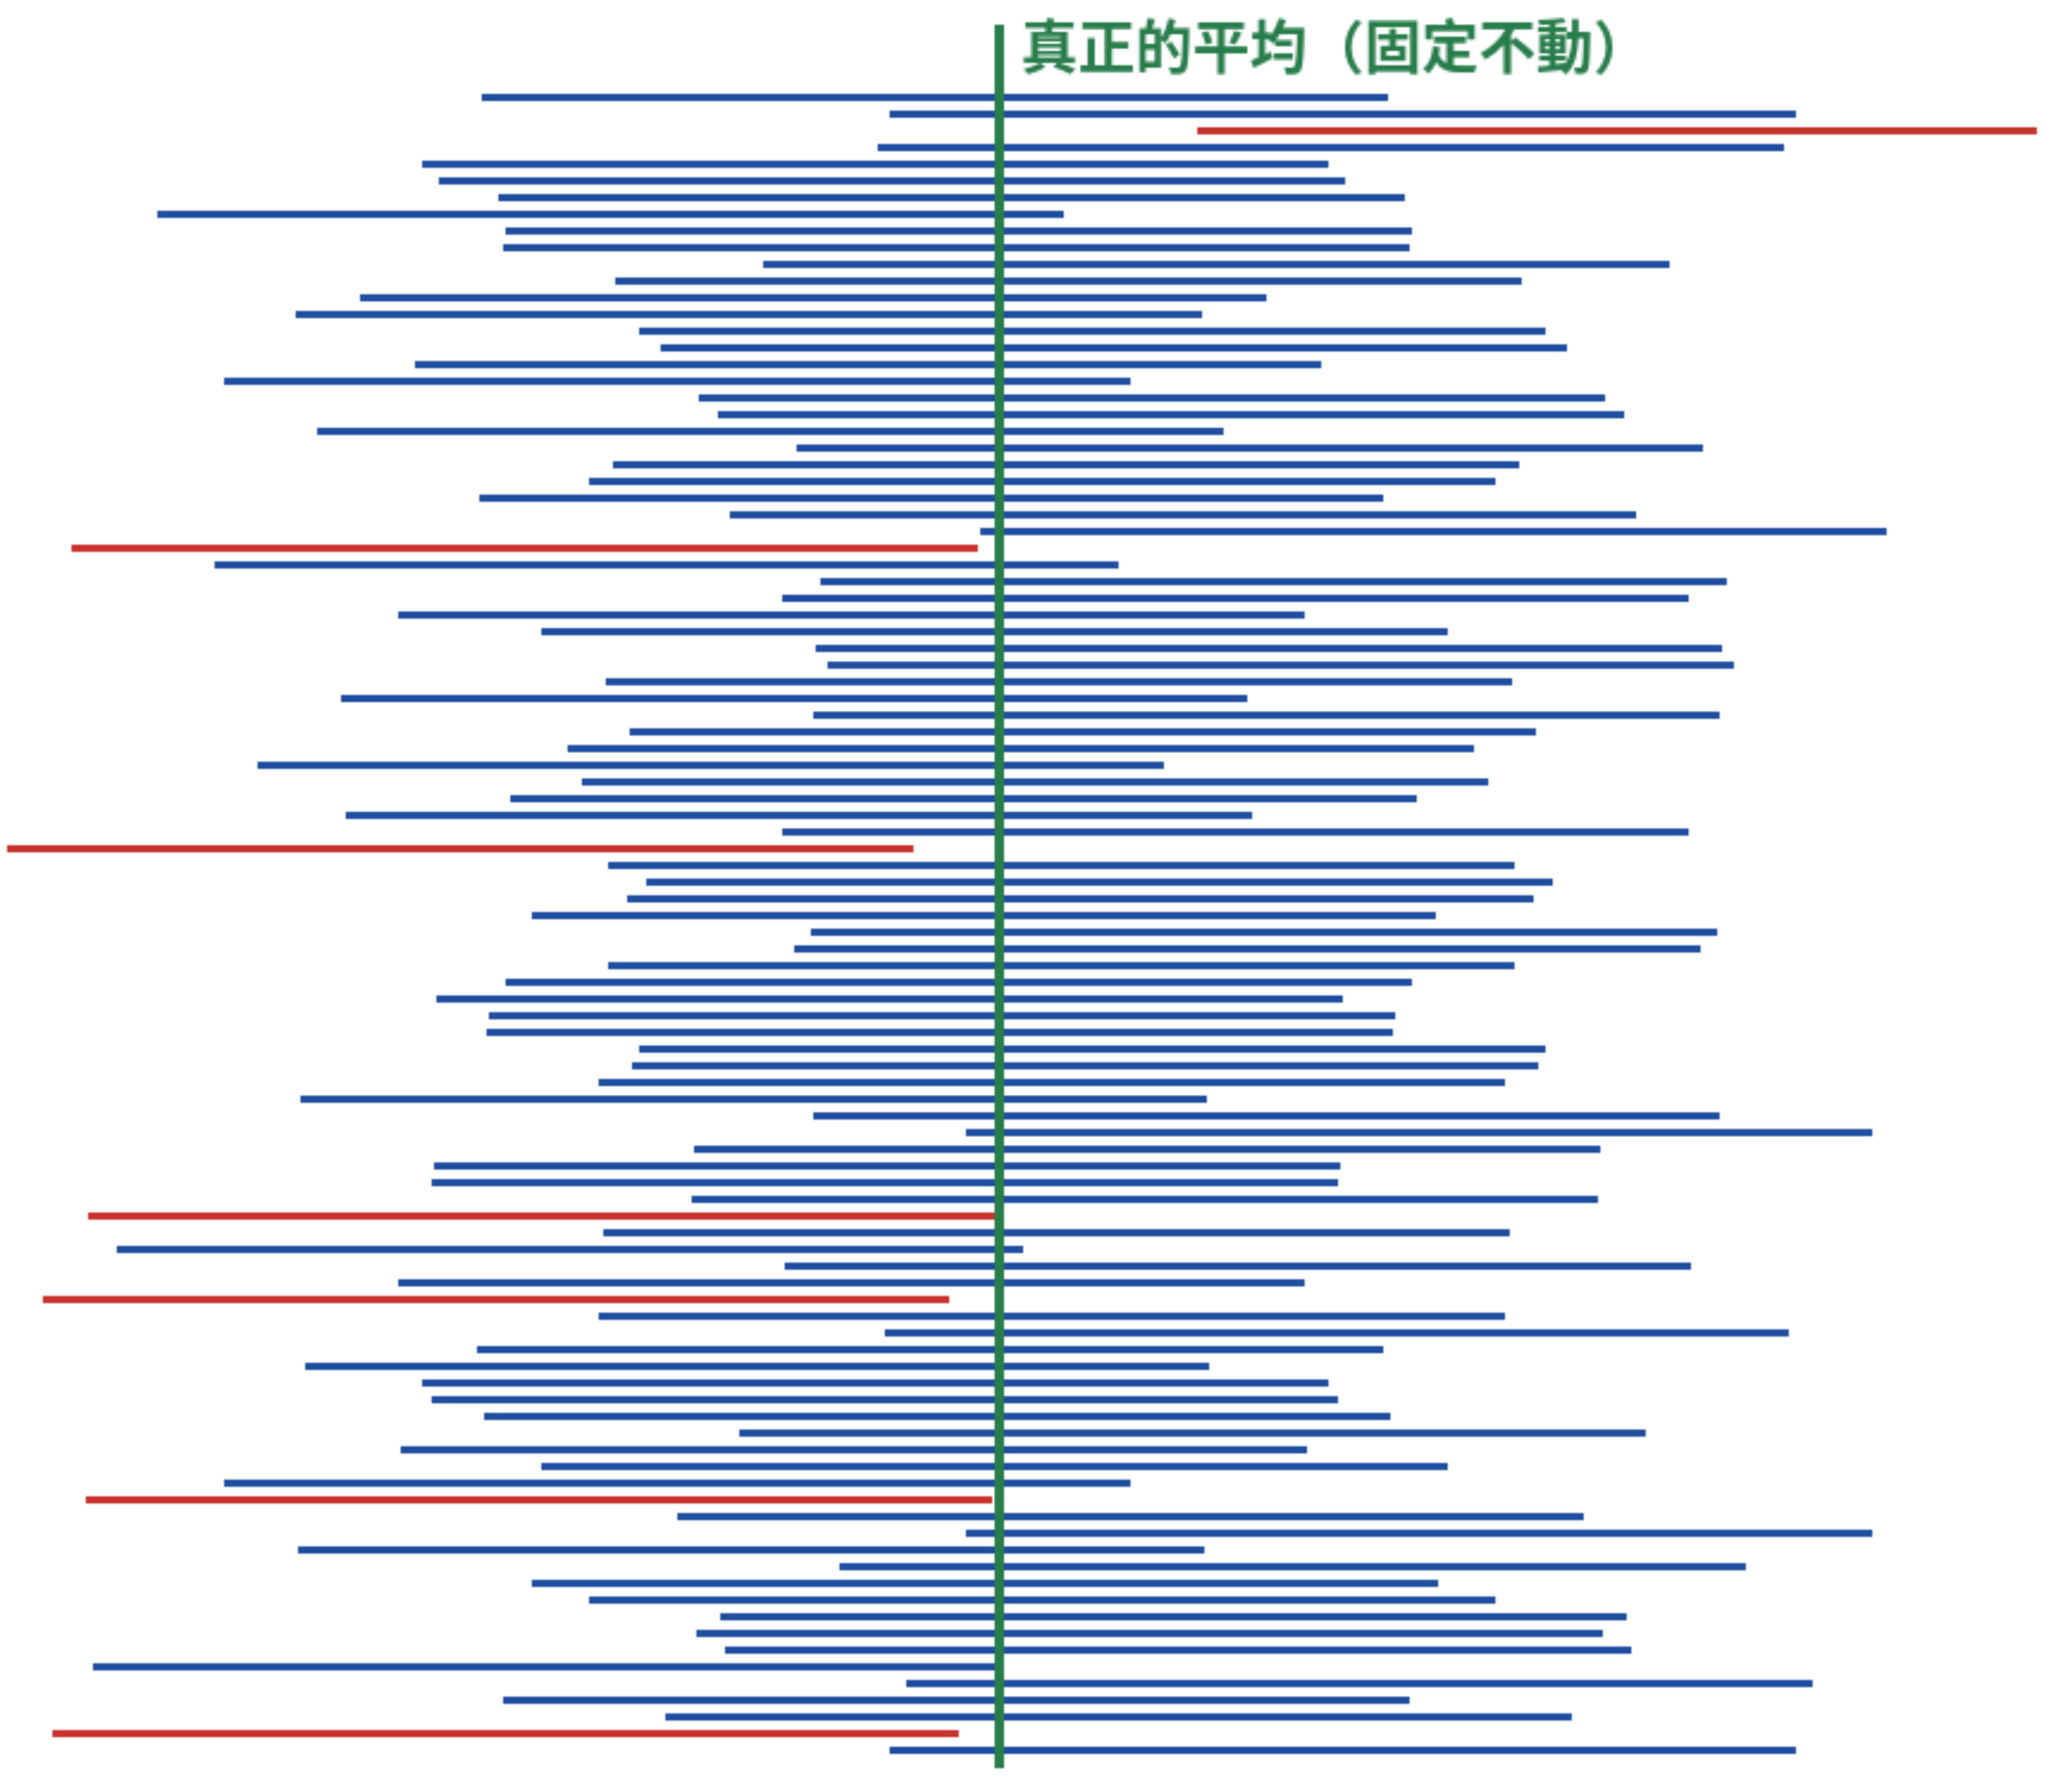
樣本平均會晃來晃去；晃動的幅度叫「標準誤」，這裡約 1 公分

第 3 步　以手上這批平均為中心，左右各撒約 2 個標準誤的網



這張網＝95% 信賴區間 [157.3, 161.2]（平均 ± 1.96 × 標準誤）

第 4 步　100 個人各自抽樣、各撒一張網



這次模擬：100 張網有 93 張撈到真值（藍），7 張沒撈到（紅）

「95%」＝這種撒網方法，長期大約 95% 的網撈得到

示意：真值設為 160、標準差 6、每批 36 人，數字由程式模擬實算

‹ 回目錄