紐約市 MyCity 聊天機器人稽核｜口語研讀摘要

原文：NYC Comptroller《Audit Report on the New York City Office of Technology and Innovation's MyCity System》（IT25PAR20028，2025-12-30，PDF 44 頁）。本摘要為 AI 整理，數字皆已回原文核對；完整譯文見 nyc-mycity-audit_bilingual。

一頁看懂：紐約市花了超過一億美元做「一站式」市政入口 MyCity，審計長稽核後認為成果有限。其中 AI 聊天機器人最值得公部門借鏡：同一題問兩次答案不同；市府自己的每週報告中，48 題該回答的有 23 題沒回答；市府宣稱準確率超過 95%，審計長改用「所有被問的問題」當分母重算，8 月只有 84.8% 至 92.7%。對採購 AI 導覽服務的單位，真正的教訓是：驗收標準要在簽約前寫清楚，包括分母怎麼算、同題要不要一致、測試紀錄要不要留。

一、這篇為什麼值得看

- 它是少數由政府審計機關，針對「政府自己上線的 AI 聊天機器人」所做的正式稽核，有實測、有數字、有機關的反駁，可以兩邊對照著讀。
- 機關的反駁（OTI 回覆）和審計長的評註並列在報告裡，可以看到「驗收爭議」實際怎麼吵：用什麼分母、哪一類交易適用哪個秒數標準、測試工具可不可信。這些都是事後才吵就來不及的事。
- 限制要先講：這是紐約市的網頁入口與文字聊天機器人，不是實體導覽設備，也不是台灣法規環境。可借的是「驗收方法」，不是它的數字門檻。

二、稽核發現了什麼（口語版）

- 整個 MyCity：花了超過四年、約一億美元（超過 120 份協議，約 50 家廠商），另要求再撥約 8,100 萬美元。審計長認為「一站式」目標沒達成，多數入口只是把使用者導去舊網站；只有托育申請真的數位化。
- 專案管理：機關拿不出廠商該交的路線圖、詳細計畫與成本估算，卻已付給該廠商 250 萬美元。審計長結論是監督與合約管理不足。
- 網站效能：托育券行動版得 7 分、桌機版 9 分（滿分 100，Lighthouse 工具）；契約托育行動版 4 分、桌機版 9 分。機關自己的測試也顯示聊天功能載入超過 24 秒。

• 聊天機器人：同一題問兩次，第一次回答「沒有資訊」，第二次給詳細答案；換語序、大小寫（NYC / nyc）也會改變結果；機關自己承認生成式 AI「不一定總是一致」，並說沒有計畫讓它結束測試版。

• 機關七項建議全部不同意（但對第 1、3 項有部分正面回應）。

三、證據與數字（已與原文核對）

項目	原文怎麼說	讀的時候要注意
48 題、23 題	機關每週報告分析了 48 個「聊天機器人本應回答」的使用者問題，其中 23 題（與政府服務和方案有關）沒有回答，5 題與托育有關	這是機關報告中的分析樣本，不是隨機抽樣，原文也說測試結果不能推論到母體；23 / 48 約 48%，是我算的，原文沒寫百分比
95%	機關稱聊天機器人每週準確率持續超過 95%、幾乎沒有幻覺、負面回饋約 2.25%；回覆附錄另寫 95% 至 99%	這是機關主張，不是審計長的發現
85%–93%	審計長指出機關以「已記錄的問答數」當分母；若改用「所提問題數」，2025 年 8 月為 84.8% 至 92.7%	口語常講「約 85% 至 93%」可以，但正式引用請寫 84.8%–92.7%，且只是 2025 年 8 月單月；機關的準確率也未計入「仍有改善空間」的回應
71.4%	7、8 月超過 2,200 個問題，只有 70 人按讚 / 倒讚，其中 50 人（71.4%）給負面；19 人說沒有幫助	回饋只有 70 人，樣本小且是自願回饋；審計長自己強調這是只依回饋計算、未推估
回應時間	機關政策標準：一般頁面平均低於 3 秒、90% 低於 5 秒；聊天機器人 311 問題第 90 百分位為 12.4–16.2 秒；ChatNow 載入超過 24 秒	機關辯稱這類交易應適用複雜交易標準（平均 30 秒、90% 50 秒）；審計長認為點開聊天功能是簡單交易。這就是『分類沒寫清楚』的爭議

兩邊都要記得：機關主張審計長誤解「一站式」的意圖、錯把瀑布式模型當標準、Lighthouse 工具不適合評估大型系統；審計長則回應機關提不出文件。本摘要不替任何一方下最終判斷。

四、對公部門 AI 補助導覽服務驗收的用處

下列是從這份稽核「反推」出來的驗收項目草案，可以寫進契約或驗收規格。數字門檻原文沒有給（除效能秒數外），一律標「待機關自訂」，請採購單位與法務確認後再用。

#	驗收項目	可寫進契約的意思
1	同題一致性	同一題重問多次、以及換語序、大小寫、標點、口語說法，核心答案（金額、資格、日期、窗口）要一致。一致率門檻：待機關自訂。
2	準確率的分母	契約寫明：準確率 =（正確回答數）÷（所有被提出的問題數）。未回答、拒答、轉人工都要有明確歸類，不得從分母剔除。
3	不得排除灰色回答	把『部分正確』『仍有改善空間』的回應如何計分寫清楚，不能只算完全正確的、或只算有記錄的。
4	未回答 / 拒答率	在測試題集中，『本應回答卻回答沒有資訊』的比例上限：待機關自訂。本案中 48 題有 23 題未回答是反面教材。
5	機關自備題庫	題庫由採購單位自備且不事先給廠商，含補助資格、申請步驟、承辦窗口、現任首長等基本事實題，並包含同題多種問法與長輩常用的口語。
6	幻覺與無依據回答	契約定義『幻覺』與『失去依據』（可參考 OTI 的定義：虛假或捏造，或依據資料範圍以外的內容作答），並規定出現時的處理與計算方式。
7	使用者回饋的算法	負面回饋以『有給評價的人』為分母時，必須同時揭露回覆率；不得假設沒回應的人都滿意。
8	紅隊演練與測試紀錄	交付前與定期執行壓力式、刁鑽

		式測試，並留存題目、次數、結果與修正紀錄。審計長指出機關只提出一頁摘要，不足以判斷。
9	回應時間與交易分類	契約先定義哪些是簡單操作、哪些是複雜操作，各自的平均與百分位秒數（可參考原文 3 秒 / 5 秒作對照）；測試結果須有核可簽名。避免日後像本案一樣在 3 秒或 30 秒之間爭執。
10	測試版不等於免驗收	『測試版』免責聲明不得取代驗收標準；契約寫明何時、依什麼條件才能結束測試版。本案機關表示沒有計畫結束測試版。
11	內容更新後回歸測試	後端知識或補助資料更新後，須重跑一致性與準確率測試；保留版本紀錄。審計長認為持續更新後端資料可能造成回答不一致。
12	交付文件與付款掛鉤	需求規格、專案計畫、時程、成本估算列為交付項目，付款與驗收文件掛鉤；變更須有書面變更單。本案審計長最嚴厲的批評就是付了錢卻拿不出文件。
13	獨立測試	準確率與回應時間由採購單位或第三方獨立測試，不採廠商自報數字。
14	多語言與使用者差異	測試必須涵蓋實際使用者會用的語言與說法（原文提到英語非母語、學習障礙者可能受不成比例影響）。

五、還要核對什麼

• 版本：PDF 封面印有「DRAFT」，網頁上卻是正式發布版，檔名為 final-copy；引用前請到審計長網站確認是否有更新版。

• 原文是網頁與文字聊天機器人。若採購的是實體導覽設備，還需另加：語音辨識（噪音、方言、長者口音）、硬體穩定度、螢幕可及性等驗收項目，這份報告沒有提供依據。

• 台灣的政府採購法、個資與資安規範、補助資訊的法律責任，原文都沒有涵蓋，需法務確認；以上驗收項目只是方法借鏡，不是合規意見。

• 數字門檻（一致率、準確率、未回答率）原文沒有給出建議值；要不要引用原文的 3 秒 / 5 秒，也請依實際設備測試。

• 7、8 月的 70 人回饋、48 題分析樣本都是小樣本，不宜當成一般性結論，只適合當成『要求驗收要有大樣本與公開算法』的理由。

• 附錄（機關回覆）只有重點，未逐句翻譯；若要引用機關的論點，請回原文第 1 至 15 頁。