口語研讀摘要

AI 驅動的規則即程式碼（Rules as Code）：公共福利政策實驗

這份摘要依據的版本：Digital Government Hub 刊載的完整報告網頁版全文（Beeck Center for Social Impact + Innovation 與 Massive Data Institute，喬治城大學，2025 年 3 月 24 日），網址 https://digitalgovernmenthub.org/publications/ai-powered-rules-as-code-experiments-with-public-benefits-policy/ 。該頁面沒有 PDF 下載，網頁全文約 1.4 萬英文字詞，PDF 估計約 40 頁以上。另有縮短的摘要頁（網址結尾加 -summary/），內容與完整報告一致但較簡略。完整中英對照見 us-benefits-rules-as-code_bilingual。

一、這篇為什麼值得看

- 它測的正是「讓 AI 讀官方福利文件，再回答人能不能領」這件事，而且是拿真實的美國福利政策（SNAP 食物補助、Medicaid 醫療補助）、七個州的官方手冊來測，不是空談。
- 結論對做服務很實用：AI 把官方文件讀進去之後，「講出來的內容大多正確」，但「講得不完整」，常常漏掉判斷資格需要的條件，而且講話口氣很有把握，使用者不容易察覺。
- 它同時給出解法方向：不要只靠 AI 讀文件，而是先由人把規則整理成固定欄位的結構化範本，再讓 AI 照範本去填，準確度明顯提高。這跟「用人工整理規則」的思路是同一條路。
- 作者是研究機構，不是賣工具的廠商，報告把提示、回應與評分準則都公開了，可檢查。

二、它提出什麼

作者把「政策轉成程式碼」拆成四個實驗，一層比一層深：

- **實驗一：**直接問聊天機器人（ChatGPT、Gemini、GPT-4o），不給文件。結果：答案忽好忽壞，且常沒有出處。
- **實驗二：**把官方政策手冊餵給 AI（用 RAG，也就是先檢索相關段落再回答）。結果：正確性高，但完整性與相關性低。

- **實驗三：**先由人做一份規則範本（例如收入上限、公民身分、工作要求，用 JSON 格式），再讓 AI 去填數字。結果：沒有文件時，數字型規則全錯；有 RAG 文件時，幾乎全對。
- **實驗四：**讓 AI 直接寫判斷資格的程式碼。結果：只丟簡單指令會寫出跑不動的程式；給詳細指示且附政策摘錄最好；把工作拆成多步驟反而錯誤累積。

作者的核心主張有四點：人一定要在迴路中審查；政策文件要做成機器好讀的形式（至少是可複製文字的單一檔案，最好是純文字或網頁）；高風險的福利系統裡，正確與公平要比效率優先；人工整理的範本目前仍然需要。

三、證據是什麼

聊天機器人直接回答（實驗一）

- 三個模型表現沒有重大差異；Medicaid 的回應分數略高於 SNAP。在「現行且符合州別」這一項，收入情境類問題表現最差，模型很難給出現行、正確的收入上限，並與題目中的收入數字比較。
- 大多數回應沒有附出處，無法判斷資訊來自官方文件還是第三方網站。

餵官方文件後（實驗二，六個州，SNAP 與 Medicaid 各 114 則，共 228 則回應）

- 準確性：SNAP 各州平均 4.16 至 4.84 分（滿分 5），Medicaid 各州 4.32 至 5.00 分。
- 完整性：SNAP 各州平均只有 1.74 至 3.16 分；得到 4 或 5 分的回應比例，SNAP 最高 42.11%，密西根州為 0%；Medicaid 最高 26.32%。
- 相關性：中間偏低到中等（SNAP 2.63 至 3.84 分，Medicaid 3.42 至 4.42 分）。
- 作者歸納的常見錯誤：誤解年齡或工作要求、混淆不同族群的標準、過度強調新政策而忽略仍適用的舊政策、遺漏理解資格必需的細節、被申請時程與身分驗證之類的行政資訊帶偏。

用結構化範本（實驗三，喬治亞、賓夕法尼亞、德州的 SNAP）

- 不給文件（一般提示）：收入與資產上限這類數字，三州準確度都是 0%；公民身分與工作要求這類全國一致的規則則是 100%（德州公民身分的居住要求除外）。

- 加上 RAG 後，預先定義的規則幾乎都 100% 正確，只有喬治亞認證期間、賓夕法尼亞扣除額、德州每月給付額等少數項目出錯。作者分析喬治亞的錯誤，原因是政策資料庫裡缺少相關內容，而 AI 會假設答案就在檢索到的文字裡，缺了資料就容易亂補。

寫程式（實驗四，只測喬治亞 SNAP 工作登記資格這一個小任務）

- 簡單提示：變數命名前後不一，程式跑不動。詳細提示：最好，但資格門檻寫死在程式裡、錯誤處理不足。多步驟迭代：摘要漏掉豁免條件，偽代碼又漏掉定義，錯誤一路累積。

讀證據時要記得的限制：作者自己說明，人工評分只有兩位、而且不是各州政策專家；評分以 1 至 5 分的人工判斷為主；測試的模型是 2024 年的 GPT-4o、GPT-3.5 與 Gemini 1.5 Flash，模型之後已更新；實驗四只有一個任務。因此這些結果適合當作「方向與風險」的依據，不宜當成精確數字直接引用。

四、對公部門 AI 補助導覽服務的用處

1. 定位：導覽設備講什麼、不講什麼

- 文獻顯示，AI 單靠讀官方文件回答資格問題，容易「講對一部分、漏掉條件」。因此設備的定位比較穩的說法是「協助民眾找到可能適用的補助與申請入口」，而不是「告訴你一定能不能領」。
- 涉及金額上限、身分條件、扣除項目的判斷，建議以固定規則計算，或明確標示「僅供參考，以承辦單位審核為準」，並提供承辦窗口。
- 作者提醒聊天機器人會用有把握的口氣說錯話。設備回答時，建議每一則都附上依據的條文或文件名稱與更新日期，讓民眾與工作人員能追溯。

2. 知識庫準備：先整理資料，再談 AI

- 先建立「規則範本」：每一項補助整理成固定欄位，例如適用對象、年齡、戶籍或居住條件、所得或資產門檻、需檢附文件、申請窗口、生效與截止日期。實驗三顯示，有範本加上正確來源文件，準確度大幅提高。

- 來源文件要先整理成機器好讀：把分散的公告、附件與網頁，彙整成可複製文字的單一檔案或網頁，掃描圖檔要先轉成文字。實驗二指出，掃描版 PDF 與分散文件是主要障礙。
- 每條規則記錄出處與生效日期，並規劃更新機制。報告提到政策會定期變動，知識庫要有人負責維護，也要檢查資料庫是否漏了某項條件（實驗三的喬治亞認證期間錯誤就來自資料庫缺資料）。
- 先準備測試題：把各項補助常見的情境問題與標準答案由熟悉政策的人寫好，每次更新資料或換模型後重測。作者也指出，缺乏專家設計的測試案例是他們研究的限制。

3. 互動流程：把「問條件」設計成逐項確認

- 實驗一看到，請模型逐項說明個別資格標準，比一次問「所有資格標準」更完整；實驗二中喬治亞 SNAP 的最低分範例，也出現在「誰有資格？」這類總括式問題。因此互動流程適合設計成一步一步詢問（年齡、居住地、所得、身分別），而不是讓 AI 自由回答一大段。
- 每個步驟用固定規則判斷，AI 負責把結果用口語說明，並列出「還缺哪些條件需要確認」。
- 遇到資料庫沒有的情況，要讓系統明確回答「這部分我沒有資料，請洽承辦窗口」，而不是讓 AI 自行推測。實驗三顯示，缺資料時 AI 更容易編造答案。
- 保留人工複核與回報的管道，例如民眾可標記「答案不對」，工作人員定期檢視。

五、還要核對什麼

- 這是美國的 SNAP 與 Medicaid，制度、語言與文件格式都和臺灣不同。結果只能當作方法與風險的參考，不能直接套用數字。要判斷是否適用，需要用實際要上架的補助文件，自己做一輪小型測試。
- 報告測的是 2024 年的模型；新模型的完整性是否改善，報告沒有說，需要另行測試，不能假設已經解決。
- 原報告正文有一處與自己的表格不一致：正文寫喬治亞 Medicaid 相關性為 3.84（76.84%），表 18 為 3.42（68.42%）。本摘要以表格為準，引用前請對照原文。
- 報告沒有測試中文文件，也沒有測試對老年使用者的口語互動，這兩點要另外驗證。

- 報告沒有說明「人工結構化規則」的人力成本；實務上要由誰整理、多久更新一次，需要進一步評估。
- 報告提到 Georgetown 的作者團隊持續進行相關研究，並公開實驗資料（提示、回應、評分）。若要引用或延伸，建議到原報告附錄取得資料，並確認授權與引用方式。
- 廠商若宣稱「AI 直接讀政策文件就能正確回答資格問題」，可以用本報告的結果請對方說明：如何處理遺漏條件、是否顯示出處與更新日期、資料庫缺資料時如何回應、有沒有專家設計的測試集與成果。