淡江大學

管理學院資訊管理學系碩士在職專班

碩士論文全文工作稿

AI 輔助語意檢索與問答

於就業服務知識文件之成效研究

與字面關鍵字查找之比較

【待確認：工作題名，尚未由本人與教授定稿】

研究生：羅靜娟

【待確認：指導教授鄭元成博士、陳智揚博士之掛名方式與順序】

全文工作稿整理日期：2026 年 10 月 23 日

【待補：正式提交年月、口試與審定所需表件】

全文工作稿使用說明

本稿整合已能依據現有材料完成的論文內容，供研究者逐章閱讀、修改並與指導教授討論。正文以黑字書寫；紅字「待補」表示尚缺資料或證據，紅字「待確認」表示研究方法、題目或格式尚未定案。黑字並不表示已獲教授審定，其中以「建議」「規劃」表述的方法仍屬待決定方案。

本稿包含中英文摘要、誌謝位置、目錄、圖表目錄、五章正文、參考文獻及五項附錄。第四章的開發紀錄具有明確來源；正式成效資料尚未取得，第五章因此不預填 AI 優於字面查找的結論。稿件日期為 2026 年 10 月 23 日，屬紫區全文工作稿，不是可直接送審的定稿。

原先題目曾使用「隱性知識外化文件」一詞；目前文件庫以公開就業服務資料為主，其形成過程未必能證明隱性知識外化。本稿採能對應現行設計的工作題名，保留研究者最初對口語查詢與資料再使用的關切。

【待確認：工作題名為「AI 輔助語意檢索與問答於就業服務知識文件之成效研究——與字面關鍵字查找之比較」。正式題名及是否保留「隱性知識外化」須由研究者與教授確認。】

【待確認：本稿依既有老師版偏好使用 A4、12 點正文、1.5 倍行距及分節頁碼。Word 指定標楷體與 Times New Roman；本機未安裝標楷體，PDF 中文暫以芫荽楷體呈現。正式繳交前須依學校範本核對字型、封面、頁邊界、指導資訊及必要表件。】

中文摘要

就業服務知識文件包含制度名稱、適用條件與程序說明，使用者卻可能以日常口語描述需求。當查詢用語與文件表述不同，即使資料已存在，使用者仍可能無法直接找回所需內容。本研究由研究者使用 NotebookLM 進行來源問答的經驗出發，改以可控制語料與流程的自建平台，探討字面查找與完整 AI 語意檢索問答在同一文件庫上的表現。

本研究區分 A、B 兩種查找方式。A 組採連續原字串比對，不自動拆詞或擴展同義詞；B 組包含查詢改寫、向量檢索、依據來源生成回答、引用及必要的釐清。評估設計以找回正確支持資料為兩組共同面向，並對 B 組另行檢查回答正確性、完整性、引用支持與資訊不足處理。兩組比較屬完整工具層次，不把差異全部歸因於向量模型。

目前已建立開發平台與 1,781 個可檢索項目的開發語料，並保存工程驗證與部分案例紀錄；正式語料、題組、操作規程及人工評分仍待凍結。開發觀察用於說明工具行為與來源缺口，不作為正式成效結論。

【待補：正式研究方法確認後，補入研究題數、資料期間、評閱與分析方法；完成第四章後補入主要結果與結論，並刪除此工作稿狀態說明。】

關鍵詞：字面查找、語意檢索、檢索增強生成、就業服務知識、引用支持。

Abstract

Employment service documents express eligibility conditions and procedures using institutional terminology, while users may describe their needs in everyday language. This study examines how existing knowledge can be retrieved and used when the wording of a question differs from that of the source documents. Motivated by source-based question answering with NotebookLM, the study develops a controllable research platform rather than assuming that a similar interface reproduces the commercial product.

Two approaches share the same document collection. Approach A performs exact contiguous string matching without automatic tokenization or synonym expansion. Approach B combines query rewriting, dense retrieval, source-grounded answer generation, citations, and clarification when needed. Retrieval of adequate supporting evidence is the shared evaluation focus. Answer correctness, completeness, citation support, and handling of insufficient information are evaluated separately for Approach B. Any observed differences concern the complete systems and cannot be attributed solely to vector retrieval.

A development platform and a collection of 1,781 retrievable items have been established. Engineering checks and selected development observations are documented. The formal corpus, question set, operating protocol, and human assessment have not yet been finalized; development observations therefore do not establish comparative effectiveness.

【待補：After formal evaluation, replace this working-draft status with the confirmed method, principal findings, and conclusions. Do not report invented sample sizes or effects.】

Keywords: literal search; semantic retrieval; retrieval-augmented generation; employment service knowledge; citation support.

誌謝

【待補：由研究者以本人經驗撰寫誌謝，確認指導、協助與支持者的姓名及具體貢獻。本稿不代寫尚未發生的口試、研究參與或完成歷程。】

目錄

全文工作稿使用說明.....I
中文摘要.....II
Abstract.....III
誌謝.....IV
第 1 章 緒論.....1
1.1 研究背景.....1
1.2 研究動機與問題意識.....2
1.3 研究目的與研究問題.....3
1.4 研究範圍與界線.....4
1.5 名詞界定.....4
1.6 研究流程與論文結構.....5
第 2 章　文獻探討.....6
2.1 知識再使用：已寫下的內容能否被找回.....6
2.2 詞彙落差與資訊需求的表達.....7
2.3 字面查找、向量檢索與檢索增強生成.....8
2.4 完整系統的評估：檢索、回答與引用.....10
2.5 文獻缺口與本研究定位.....12
第 3 章 研究方法與平台設計.....14
3.1 研究設計.....14
3.2 共同文件庫的建置與來源管理.....14
3.3 兩組工具與系統架構.....16
3.4 題目集與參考答案.....19
3.5 查詢與執行程序.....20
3.6 評估指標與分析方法.....21
3.7 品質控制與可追溯性.....23
第 4 章 平台實作與研究結果.....24

4.1 本章資料的性質.....24
4.2 已完成的平台實作與工程檢查.....24
4.3 開發案例的觀察與限制.....25
4.4 正式題組與樣本概況.....26
4.5 研究問題一的比較結果.....27
4.6 研究問題二的回答與引用結果.....28
4.7 綜合討論.....28
第 5 章 結論與建議.....29
5.1 研究工作目前完成的內容.....29
5.2 研究問題的正式結論.....29
5.3 平台設計與實務意涵.....30
5.4 研究限制.....30
5.5 後續研究與完成順序.....31
參考文獻.....32
附錄一 題目與參考答案紀錄表.....34
附錄二 執行與評閱紀錄表.....35
附錄三 版本與來源追溯.....36
附錄四 待完成事項與論文定稿條件.....37
附錄五 AI 協作與研究責任說明.....38

圖目錄

圖 3-1 共同文件庫與兩組查找方式.....18

公式目錄

本文目前未使用編號公式，因此無公式條目。

表目錄

表 2-1 文獻線索與適用界線 12

表 2-2 工作版研究問題與文獻連結 13

表 3-1 共同語料與版本狀態 16

表 3-2 評分規準草案 22

表 4-1 開發驗證紀錄及可支持的主張 25

表 4-2 正式研究資料概況待填表 27

表 A-1 題目紀錄欄位 34

表 A-2 執行與評閱欄位 35

表 A-3 定稿前的必要工作 37

第1章 緒論

1.1 研究背景

就業服務工作中的資訊需求，經常由一個生活情境開始。詢問者可能說明自己剛進公司、需要照顧孩子，或想知道離職後可以申請什麼協助；提供答案所需的依據，卻分散在法規條文、施行規定、行政說明與官方問答之中。查詢者必須把日常語言轉成制度使用的名詞，再判斷找到的文件是否涵蓋自己的條件。文件已經上網，並不代表每一個人都能從自己的問題順利抵達適用的內容。

研究者最初的疑問來自工作與學習資料的累積：曾經保存、閱讀或整理過的資料，日後需要使用時，未必記得原先的標題與用詞。即使知道答案可能就在某一批資料內，也可能反覆更換關鍵字，才能找到想要的段落。這種經驗使研究者關心的焦點從「如何增加更多文件」，轉為「已存在的文件能不能用自己的話找回」。此一經驗是研究動機的來源，尚不是經抽樣驗證的使用者行為結論。

研究者曾以 NotebookLM 作為口語提問與來源問答的體驗起點。相較於先猜測文件用語，直接描述問題、取得整理後答案並回查來源的方式，呈現了另一種使用資料庫的可能性。為了使文件範圍、查詢流程、模型設定與評估紀錄可以被控制，本研究後續改以自建平台作為研究工具。自建的目的在於讓比較條件可追溯，並不表示商用產品已被複製，也不以介面相似作為品質相同的證據。

本研究將上述問題放在繁體中文就業服務知識文件的情境中，區分兩種資料使用方式。第一種是使用者輸入一段文字，系統找出字面完全相符的位置，再由使用者閱讀與判斷；第二種是系統以口語問題為起點，進行查詢改寫、語意向量檢索、答案整理與引用呈現。兩種方式共用同一份文件庫，藉此避免把來源多寡的差別誤認為搜尋方式的成效。

1.2 研究動機與問題意識

1.2.1 從猜測用詞到表達需求

字面查找適合使用者已知道名稱、條號或特定片語的情況。例如，若希望確認某個明確詞彙出現在哪些段落，逐字查找的條件清楚，結果也容易核對。但使用者若輸入的是一整句口語問題，句子未必以相同形式出現在文件內。此時的零命中，表示沒有相同連續字串，不能直接解釋成文件庫沒有相關資訊。

研究者提出「育嬰假如何請」與「育嬰」的差異，正是在說明這個疑問：使用者想問的是申請程序，文件可能以制度名稱、申請要件與條文分項書寫。完整句子找不到、縮短詞語後出現大量結果，並不矛盾；前者反映字面條件較嚴，後者增加候選範圍，卻把篩選與理解的工作留給使用者。開發時已觀察到這種現象，但單一例子不足以決定兩組整體成效。

Furnas 等人（1987）的詞彙問題研究指出，不同人對同一對象的命名未必一致；Belkin（1980）則提醒，使用者有時連資訊需求本身都尚未能精確表達。這些文獻為研究動機提供概念背景，但無法直接證明特定中文平台的實際成效。因此，本研究仍須在明確文件範圍與操作規程下，逐題核對查找結果。

1.2.2 從取回資料到有依據的回答

研究者期待的語意查詢，不只是在畫面上出現一些意思相近的段落，而是能依問題整理出可理解的答案，指出依據，並在條件不足時提出必要的釐清。只比較段落排名，無法完整回應這項期待。相對地，回答流暢也不代表正確；若沒有找到適用的條文，或引用內容無法支持所作的判斷，流暢的回答仍可能誤導。

因此，本研究把「找回支持資料」與「根據資料回答」分成兩個需要觀察的層次。A 組提供字面命中位置與來源，B 組提供語意取回的候選內容與生成回答。共同的比較重點是正確支持資料是否被找回；B 組另須接受回答正確

性、完整性、引用支持與資訊不足處理的檢查。A 組沒有自動生成答案，不應在生成品質項目被記為零分。

1.2.3 建立可控制且不預設勝負的研究工具

若每次測試都使用不同文件、不同模型或不同查詢規則，便很難知道結果差異來自何處。自建平台可保留語料版本、提示詞、模型識別、查詢序列與輸出紀錄，讓同一題的結果能被追溯。這項可控制性，是本研究由商用工具體驗走向研究平台建置的重要理由。

然而，工具可控制不代表研究天然公平。若 A 組只能送入完整口語問題一次，B 組卻可改寫與追問多次，研究可能只證明兩組被給予不同的操作機會。正式比較應分開呈現首次原句查詢與按預定規則完成的查找任務，並在測試前固定換詞、追問與停止條件。研究問題應容許 A 組在明確詞彙查找中表現良好，也容許 B 組在語意誤判或證據不足時失敗。

1.3 研究目的與研究問題

本研究的目的，是在同一份繁體中文就業服務文件庫中，建立字面查找與完整 AI 語意檢索問答的可追溯比較方式，說明兩者何時能找回正確依據、何時失敗，以及生成回答是否受到來源支持。研究並不以證明 AI 必然優於所有搜尋工具為目標，也不把本平台的字面查找當作一般搜尋引擎的代表。

【待確認：以下研究問題為依目前紫區方向整理的工作版，須由研究者與指導教授確認後凍結。】

RQ1：在預先訂定的查詢操作規則下，字面查找與完整 AI 語意檢索問答找回正確支持資料的表現與失敗差異為何？

RQ2：完整 AI 語意檢索問答的回答，在正確性、完整性、引用支持及資訊不足處理上，呈現何種表現與限制？

RQ1 的分析單位以資訊需求題目為核心，同一題在兩組之間形成配對；RQ2 針對 B 組的回答與引用進行核對。若後續納入真人使用者，使用時間、負擔與滿意度可作為新增問題，但必須另有相應的研究設計與資料，不由離線測試直接推論。

1.4 研究範圍與界線

研究材料目前以公開就業服務相關法規、說明與問答等文字內容為開發基礎。研究所處理的是已匯入共同文件庫的內容，不是全網搜尋。文件庫外的資訊即使在政府網站存在，也不應被視為本平台一定能回答的內容；正式語料範圍與納入、排除規則須於資料清理後固定。

A 組採本研究操作化的 Ctrl＋F 式連續字串查找。此名稱用以描述其逐字匹配機制，並不主張它與每一套軟體的 Ctrl＋F 設定完全一致；本平台大小寫敏感，標點、空白與全半形均會影響比對。B 組則包含語言模型改寫、向量檢索、生成與多輪互動，兩組是完整工具層次的比較。即使 B 組較佳，也不能將差異全部歸因於向量檢索。

NotebookLM 僅作為研究起點與功能體驗參照，未列為正式比較組。研究亦不評定 Google、勞動部、勞動力發展署或各地方就業服務網站的整體品質。這些服務可能採用不同的索引、排序與語意功能，需各自調查，不能用本研究 A 組的結果概括。

【待補：正式語料收錄日期、文件類型與各類數量、主管機關範圍、適用地區、版本與有效性核對，以及研究執行期間。】

1.5 名詞界定

本研究所稱「字面查找」，是查詢字串必須在單一標題或內文欄位中連續且完全相同地出現，系統才回傳命中項目。其不包含系統自動拆詞、同義詞擴

展、布林 OR 回退或相關性排序。使用者改用另一個詞查詢，屬於下一次操作，而非系統暗中放寬原來的匹配條件。

「語意向量檢索」指將問題與文件內容表示為向量，再依相似程度取得候選段落的程序。「完整 AI 語意檢索與問答」則是本研究 B 組的整體流程，除向量檢索外，還包含改寫、答案生成、引用與必要的釐清。二者不可混用為完全相同的技術範圍。

「正確支持資料」指經評閱者確認，能支持題目所需事實、條件或程序的語料項目；僅出現相關詞彙尚不足以構成支持。「引用支持」指回答中的實質陳述與其標示的來源內容之間存在可核對的支持關係；來源編號有效，並不等於陳述一定正確。

「資訊不足」包括問題缺少決定適用規則所需的條件，以及文件庫沒有足夠內容作答，二者須分別處理。前者可以提出釐清問題；後者應說明現有來源的限制。「知識外化」在本稿僅作為知識管理背景概念；公開法規的存在不能直接證明個人隱性知識已完成外化。

1.6 研究流程與論文結構

研究流程由確認資訊需求與文件範圍開始，依序進行來源盤點、共同語料建置、兩組工具實作、開發測試、正式題組與評分規準制定、版本凍結、正式執行及結果分析。開發測試中已出現並用來修正系統的題目，必須與正式評估題目分開保存，以免把已知案例的改善誤當成對新問題的能力。

全文共五章。第一章界定研究動機、目的與範圍；第二章整理詞彙落差、資訊需求、檢索生成與評估文獻；第三章說明研究方法與現行工具，並標示待定規程；第四章先呈現可核對的開發證據，再保留正式結果的寫作位置；第五章討論目前可成立的設計意涵、限制與後續研究，正式成效結論則等待實驗資料。

第2章 文獻探討

本章整理支撐本研究問題的四條文獻線索：知識再使用的背景、詞彙落差與資訊需求的表達、字面查找與 AI 語意檢索問答的機制差異，以及完整檢索問答系統的評估方式。各節引用均限定於原研究的情境與範圍；本研究場域中是否出現相同現象，列為本研究待檢驗的問題，而非由文獻直接推定。凡標示 [待補] 者，表示該處仍需補充證據或待研究設計確認。

2.1 知識再使用：已寫下的內容能否被找回

2.1.1 知識創造理論作為背景

Nonaka（1994）援引 Polanyi 的區分，將知識分為可用形式化、系統化語言傳遞的顯性知識，以及具個人性質、難以形式化且深植於行動與特定情境的隱性知識；並以兩者的相互轉化區分社會化、外化、結合與內化四種模式（Nonaka, 1994）。組織層次的知識創造，被描述為四種模式持續循環、由個人向群體與組織擴展的歷程（Nonaka, 1994）。

本研究採用此一架構，僅作為理解「知識寫成文件之後如何再被使用」的背景，不驗證該模型，也不新增知識轉化階段。本研究關心的是文件已經存在之後，使用者能否以自己的語言把它找回並正確使用；這個問題與原典所談的外化歷程相關，但並不相同。

2.1.2 本研究材料與「外化」的距離

本研究規劃使用的共同文件庫，以公開的就業服務法規、行政函釋與官方問答為主。這些文本係依立法或行政程序發布，其形成過程與組織成員把個人經驗表述為文件的外化歷程並不相同；公開法規本身不能直接作為隱性知識外

化的證據。因此，本章以「已寫下、供他人查閱的就業服務知識文件」作為中性指稱，並將知識創造理論的角色限定於研究背景。

【待補：正式題目若保留「隱性知識外化文件」，須另選具外化歷程證據的文件，並在第三章說明其形成過程；若改採公開就業服務文件，題目用語須與教授確認後同步修正第一章與本節。】

2.2 詞彙落差與資訊需求的表達

2.2.1 詞彙問題的實證

Furnas 等人（1987）以多個應用領域的命名資料，說明不同人為同一對象選擇的詞彙往往不一致。當系統依賴單一名稱作為入口，使用者可能因用詞不同而無法接近原本存在的內容；該文因此討論以多種別名改善存取的可能性。

此一結果來自一般命名任務，討論重點是「單一存取詞」的設計情境，不能泛指所有關鍵字查詢，也不直接證明就業服務文件與其使用者之間存在相同幅度的落差。它對本研究的意義在於說明：查找成功與否，不只取決於文件是否存在，也取決於查詢者的用語能否與文件端的表述相遇。

2.2.2 大型全文檢索情境中的實測

Blair 與 Maron（1985）評估法律文件的全文檢索系統，指出使用者對取回完整度的認知與實際評估可能存在落差。其問題之一，是查詢者難以預先猜測相關文件可能使用的不同表述。此研究提醒，找到若干看似合適的文件，並不表示所有必要證據都已被找回。

需要強調的是，這項研究的對象是 1980 年代的英文法律文件與布林式全文檢索系統，查詢由受過訓練的人員組合多個檢索詞與運算子完成。它不是瀏覽器或文書軟體中的 Ctrl＋F 連續字串查找實驗，也不涉及向量檢索或生成技術。本研究援引它，只在說明「使用者必須猜中文件用詞」這個限制在真實大

型文件集中曾被觀察到，以及使用者對自身查找完整度的判斷可能與實際有落差。

2.2.3 資訊需求本身難以精確表達

Belkin（1980）從使用者端提出「異常知識狀態」（anomalous state of knowledge, ASK）的觀點：使用者在面對問題時察覺自身知識狀態有所不足，此一體認再經語言與語用上的轉換，才成為向檢索系統提出的請求（Belkin, 1980）。他進一步區分兩種難以精確表達的情形：一是使用者在認知上尚不知道需要什麼資訊，二是即使認知上已明確，也未必能以特定系統的語言表達（Belkin, 1980）；並據此主張，以「最佳匹配」為原則、仰賴使用者精確陳述需求的系統，難以在理論上的最佳狀態下運作（Belkin, 1980）。

Belkin 自陳此一架構屬概念性論述，不能直接導出可否證的推論（Belkin, 1980），因此本研究只把它作為理解查詢形成的理論依據，不宣稱驗證 ASK。綜合三篇文獻，可整理出一個由淺到深的問題光譜：使用者講得出需求但用詞與文件不同（Furnas 等人），使用者在實際大型文件集中難以猜中所有相關文件的用詞（Blair 與 Maron），以及使用者連需求本身都尚未能清楚表述（Belkin）。本研究以日常口語提問作為查詢起點，正對應這個光譜的前兩層，而 B 組追問設計僅部分回應第三層。

【待補：繁體中文就業服務情境中，口語提問與正式文件用語之間落差的實證文獻；目前所引三篇均為英文語料與早期系統。】

2.3 字面查找、向量檢索與檢索增強生成

2.3.1 字面查找：連續字串比對

本研究 A 組所指的字面查找，是使用者輸入的文字必須在文件中以完全相同、連續的字串出現才算命中，以一般軟體 Ctrl＋F 頁內尋找的逐字比對為原

型，但大小寫、標點、空白與全半形均不做轉換。它不做斷詞、不排序、不補同義詞，也不估計相關程度；使用者可以自行換詞再查。這與資訊檢索文獻中常見的關鍵字檢索不同：Karpukhin 等人（2020）指出，開放領域問答的檢索器傳統上以 TF-IDF 或 BM25 實作，透過倒排索引比對詞彙並計分排序。本研究不在 A 組加入此類排序或拆詞機制，以免把 A 組變成另一種檢索模型；因此，關於 BM25 等排序式關鍵字檢索的文獻結果，不能直接移用來描述 A 組表現，反之亦然。

【待補：探討頁內尋找或連續字串比對之使用行為的文獻；若查無適切文獻，於第三章說明 A 組定義係依研究目的自行界定。】

2.3.2 向量檢索

Karpukhin 等人（2020）提出的稠密段落檢索，以兩個各自獨立的編碼器分別把問題與段落映射到低維連續向量空間，並以兩向量的內積作為相似度，取回最接近的前 k 個段落。作者指出，此種稠密表示在設計上可與稀疏表示互補：即使同義詞或改寫使用完全不同的詞元，仍可能被映射到相近的位置。

這個特性說明了向量檢索在處理用詞不一致時的潛在優勢，但該文的實驗建立在英文維基百科等開放領域問答資料上。它不能證明向量檢索在繁體中文法規、函釋與問答文件上已具同等優勢；本研究的向量模型、切分方式與候選數量，須在自身語料上另行驗證。

2.3.3 檢索後生成

Lewis 等人（2020）提出檢索增強生成（retrieval-augmented generation, RAG）：模型先以輸入取回文本段落，再把取回內容作為生成回答時的額外脈絡；架構包含回傳前 K 筆段落的檢索器，以及依輸入、取回段落與已生成內容產生輸出的生成器。該文採用維基百科稠密向量索引作為外部記憶，屬於其模型的具體設定，並非所有 RAG 系統皆然。

就一般架構而言（本研究整理），字面比對與向量檢索是可單用或併用的檢索實作，生成則可接在任一種檢索結果之後。本研究 B 組是一條包含查詢理解與改寫、向量取回候選段落、整合回答、附段落引用，以及資訊不足時追問或說明不足的完整流程。A、B 兩組的差異同時來自檢索方式、回答生成與互動設計，研究結果只能歸屬於兩套完整查找方式，不能單獨歸因於向量模型。

2.3.4 商用產品作為體驗參照

NotebookLM 的官方說明指出，系統以使用者提供的來源回答，並利用問題檢索相關內容與處理對話脈絡（Google, n.d.）。本稿沿用研究起點的 NotebookLM 名稱；查閱時官方說明頁已以 Gemini Notebook 呈現。本研究以其公開說明的功能作為 B 組設計的體驗參照，用來界定「完整 AI 語意查詢」應包含的能力範圍；但其公開功能說明不足以重建完整內部流程，本研究未對其做同條件品質對照，也不宣稱自建 B 組已達到相同品質，更不將其列為第三個比較組。

2.4 完整系統的評估：檢索、回答與引用

2.4.1 系統中心與使用者中心的評估

Kelly（2009）區分兩類評估問題：傳統以系統為中心的評估，問系統能否取回相關文件；互動式資訊檢索評估則問人能否使用該系統取回相關文件。她以一條連續光譜整理相關研究，一端是沒有真實使用者與互動搜尋的測試集研究，另一端才是同時具備真實使用者與互動搜尋的研究。她也指出，使用標準測試集時必須暫時假定相關性是二元、靜態且可跨人類推，但這些假定與實際上不同人判斷常不一致的情形並不相符。

這個區分直接影響本研究能主張的範圍。若以事先訂定的查詢序列進行離線評估，所得結果只能說明「在該操作規程下」兩套系統的表現，位於光譜中偏系統中心的一端；真人是否因此更省時、負擔較低或較偏好某一方式，需要

真人操作的證據才能主張。Blair 與 Maron（1985）所觀察到的使用者高估查找完整度，也提醒本研究不能以使用者自陳滿意度取代對「是否真的找到正確依據」的核對。

【待補：本研究採離線固定查詢序列或真人操作，尚待與教授確認；若納入真人，另需招募、同意與倫理程序，且不沿用舊有二十人訪談方案。】

2.4.2 公平的操作規程

當一端是連續字串比對、另一端是理解口語的問答系統時，若只把同一句長口語問題送入兩端，可能只反映原句是否出現在文件內，難以涵蓋使用者換詞後完成任務的能力。首次查詢可作描述，但應與完整操作規程的結果分開。較合理的作法是事先訂定兩組各自的操作規則：A 組允許的換詞方式與次數、B 組允許的追問次數，以及兩組的停止條件，並在看到正式結果前固定。Kelly（2009）對任務與主題的區分及模擬工作任務情境的討論，可作為設計查詢情境的參考。

【待補：A 組換詞與 B 組追問的具體規程、停止條件與題型分層；支持字面查找與 AI 問答公平比較的方法文獻。】

2.4.3 回答品質與引用支持

檢索增強生成系統的評估不能只看是否取回相關段落。Es 等人（2024）提出 RAGAs，作為不依賴人工標準答案的 RAG 流程評估框架，從回答是否忠於取回內容、回答與問題的相關程度，以及取回內容的相關程度等面向進行自動評估。Gao 等人（2023）提出 ALCE 基準，評估大型語言模型生成附引用回答的能力，將回答的流暢、正確與引用品質分開衡量，並指出現有模型的引用經常未能完整支持其陳述。

這兩篇文獻支持本研究把評估分成兩層：檢索層判斷是否找回正確的支持資料；回答層判斷回答是否正確、完整、引用是否確實支持所述內容，以及在

文件庫缺乏答案時是否說明不足而非編造。兩者的自動評分方法都不能直接代替本研究由具領域知識者進行的人工核對；AI 評分最多只作初篩。

【待補：RAGAs 與 ALCE 本次已核對官方書目與摘要，尚未完成全文研讀；其指標定義與本研究評分規準的對應、以及是否適用繁體中文語料，須補讀後再定稿本小節。資料庫無答案情境的評分規則亦待補文獻。】

2.5 文獻缺口與本研究定位

2.5.1 各線索的貢獻與限制

表 2-1 文獻線索與適用界線

線索	文獻提供的基礎	未涵蓋之處
知識再使用	顯性與隱性知識的區分及四種轉化模式（Nonaka, 1994）	未處理就業服務文件；公開法規不等於外化成果
詞彙與需求	用詞不一致的實證（Furnas et al., 1987）；大型全文檢索中召回不足與使用者高估（Blair & Maron, 1985）；需求難以精確表達（Belkin, 1980）	均為英文語料與早期系統；不涉及 Ctrl＋F、向量檢索或生成
檢索與生成機制	稠密向量檢索可處理改寫與同義表述的設計原理（Karpukhin et al., 2020）；檢索後生成的架構（Lewis et al., 2020）	實驗基於英文開放領域資料；未證明繁體中文法規情境的優勢
評估方法	系統中心與使用者中心評估的區分（Kelly, 2009）；回答忠實度與引用品質的評估框架（Es et al., 2024；Gao et al., 2023）	未提供字面查找與 AI 問答的公平比較規程；中文適用性待查

2.5.2 本研究的位置

就本章所引文獻而言，尚未見到在同一批繁體中文就業服務文件上，以預先訂定的操作規程，比較 Ctrl＋F 式字面查找與完整 AI 語意檢索問答，並將檢索成功與回答品質、引用支持分開評估的研究。此一判斷僅限於本章所引文獻，不代表該主題在整體文獻中皆未被處理。【待補：以系統性檢索確認是否已有相近研究，特別是中文法規問答與政府資訊查找領域。】

本研究的貢獻因此設定在兩個層次。其一，在共同語料與事先固定的操作規則下，描述兩套查找方式找回正確支持資料的表現與失敗類型；其二，評估 AI 語意問答在回答正確、完整、引用支持與資訊不足處理上的實際表現。對應的工作版研究問題為：

表 2-2 工作版研究問題與文獻連結

研究問題（工作版）	主要文獻依據
RQ1　在預先訂定的查詢操作規則下，A、B 兩組找回正確支持資料的表現與失敗差異為何？	Furnas et al.（1987）；Blair & Maron（1985）；Belkin（1980）；Karpukhin et al.（2020）；Kelly（2009）
RQ2　B 組回答在正確性、完整性、引用支持及資訊不足處理上的表現為何？	Lewis et al.（2020）；Es et al.（2024）；Gao et al.（2023）

本研究不主張 AI 必然勝出，不把結果泛化到 Google 或所有關鍵字搜尋引擎，也不把離線評估結果寫成真人效率或滿意度的證據。研究問題的正式措辭、題目與比較條件，待與指導教授確認後於第三章定稿。【待補：教授確認後的正式研究問題措辭。】

第3章 研究方法與平台設計

3.1 研究設計

本研究以共同文件庫為控制基礎，比較 A 組字面查找與 B 組完整 AI 語意檢索問答。比較的處理條件是整套查找方式，包括使用者可提交的查詢、系統處理步驟與輸出形式；文件內容與題目的資訊需求應保持一致。此設計能描述兩套方式的差異，但不構成只操弄向量檢索單一因素的實驗。

本稿建議先以離線、題目配對的方式完成主要比較。每一題具有明確情境、所需答案要點與支持來源，由預先制定的程序分別執行兩組查詢，減少操作臨場差異。如此可先檢驗是否找回依據及 B 組是否根據依據回答；若日後要研究真實使用者的操作負擔，再另行加入使用者研究。兩個階段所能回答的問題應分開。

【待確認：採用上述離線配對設計、正式題數、題型配置、是否增加真人研究，以及是否需要學校研究倫理審查或免審認定。以上尚未核定，不代表已招募、已取得同意或已完成倫理程序。】

研究過程區分開發與正式評估。開發階段允許修補程式、補齊來源與調整提示詞；正式評估則以已凍結的語料、題組、模型與規程執行。如果正式執行後發現必須修正系統，應保留舊版本結果，另立修訂版本與新的分析批次，不以修正後的單題成功覆蓋原始失敗。

3.2 共同文件庫的建置與來源管理

3.2.1 開發語料與正式語料的區別

目前開發文件庫共有 1,781 個可檢索項目，由原始 1,772 項及後續補入的九個育嬰留職停薪實施辦法條文項目組成。此數量是程式資料中的檢索單位

數，不能解讀為 1,781 份彼此獨立的完整文件。其來源與雜湊已記錄於平台版本資料，詳細識別列於附錄。

九個新增條文項目來自開發時已看過的申請程序案例所暴露的來源缺漏。補入資料改善的是文件庫覆蓋範圍；若用同一案例比較補入前後的表現，便同時改變了語料條件，不能當作單純檢索技術改善的證據。正式評估使用的語料應在題目保留與資料納入規則確定後凍結，並記錄哪些題目已在開發階段使用。

現有來源盤點另指出，157 個指引段落仍缺少原網站網址。此缺口影響來源回查與版本確認。正式語料驗收應逐筆補足網址、發布單位、標題、修訂日期與擷取日期；無法確認來源或內容已失效的材料，須依事先規則排除或標示，不能只因為向量可建立就視為完成清理。

3.2.2 建議的資料處理程序

資料處理以保留原意與可回查性為原則。先建立原始文件清單，再將條文或具完整意義的段落整理成檢索項目，保留來源文件識別與段落位置。去除導覽列、重複頁尾等非內容文字時，需留下處理規則；若段落依賴上文的主體、適用對象或例外條件，不應在沒有脈絡的情況下獨立切分。

對於法律名稱、條號、日期、金額、條件與例外，不宜為了降低字面差異而任意改寫。兩組共用的文本必須一致。若需要統一編碼或處理不可見字元，應在建立語料時一次完成並記錄；A 組不得在查詢時額外進行只有該組具備的未揭露正規化。

【待確認：正式切分單位、最大長度、相鄰段落是否保留、重複文件判定規則、資料更新停止日及跨版本條文的納入方式。現行開發項目不得直接視為方法已核定。】

3.2.3 共同語料下的表示差異

兩組共享資料項目，並不表示輸入檢索器的表示方式完全相同。現行 A 組分別在標題與內文尋找完整字串，不跨越欄位邊界；B 組以標題、換行與內文合併後的內容建立向量。因此，本研究控制的是共同來源與原文內容，並揭露兩組如何使用這些欄位，避免以「完全相同」掩蓋處理步驟的差異。

表 3-1 整理現行開發版本與正式驗收仍需完成的項目。

表 3-1 共同語料與版本狀態

項目	目前可核對狀態	正式研究前的處理
檢索單位	1,781 項開發材料	【待補：各類數量與凍結清單】
新增材料	九個條文項目，源自開發案例補缺	隔離已見案例並記錄納入理由
原網站回查	157 個指引段落缺網址	【待補：逐筆補齊或依規則排除】
版本識別	已保存資料雜湊與來源 commit	【待補：正式版本與簽核日期】
內容有效性	尚未完成全庫時效核對	【待補：有效版本及專業核對】

3.3 兩組工具與系統架構

3.3.1 A 組字面查找

A 組將使用者輸入視為完整的連續字串，分別檢查每一項目的標題與內文。只有字面完全相同的位置才算命中。現行設定區分大小寫，不自動移除標點或空白，也不合併全形與半形字元；這是本研究工具的操作定義，並不代表所有文書軟體的預設行為。

系統保留全部命中項目，以語料原有順序呈現，預設每頁顯示 20 項，並提供命中次數與位置。分頁是顯示機制，不是僅取前 20 名的相關性排名。A 組沒有自動生成答案，使用者必須閱讀原文、判斷是否適用。若完整口語句子未命中，使用者可以自行縮短或更換詞語，但正式研究必須事先規定允許的操作次數與詞語來源。

3.3.2 B 組語意檢索與問答

B 組先接收原始問題與允許保留的對話脈絡，由語言模型形成較適合檢索的補充查詢。現行流程包含主改寫查詢、至多兩個補充查詢與原問題，去除重複後最多有四個查詢；每個查詢取回八個候選項目，合併後最多保留 20 個不同項目供回答使用。生成時每個證據項目的內文最多帶入 1,500 個字元，原問題長度上限為 500 個字元；這些限制均應在正式版本凍結前記錄。程式另設數量保護，移除改寫中使用者未提供的數量或期間，必要時退回使用者原話；查詢向量化時加上 BGE 官方查詢指令。候選項目依各查詢的排名輪流合併並去重，不以不同查詢的相似度直接混排。

向量模型目前使用 BAAI/bge-base-zh-v1.5，並保存指定版本的識別碼。回答生成的開發設定為 gpt-5.4-mini-2026-03-17。模型名稱在本稿只是描述現行實作，不是經正式比較後選出的最佳模型，也不能據此推定在本場域的品質。改寫提示詞、回答提示詞與模型參數應與程式版本一併保存，避免只記住服務品牌而失去重現條件。

B 組可輸出回答、請求釐清或說明資訊不足三種狀態。回答應以取回的材料為依據，保留來源識別；條件不明時應避免替使用者補出年資、身分或其他適用前提。對話脈絡目前最多保留六輪、十二則訊息。若後續題目需要超出這個範圍，應另訂正式操作程序，不假設模型能記得所有歷史內容。

現行程式會核對引用識別是否存在於本次證據集合。然而，這種核對只排除不存在的來源編號，不能判定來源是否真的支持回答中的每一個陳述。法規

例外、期間或主體若被誤讀，仍可能產生帶有有效來源編號的錯誤答案，因此需要回答層的人工評閱。

3.3.3 架構與功能邊界

圖 3-1 呈現兩組共享文件庫、分別處理查詢與輸出的關係。A 組的主要產物為原文命中位置；B 組的主要產物為依候選證據形成的回答及引用。評估時共同核對支持資料，並針對 B 組增加回答層檢查。

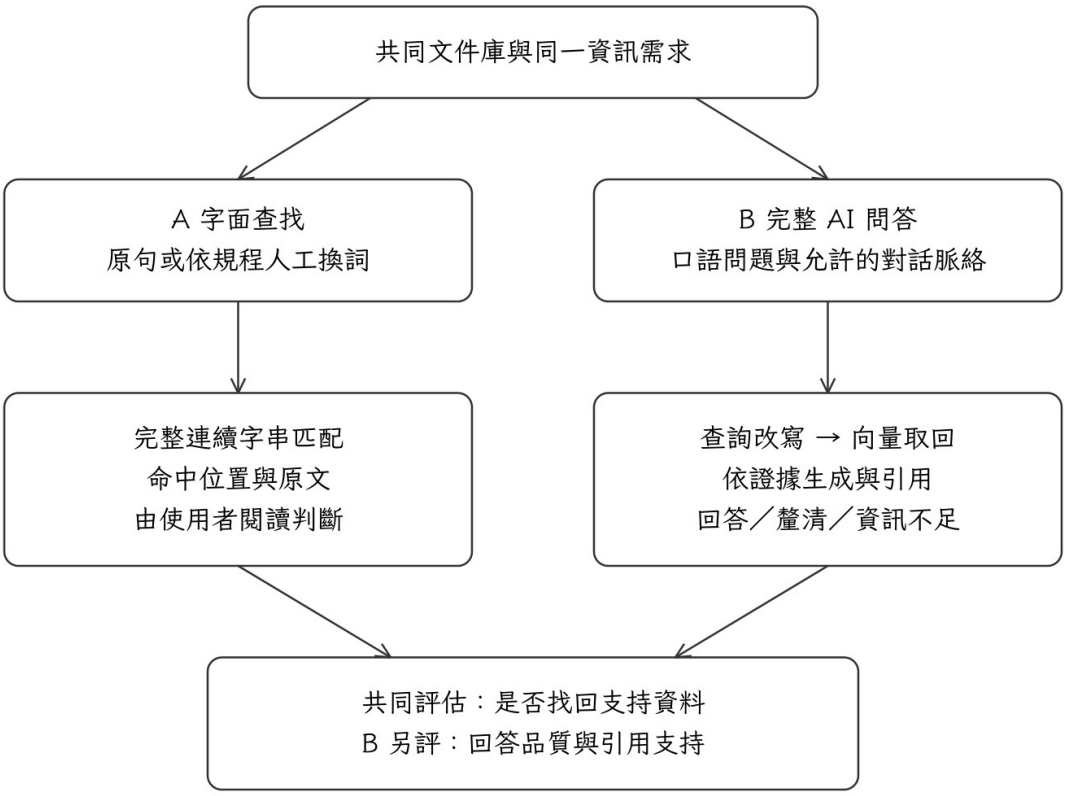


圖 3-1 共同文件庫與兩組查找方式

【待確認：現行模型、候選數、截斷長度、歷史保留範圍與提示詞，須經開發檢查後決定是否納入正式版本。若變更，第三章、版本清單與實際程式須同時更新。】

3.4 題目集與參考答案

3.4.1 題目單位與來源

一題應代表一個可辨識的資訊需求，而不是一個事先挑好的關鍵字。題目可包含使用者情境、原始口語問法、必要條件、希望完成的查找任務及預期應取得的證據。題目的答案必須依凍結語料判定；若來源無法回答，應事先標示為無足夠資料類型，不能在看到系統失敗後才把它改成例外。

題目來源宜與系統開發過程分開。已用來修改提示詞、補文件或除錯的例子，可保留在開發集，作為回歸檢查；正式評估題則需保留其建立日期、提供者角色、是否曾曝光及排除理由。若題目由 AI 協助起草，應由具領域知識者確認情境合理性與答案，並揭露使用方式；AI 起草不等於獨立的專家標準答案。

【待補：正式題目來源、題數、建立者與審查者資格、開發集與正式集分配、避免題目內容被帶入索引的檢查紀錄。】

3.4.2 題型分層與可回答性

建議題型涵蓋明確制度名稱、口語與正式用語不一致、需要多段證據、條件不足須釐清，以及文件庫無答案等情況。分層的目的在於辨識失敗條件，不能只挑選長句零命中的題目。A 組可能擅長的明確詞彙查找亦應納入，讓比較能反映不同任務需求。

可回答性需先於系統執行判定。若題目已提供足夠條件，且共同語料中有支持答案的內容，可歸為可回答；若欠缺會影響適用規則的必要條件，應列出應釐清的問題；若資料庫沒有足夠內容，則標示來源不足。這三類所期待的正確行為不同，不宜混在同一個答案正確率中而不加說明。

3.4.3 參考答案與證據集合

參考答案宜以「必要要點」及其支持來源建立，而不只提供一段理想文句。每個要點需標明適用條件、必須包含的資訊與可接受的表述方式；支持來源應標記穩定項目識別，必要時記錄多種等價來源。若不同條文必須合併才足以作答，評分應要求必要證據組合，而非找到其中任一段就算完全成功。

【待確認：由至少兩位具相關知識的評閱者獨立建立或核對參考答案，再處理分歧，是本稿的建議方案；人數、資格、分工與共識程序尚未確定。】

3.5 查詢與執行程序

正式執行前，應先保存語料與系統版本、檢查服務可用、確認每題以新的工作階段開始。兩組使用同一題目情境；查詢記錄必須保留先後次序、原始輸入、後續換詞或回答釐清的內容、系統輸出及停止原因。不能只留下最後成功的一次查詢。

建議把比較分為兩個觀察點。第一個是原始口語問題送入後的首次回應，用來觀察原句在兩組中的處理差異；第二個是在事先規定的操作機會內，能否完成查找任務。首次回應可以呈現字面落差，但研究的主要實務結論不應只建立在長句對 A 組不利的單次測試上。

【待確認：本稿建議的試行規程為每題最多三次查詢機會。A 組採測試前寫定的原句及最多兩次人工換詞；B 組由原句開始，最多接受兩次依事先情境提供的釐清回覆。此規程尚未核定，需先導測試檢查兩組操作機會是否合理，再凍結正式規則。】

在離線設計中，A 組的換詞序列應於看見結果前形成，不能由知道標準答案的操作者臨場挑出最容易命中的字。B 組的釐清回覆應只提供題目情境原先允許的資訊，不能額外提示正確條文或答案。若模型提出情境資料無法回答的問題，應照實記錄，而非由操作人員代為補充有利資訊。

本節所稱查詢機會，是使用者送出問題或回覆的次數；B 組一次輸入可觸發最多四個內部向量查詢，並不等同 A 組的一次字串比對。此差異屬完整工具的處理機制，應另記內部查詢數及成本，不能宣稱兩組運算量相等。

服務錯誤、逾時、格式解析失敗與內容答錯須分別編碼。研究可事先規定技術性重試條件，但不得因答案不理想就重問直到成功。由於語言模型輸出可能有變動，重複執行次數與彙整方式需在正式測試前決定；同一題的多次執行不能當作多個彼此獨立的題目樣本。

【待補：正式順序安排、停止條件、技術錯誤重試次數、時間上限、B 組重複執行次數與成本上限，以及各欄位如何由工具自動保存。】

3.6 評估指標與分析方法

3.6.1 共同的支持資料評估

兩組共同評估的核心，是在預定操作規程下能否取得足以完成任務的支持資料。可先以逐題的完全支持、部分支持與未支持進行分類，再依題型整理成功與失敗分布。若使用召回率等指標，須先具備足夠完整的相關來源標註；沒有完整的相關集合時，不宜把取回某一段的比例稱為全庫召回率。

A 組可能回傳大量結果，而 B 組有候選數限制，因此「回傳集合包含答案」與「使用者能在合理檢視範圍內看見答案」應分開記錄。全量命中集合可用來判斷匹配機制是否涵蓋支持資料；若要比較有限閱讀量下的可達性，則須另外訂定兩組可檢視的項目數或閱讀預算，不能把所有 A 組命中與 B 組少數候選直接混成同一個前 k 名指標。

3.6.2 B 組回答與引用評估

回答層建議分別記錄正確性、完整性、引用支持與資訊不足處理。正確性檢查有無錯誤要件或相反結論；完整性檢查必要要點是否齊備；引用支持檢查

每項實質陳述是否由其所指來源支持；資訊不足處理檢查該追問時是否追問、沒有來源時是否坦承不足。這些項目應保留個別分數，不先以任意加權總分掩蓋不同類型的缺陷。

表 3-2 是可供教授討論的評分草案。正式使用前須用開發題校準、修正文句並固定。表中規準為本研究建議的操作化方式，不宣稱直接等同 RAGAs 或 ALCE 的原始計算公式。

表 3-2 評分規準草案

面向	建議判定方式	適用範圍
支持資料	完全支持／部分支持／未支持；另記技術失敗	A、B 共同
回答正確性	無實質錯誤／局部錯誤／核心結論錯誤	B；A 不適用
回答完整性	必要要點全數／部分／未涵蓋	B；A 不適用
引用支持	逐項陳述核對支持、部分支持或不支持	B；A 不適用
資訊不足處理	依題型判定正確追問、適當不足說明或不當作答	B；依參考答案
程序與成本	實際查詢次數、服務時間、token 用量與估算費用	分欄呈現，不混成品質分數

【待確認：各面向的正式等級、計算分母、部分支持定義、重大錯誤判準及評閱者一致性檢查方式。A 組不具生成答案功能，生成評分欄必須記為不適用。】

3.6.3 配對分析與失敗分類

分析時先呈現題目數、題型與可回答性，再逐題對照兩組的支持資料表現。若以二元成功判定進行推論統計，可考慮適合配對資料的方法；小樣本、少數不一致配對或多層級評分，需另行選擇合適程序。此處不預先填入顯著性、效果量或信賴區間，正式方法須配合最終資料結構決定。

【待確認：統計檢定、效果量、區間估計、缺失值與技術失敗的處理方式；是否採 McNemar 檢定或其他方法，須在正式執行前完成方法文獻核對與分析計畫。】

量化摘要之外，應保留失敗案例分析。A 組可區分原句未出現、換詞後候選過多、檢視範圍未及支持段落等情形；B 組可區分改寫偏離意圖、取回錯誤或不完整、生成誤讀條件、引用不支持與不當拒答等情形。分類以可觀察的輸入、中間結果與輸出為據；沒有內部證據時，不把推測寫成模型的實際心理過程。

3.7 品質控制與可追溯性

品質控制包含內容、程序與版本三個部分。內容方面，保留原始來源與人工核對紀錄；程序方面，在看到正式結果前固定題目、換詞與評分規則；版本方面，保存語料雜湊、程式 commit、模型識別與提示詞雜湊。這些紀錄使他人能區分來源更新、工具修改與查詢差異，不保證外部模型服務在未來永遠產生相同文字。

AI 可協助整理資料、撰寫程式、起草文件與初步檢查，但研究者仍須確認來源、方法與結論。正式參考答案與評分不應只由同一個生成模型自行判定。若評閱者知道答案來自哪一組而無法完全盲評，應揭露此限制；可以在不破壞內容意義的前提下隱去模型名稱及介面標誌，降低不必要的品牌期待。

本稿公開研究成果，排除金鑰、密碼與原始查詢日誌。新增真人資料須完成相應研究程序；工具公開不等於參與者已同意。

第4章 平台實作與研究結果

4.1 本章資料的性質

截至本稿整理日，已具備兩組工具的開發版本、來源清單、部分工程驗證與開發觀察；正式題組、操作規程與人工評分尚未完成。本章先呈現已存在且可追溯的開發證據，並保留正式研究結果的完整寫作結構。工程測試通過表示特定功能符合測試條件，不能直接換算為回答正確率或研究假設獲得支持。

本章引用的開發紀錄來自平台 docs/verification.json，驗證時間為 2026 年 10 月 22 日 11 時 07 分。該紀錄標示 development 階段與 0.1.1 版本，保存語料雜湊、工程檢查與案例觀察。它不是正式實驗資料表，也不是所有使用者提問的完整歷史。

【待補：正式研究執行日期、題組與系統凍結版本、有效題數、評閱者、排除與缺失資料紀錄。完成後本章正式結果各節才能填入數據。】

4.2 已完成的平台實作與工程檢查

目前兩組已能在共同開發語料上操作。A 組呈現字面命中項目與位置；B 組具備查詢改寫、向量取回、生成回答、引用來源及多輪追問的流程。來源檢視與紀錄匯出等功能，使後續評閱能回到原始段落，而不只停留在聊天畫面的答案文字。

既有工程紀錄記載 33 項單元測試通過，並明確註記該批測試沒有呼叫真實模型 API；因此它支持的是程式邏輯與受測情境的運作，不支持真實模型的整體答案品質。相同紀錄亦保存服務回應、來源視窗、CSV 下載與文件下載雜湊檢查，以及 launchd 服務重啟的驗證。

介面曾以 390 × 844 的瀏覽器視窗檢查響應式呈現，但紀錄中的實體 iPhone 測試欄位為否。故本稿只描述窄螢幕檢查，不宣稱已完成各手機與瀏覽

器的實機驗收。工具可從指定私人網路開啟，是研究執行條件之一；平台可連線與回答正確，仍屬不同層次的驗證。

表 4-1 開發驗證紀錄及可支持的主張

紀錄	已記載狀態	解讀界線
單元測試	33 項通過；未呼叫真實 API	特定程式測試通過，非正確率
網頁服務	HTTP 200；來源視窗與下載檢查通過	功能可用，非研究成效
窄螢幕呈現	390 × 844 視窗檢查	未記載實體 iPhone 驗收
服務維運	已驗證 launchd 重啟	支持服務維持能力
舊版保全	149 個綠區檔案未改動	開發區隔紀錄，非實驗控制證明

4.3 開發案例的觀察與限制

4.3.1 完整口語句子與短詞查找

既有開發紀錄中，A 組輸入「育嬰假如何請」時，命中項目數為零；改輸入「育嬰」時，命中 41 個項目，共有 107 處出現位置。兩個數字的單位不同：項目數表示多少個檢索單位含有該字串，出現次數則計入同一項目內的重複位置。不能把 107 解釋成 107 份相關文件。

此案例符合 A 組連續字串比對的設定。短詞命中較多，是因為條件變寬；它並不反駁完整句子找不到的觀察，也不能證明這 41 個項目都能回答申請程序。是否取得正確程序，仍須回查支持內容。這也是正式研究應同時記錄零命中、候選數量與真正支持資料的原因。

4.3.2 語意問答與來源補缺

開發紀錄顯示，B 組在口語申請程序案例中曾回答並引用育嬰留職停薪實施辦法第二條；在任職條件與接續追問案例中，曾引用性別平等工作法第十六條。此處描述的是保存的系統觀察，不代替現行法規的適用判斷，也未逐句認定所有生成內容均正確。

該批案例保留了兩類修正歷史：一是語料缺少申請程序法源後補入條文，二是任職條件案例曾漏找相關條文後修正。這說明語意模型不能靠理解能力補足文件庫原本欠缺的證據。若修正過程新增來源，正式分析必須辨認其作用來自資料覆蓋、查詢流程或生成提示，不能把所有改善都歸為「AI 更懂問題」。已看過的案例適合留作開發回歸測試，不能再次充當未見的正式測試題。

4.3.3 釐清與資料不足

對請假類型不明的開發案例，紀錄顯示 B 組採取釐清；對文件庫外的氣溫預報，則記為資訊不足。最終資訊不足狀態也可能來自格式或引用驗證後的處理；正式研究應回查中間紀錄，區分模型主動判斷不足與程式移除無效回答。這些觀察支持系統具備不同輸出路徑，但尚不足以證明它在各類模糊或無答案問題上都能正確選擇。尤其釐清語句是否讓新手理解、是否詢問了真正必要的條件，仍需依題目情境人工評閱。

因此，目前可以說明工具已實作哪些反應，以及特定開發案例曾出現何種輸出；不能寫成 B 組已普遍優於 A 組，或已達到 NotebookLM 的品質。正式結論必須建立在未用於調整系統的題組與事前固定的評分規準上。

4.4 正式題組與樣本概況

正式結果首先應報告題目來源與篩選過程，包含候選題數、排除原因、最終有效題數及各題型分布；再說明可回答、需釐清與來源不足各類的數量。若有多次模型執行，應分列題目數與執行次數，避免混淆樣本單位。

【待補：本節正式敘述須由題組凍結清單與執行紀錄產生。目前沒有可填入的正式樣本數、受試者數、題型比例或缺失率。】

表 4-2 正式研究資料概況待填表

欄位	正式數值	必須對應的證據
候選與納入題數	【待補：尚未定稿】	題目清單與排除紀錄
各題型及可回答性	【待補：尚未標註】	參考答案與審查表
有效配對及失敗執行	【待補：尚未正式執行】	原始執行紀錄
評閱者及一致性	【待補：尚未評閱】	獨立評分與分歧處理

4.5 研究問題一的比較結果

RQ1 的結果應先逐題呈現兩組支持資料判定，再彙整 A、B 皆成功、僅 A 成功、僅 B 成功與皆未成功的配對分布。如果使用完全、部分與未支持的分級，也應保存原始分級，說明是否及如何轉為二元判定。首次回應與規程內完成任務的結果須分開呈現。

【待補：填入兩組各題型的支持資料結果、配對差異、區間估計及核定的統計分析。正式資料尚未取得，不填入任何假設百分比或顯著性。】

【待補：依實際結果撰寫解釋。若 A 組在明確詞彙題較佳、B 組在口語改寫題較佳，應指出證據與例外；若未出現差異，也應如實說明，不能預先寫成語意工具勝出。】

4.6 研究問題二的回答與引用結果

RQ2 的結果應逐項呈現正確性、完整性、引用支持與資訊不足處理，並分開報告可回答、需釐清與來源不足題。回答內容多或語氣肯定，都不能直接代表較高品質。對具有多個必要要點的題目，宜指出缺漏的是程序、條件、例外或其他核心內容。

【待補：正式人工評閱表、各面向結果、引用支持的分子與分母、重大錯誤案例，以及評閱分歧的處理紀錄。】

對於有引用但仍錯誤的案例，分析應同時保存問題、必要條件、取回證據、生成陳述與判定理由。若來源確實包含答案而生成誤讀，屬回答層的限制；若證據本身未涵蓋必要條件，則需追溯檢索或資料覆蓋。只有保留這些中間證據，才能避免把不同失敗原因混為單一「AI 不準」。

4.7 綜合討論

目前開發證據已顯示，字面命中、取得支持資料與形成正確答案是三個應分開檢查的事件。A 組回傳大量包含同一短詞的項目，並不等於取得完整答案；B 組生成帶引用的文字，也不等於引用足以支持結論。這項區分為正式分析提供分類框架，但尚不是兩組成效差異的實證結論。

【待補：完成正式結果後，回到第二章文獻討論本研究在哪些條件下支持、補充或限制既有觀點；須明確區分英文既有研究與本研究繁體中文情境，並處理與預期不一致的發現。】

第5章 結論與建議

5.1 研究工作目前完成的內容

本研究由「使用者能否以自己的話找回已存在的知識」出發，將比較對象界定為同一文件庫上的字面查找與完整 AI 語意檢索問答。自建平台使語料、查詢處理與輸出證據能夠被記錄，也使研究者得以檢查查找失敗究竟發生在字面匹配、語意取回、資料覆蓋或生成解讀。

目前已完成的是研究方向重整、兩組開發工具、開發語料與版本紀錄，以及部分工程與案例檢查。全文已將文獻背景、方法設計、已知工程證據與待完成正式結果連接起來；尚未完成的是正式題組、規程凍結、領域評閱與成效分析。因此，這一階段能交付完整的論文工作稿，但不能將它稱為已完成實證的學位論文。

5.2 研究問題的正式結論

【待補：RQ1 結論。須根據第四章的配對資料說明，在何種操作規程及題型下，A、B 兩組找回正確支持資料的表現如何；包含差異大小、例外與適用範圍。未有正式資料前，不宣稱任一組較優。】

【待補：RQ2 結論。須根據回答正確性、完整性、引用支持及資訊不足處理的人工評閱，說明 B 組可用能力與主要失敗條件；不能以少數開發成功案例代替整體結果。】

【待補：研究貢獻的最終表述。正式結果完成後，判斷貢獻主要屬於方法與工具建置、特定場域實證，或其他已獲證據支持的面向，避免以尚未證明的普遍效益作結。】

5.3 平台設計與實務意涵

5.3.1 保留精確查找的用途

本研究不把字面查找視為應被淘汰的功能。當使用者知道法律名稱、條號或特定用語時，字面命中具有條件透明、容易重現與便於定位的價值。語意查詢提供另一種入口，兩者可以在實際系統中並存；但本研究的比較仍應分開操作，以辨認不同方式的作用。

5.3.2 以證據支撐口語回答

讓使用者直接說出問題，並不免除系統核對來源的責任。完整 AI 問答應把答案與原文連接，讓使用者能查看必要條件與例外；若缺少資料或問題不明，應提供有用的釐清或範圍說明。設計上可支援這些行為，實際上能否穩定做到，仍需以正式評估確認。

5.3.3 把資料維護納入工具品質

開發中的來源補缺，顯示資料庫覆蓋範圍與可追溯性會直接影響工具能回答的內容。模型更新不能取代原始文件的時效核對。對就業服務知識系統而言，來源網址、修訂日期、段落脈絡與異動紀錄，都是研究與後續維運需要共同管理的資料，而非建好向量後即可忽略的附屬欄位。

上述意涵來自設計邏輯與已知開發限制，屬於本階段可提出的建議；是否提升工作效率、降低認知負擔或改善服務品質，尚須另有實際使用資料支持。

5.4 研究限制

第一，A 組是明確界定的連續字串工具，其結果不能代表所有關鍵字搜尋。採倒排索引、BM25、混合檢索或其他語意處理的服務，與本研究的處理條

件不同。第二，B 組同時包含改寫、向量、生成與互動，故本研究比較的是整體方式，不能單獨估計向量模型的因果效果。

第三，開發語料仍有來源網址與時效核對缺口，正式清理可能改變文件庫範圍；本稿所列的 1,781 項不能預先當成最終樣本。第四，開發過程已接觸部分題目並據以修正系統，這些案例必須排除於未見題的成效估計之外。第五，外部模型可能更新或有非確定性，即使保留名稱與提示詞，也需記錄執行日期與重複試驗安排。

第六，若採離線評估，結果只能說明規程下的系統表現，不能直接說明真人操作時間、信任、滿意度與學習成效。第七，參考答案與評分仍有領域判斷，須揭露評閱者資格與分歧處理。第八，NotebookLM 尚未接受同題、同來源與同規程測試，本研究不能宣稱與其等效或達到同等品質。

【待補：正式執行後新增的限制，包括資料缺失、評閱一致性、服務失敗、題型樣本不足與結果可推廣範圍。】

5.5 後續研究與完成順序

本研究下一階段應先確認題目與語料的一致性，完成來源回查，再凍結題組與操作規程。其後建立參考答案及評分規準、完成先導校準、保留未見正式題並執行比較。這個順序能避免先看到結果，再修改評分方式以配合預期。

未來若希望辨認 B 組各元件的作用，可在本研究之外設計移除改寫、移除多輪脈絡或替換檢索器的對照條件；但必須另有足夠資料與預先設定，不應在目前兩組設計中直接推論。若要了解第一線人員或一般民眾的使用效果，則可增加真人任務研究，觀察查詢歷程與來源判讀，並完成相應的招募與倫理程序。

對本研究者而言，最初的問題仍是：資料已經存在時，能否讓使用者用自己的語言抵達可信的答案。本文已將這個問題轉為可操作、可追溯的研究設計；其最終答案須由正式資料決定，而不由工具名稱或個別印象決定。

參考文獻

Belkin, N. J. (1980). Anomalous states of knowledge as a basis for information retrieval. Canadian Journal of Information Science, 5, 133–143.

Blair, D. C., & Maron, M. E. (1985). An evaluation of retrieval effectiveness for a full-text document-retrieval system. Communications of the ACM, 28(3), 289–299. https://doi.org/10.1145/3166.3197

Es, S., James, J., Espinosa Anke, L., & Schockaert, S. (2024). RAGAs: Automated evaluation of retrieval augmented generation. In Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations (pp. 150–158). Association for Computational Linguistics. https://doi.org/10.18653/v1/2024.eacl-demo.16

Furnas, G. W., Landauer, T. K., Gomez, L. M., & Dumais, S. T. (1987). The vocabulary problem in human-system communication. Communications of the ACM, 30(11), 964–971. https://doi.org/10.1145/32206.32212

Gao, T., Yen, H., Yu, J., & Chen, D. (2023). Enabling large language models to generate text with citations. In Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (pp. 6465–6488). Association for Computational Linguistics. https://doi.org/10.18653/v1/2023.emnlp-main.398

Google. (n.d.). Frequently asked questions. Gemini Notebook Help. Retrieved October 23, 2026, from https://support.google.com/gemininotebook/answer/16269187?hl=en

Karpukhin, V., Oguz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., & Yih, W. (2020). Dense passage retrieval for open-domain question answering. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP) (pp. 6769–6781). Association for Computational Linguistics. https://doi.org/10.18653/v1/2020.emnlp-main.550

Kelly, D. (2009). Methods for evaluating interactive information retrieval systems with users. Foundations and Trends in Information Retrieval, 3(1–2), 1–224. https://doi.org/10.1561/1500000012

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks [Preprint; accepted at NeurIPS 2020]. arXiv. https://doi.org/10.48550/arXiv.2005.11401

Nonaka, I. (1994). A dynamic theory of organizational knowledge creation. Organization Science, 5(1), 14–37. https://doi.org/10.1287/orsc.5.1.14

【待補：依學校指定格式再次核對全文書目、斜體與作者拼寫；歷史研讀文獻需回原文確認重要轉述，補入的中文研究與方法文獻亦須加入本表。】

附錄一 題目與參考答案紀錄表

本附錄提供正式題組建立時可直接使用的欄位。它是空白研究工具，尚未完成填寫，不代表已存在經專家認定的標準答案。

表 A-1 題目紀錄欄位

欄位	填寫內容
題目識別與類型	【待補：唯一識別、題型與建立日期】
情境與原始口語問題	【待補：使用者已提供的條件與問題】
可回答性與必要釐清	【待補：可回答／需釐清／來源不足及理由】
必要答案要點	【待補：逐項列出必須涵蓋的事實與條件】
支持來源集合	【待補：項目識別、位置、適用版本與等價來源】
重大錯誤判準	【待補：錯誤主體、條件、例外或結論的判定】
開發曝光檢查	【待補：是否已用於補資料、調整提示或除錯】
審查與凍結	【待補：評閱者、分歧處理、版本與日期】

附錄二 執行與評閱紀錄表

執行紀錄應以題目、組別與執行輪次串接。原始內容與後續評閱分欄保存，避免在評分時改寫系統原始輸出。服務錯誤與答案錯誤應分開編碼。

表 A-2 執行與評閱欄位

欄位群	建議保留內容
版本	語料雜湊、程式 commit、模型識別與提示詞雜湊
操作	題目識別、組別、查詢序列、釐清回覆與停止原因
取回資料	項目識別、順序、候選數、命中位置或相似度
輸出	完整回答、引用及狀態；另記 model_status、無效引用與移除要點數、釐清階段
執行狀態	時間、技術錯誤、重試、token 用量及費用估算
獨立評閱	評閱者代碼、各面向判定與依據
分歧處理	原始差異、討論紀錄與最後判定

【待補：正式欄位結構、匯出範例與評閱者操作說明，須與實際平台產出逐欄核對。】

附錄三 版本與來源追溯

本稿的系統敘述依紫區平台開發文件及程式整理，版本識別如下。這些識別用於回查，不代表正式研究已凍結。

平台程式庫：tarshar4242/thesis-semantic-platform。查閱基準 commit 為 a885e58，程式核心沿用此前 f229681 的版本；開發驗證紀錄日期為 2026 年 10 月 22 日。

開發語料 SHA-256：3beff8975506e157fbab89e61035788171909a0b0eb4fae16ec9550be67674c0。

原始語料來源 commit：1dd75bfd4dcd06039f1803f2a65b95c9c64c464d；來源路徑為 projects/論文線/thesis-platform/data/corpus.json。補充材料與來源盤點見紫區 data/manifest.json、data/source_audit.json 及 docs/verification.json。

向量模型版本：BAAI/bge-base-zh-v1.5，revision f03589ceff5aac7111bd60cfc7d497ca17ecac65。開發回答模型識別：gpt-5.4-mini-2026-03-17。

目前全文的寫作正本保存於共同大腦紫區；網站、雲端硬碟與 RAY 保留同版成果與版本索引。綠區保存歷史方案、文獻與開發脈絡，不將舊實驗數據混入本研究結果。

公開論文入口：https://tarshar4242.github.io/learn-ai-with-tarshar/thesis-library/purple/

研究平台與互動架構圖：http://100.83.58.39:8771/ 與 http://100.83.58.39:8771/architecture。此服務需裝置已連接指定私人網路；公開論文入口可直接閱讀與下載。

【待補：正式凍結後，以完整 commit、提示詞雜湊、語料清單與執行環境清單替換本附錄的開發識別，並保留歷史版本。】

附錄四 待完成事項與論文定稿條件

本稿的紅字不是已執行的研究內容，而是取得正式證據或決策後需要補入的位置。完成下列事項後，仍需全文檢查摘要、研究問題、方法、結果與結論是否一致。

表 A-3 定稿前的必要工作

工作	完成條件	對應章節
正式題名與研究問題	本人與教授確認用語及範圍	封面、一、三
文獻補讀	中文場域、字面查找與評估方法原文核對	二、三
語料驗收	來源、時效、段落與納排規則可回查	三、附錄三
題組與參考答案	未見正式題、支持證據及審查紀錄完整	三、附錄一
規程與評分凍結	換詞、追問、停止、重試與評分規準確定	三、附錄二
正式執行與分析	原始紀錄、配對結果及人工評閱完整	四
結論與摘要回寫	所有主張能回到正式結果	摘要、五
學校格式核對	封面、指導資訊、頁碼、書目及必要表件確認	全文

附錄五 AI 協作與研究責任說明

本工作稿使用 Codex 協助整理既有研究材料、整合章節、查核來源與產製文件，並由 Claude Code 協助第二章文獻線索整理及舊稿範圍審查。AI 協作產生的文字屬研究者待審閱的草稿，不代表教授或領域專家已認可其研究設計與結論。

2026 年 10 月 23 日的第二章協作輸出，依既有研讀卡與舊章稿整理；本次未重新逐頁閱讀全部歷史文獻。因此，正文避免保留未重新交叉核對的精確頁碼與統計細節，並將文獻原文補讀列為待完成事項。RAGAs、ALCE 與 NotebookLM 功能說明於本次核對官方頁面，引用僅限可由該頁支持的範圍。

【待確認：學校對生成式 AI 使用揭露、論文原創性與引用格式的正式要求；研究者須逐段確認內容並負責最終提交版本。】